



UNIVERSITAT OBERTA DE CATALUNYA (UOC)

MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS (*Data Science*)

TRABAJO FINAL DE MÁSTER

ÁREA: 004

Mantenimiento Predictivo

Predicción del fallo de máquinas de producción a partir de datos de un sistema de sensores.

Autor: Oscar Rojo Martín

Tutor: Lorena Polo Navarro

Profesor: Antonio Lozano Bagén

Donostia-San Sebastián, 22 de enero de 2023

Créditos/Copyright

Copyright © 2022 Oscar Rojo Martín.

Permission is granted to copy, distribute and/or modify this document under the terms of the GNU Free Documentation License, Version 1.3 or any later version published by the Free Software Foundation; with no Invariant Sections, no Front-Cover Texts, and no Back-Cover Texts. A copy of the license is included in the section entitled "GNU Free Documentation License".

Se concede permiso para copiar, distribuir y/o modificar este documento bajo los términos de la Licencia de Documentación Libre de GNU, Versión 1.3 o cualquier versión posterior publicada por la Fundación para el Software Libre; sin secciones invariables, sin textos de portada y sin textos de contraportada. Se incluye una copia de la licencia en la sección titulada "Licencia de Documentación Libre GNU".



[GNU Free Documentation License](#).

FICHA DEL TRABAJO FINAL

Título del trabajo:	Mantenimiento Predictivo
Nombre del autor:	Oscar Rojo Martín
Nombre del colaborador/a docente:	Lorena Polo Navarro
Nombre del PRA:	Antonio Lozano Bagén
Fecha de entrega (mm/aaaa):	01/2023
Titulación o programa:	Máster Ciencia de Datos
Área del Trabajo Final:	Área 4 - Data Science en el ámbito industrial
Idioma del trabajo:	Español
Palabras clave	Industria, Sensores, Predicción

Dedicatoria/Cita

Este trabajo se lo dedico a todos los empresarios que desde principios del siglo pasado han contribuido a este territorio a ser uno de los más importantes de España en materia de riqueza, educación y bienestar.

“La educación es el arma más poderosa que puedes usar para cambiar el mundo.”
- Nelsón Mandela (1918-2013)

Agradecimientos

Te elijo para ser mi esposa, para hacer la vida de la mano, codo con codo. Te elijo para amar, con todo mi ser, incondicionalmente. Te elijo al principio y al final de cada día. Y te elegiría en cien vidas, en cien mundos, en cualquier versión de la realidad que te encontrara, y te elegiría.

¡Gracias **Lei!**

Y como no, mis otras 3 chicas: **”Arritxu, Emma y Maya”**

Abstract

The importance of industrial activity is one of the main characteristics of the economy of Gipuzkoa, a territory with a very rugged orography, densely populated, with a high level of economic and social development and an income level on a par with that of northern European countries. Industrial activity is highly specialised in the metal sector, such as iron and steel, automotive parts and components, metal products, capital goods, machine tools and transport equipment. All these sectors have a wide range of machinery. This work is intended to treat, visualise and generate a predictive model from the multiple sensors currently available. Machine Learning models will be applied and the results will be displayed in a Dashboard for consultation.

Keywords: Industry, Sensors, Prediction, Master Final Project

Resumen

La importancia de la actividad industrial es una de las características principales de la economía guipuzcoana, un territorio con una orografía muy agreste, densamente poblado, con un alto nivel de desarrollo económico y social y un nivel de renta a paises del norte de Europa. La actividad industrial se encuentra muy especializada en el sector dell metal, como es la siderometalurgia, piezas y componentes de automoción, productos metálicos, bienes de equipo, máquina herramienta y material de transporte. Todos estos sectores cuentan con una amplia gama de maquinaria. Este trabajo está destinado a tratar, visualizar y generar un modelo predictivo provenientes de los múltiples sensores con los que cuentan actualmente. Se intentarán aplicar modelos de Machine Learning y los resultados se mostrarán en un Panel de Mando para su consulta.

Palabras clave: Industria, Sensores, Predicción, Trabajo de Final de Máster

Índice general

1. Introducción	8
1.1. Introducción	8
1.2. Contexto y justificación del Trabajo	8
1.3. Objetivos del Trabajo	9
1.4. Impacto en sostenibilidad, ético-social y de diversidad	10
1.5. Enfoque y método seguido	10
1.6. Planificación del Trabajo	11
2. Estado del Arte	12
2.1. Introducción	12
2.2. Un poco de historia	12
2.3. Qué es el mantenimiento	13
2.4. El mantenimiento predictivo	15
2.4.1. El mantenimiento predictivo en la Industria 4.0	16
2.4.2. Técnicas	16
2.5. Bombas de Agua	17
2.5.1. Fallos en las Bombas de Agua	17
2.5.2. Métodos de mantenimiento de las bombas de agua	19
2.6. Líneas de investigación	21
2.6.1. Continuous time predictive maintenance scheduling for a deteriorating system, L. Dieulle, C. Berenguer, A. Grall and M. Roussignol. 2001 . . .	22
2.6.2. Predictive maintenance techniques, Bin Lu; David B. Durocher; Peter Stemer, 2009	23
2.6.3. A predictive maintenance policy with imperfect monitoring, Giuseppe Curcurù, Giacomo Galante, Alberto Lombardo, 2010	23
2.6.4. A new paradigm of cloud-based predictive maintenance for intelligent manufacturing, Wang, J., Zhang, L., Duan, L., 2015	23

2.6.5. Predictive Maintenance of Power Substation Equipment by Infrared Thermography Using a Machine-Learning Approach, Ullah I, Yang F, Khan R, Liu L, Yang H, Gao B, Sun K., 2017	24
2.6.6. Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture, Cachada, Ana and Barbosa, Jose and Leitño, Paulo and Geraldcs, Carla A.S. and Deusdado, Leonel and Costa, Jacinta and Teixeira, Carlos and Teixeira, Joao and Moreira, António H.J. and Moreira, Pedro Miguel and Romero, Luís, 2018	25
2.6.7. Resumen	26
2.7. La gestión de los datos	28
2.7.1. CRISP-DM	29
2.8. Aprendizaje automático	30
2.9. Aprendizaje supervisado	30
2.9.1. Modelos de aprendizaje supervisado	31
2.9.2. Red neuronal artificial	32
2.9.3. Problemas de datos desequilibrados	32
2.9.4. Overfitting y Underfitting	32
2.9.5. Métricas más comunes para la clasificación	33
2.10. Aprendizaje no supervisado	35
2.10.1. Algoritmos de clustering	36
2.10.2. Clases de algoritmos	36
2.10.3. Métricas para el aprendizaje no supervisado	37
2.11. Aprendizaje semisupervisado	39
2.11.1. Métodos inductivos	39
2.11.2. Métodos envolventes	39
2.11.3. Preprocesamiento no supervisado	40
2.11.4. Métodos intrínsecamente semisupervisados	41
2.11.5. Métodos transductivos	41
3. Diseño e Implementación	43
3.1. Requerimientos técnicos	43
3.2. Software	43
3.2.1. Sistema Operativo: Linux	44
3.2.2. IDE	44
3.2.3. Lenguajes de Programación	45
3.2.4. Control de versiones	46
3.2.5. Cloud	46

3.2.6. Navegador web	47
3.2.7. Latex	47
3.3. Hardware	48
3.4. Contexto y dataset	50
3.5. Métricas de rendimiento	52
3.6. Resumen de datos	53
3.7. EDA - Análisis Exploratorio de Datos	56
3.7.1. Distribución de las clases	56
3.7.2. Missing Values	56
3.7.3. Visualización de sensores	58
3.7.4. Matriz de correlaciones	60
3.8. Modelado	62
3.8.1. Normalización de datos	63
3.8.2. Seleccionar el tamaño de la muestra de validación	63
3.8.3. Modelos utilizados	64
3.8.4. Comparación de modelos	66
3.8.5. Ajuste de hiperparámetros	67
3.9. Aplicación web	69
3.9.1. Codificación	69
3.9.2. Apartados de la Aplicación-Web	70
3.9.3. Puesta en Producción de la aplicación	74
3.10. Repositorio	74
4. Conclusiones	75
4.1. Conclusiones	75
4.2. Lineas Futuras	76
5. Bibliografía	77
Anexo I	82

Índice de figuras

1.1.	Diagrama-ML-Django	10
3.1.	Distribución de clases	56
3.2.	Mapa de Calor de Missing Values	57
3.3.	Sensor_01	58
3.4.	Sensor_02	58
3.5.	Stat	59
3.6.	Rol	59
3.7.	Matriz de correlaciones	61
3.8.	División de datos	64
3.9.	División de datos	65
3.10.	Matriz de confusión para KNN	66
3.11.	CrossValidation	67
3.12.	KNN Best	68
3.13.	Pantalla inicial.	69
3.14.	Login	70
3.15.	EDA	70
3.16.	Visualización	71
3.17.	ScatterPlot by Plotly	72
3.18.	Input predicción	73
3.19.	Tabla de Resultados	73
3.20.	Importador de ficheros	74
5.1.	Sensor_03	82
5.2.	Sensor_04	82
5.3.	Sensor_05	83
5.4.	Sensor_06	83
5.5.	Sensor_07	83
5.6.	Sensor_08	83

5.7.	Sensor_09	84
5.8.	Sensor_10	84
5.9.	Sensor_11	84
5.10.	Sensor_12	84
5.11.	Sensor_13	85
5.12.	Sensor_14	85
5.13.	Sensor_16	85
5.14.	Sensor_17	85
5.15.	Sensor_18	86
5.16.	Sensor_19	86
5.17.	Sensor_20	86
5.18.	Sensor_21	86
5.19.	Sensor_22	87
5.20.	Sensor_23	87
5.21.	Sensor_24	87
5.22.	Sensor_25	87
5.23.	Sensor_26	88
5.24.	Sensor_27	88
5.25.	Sensor_28	88
5.26.	Sensor_29	88
5.27.	Sensor_30	89
5.28.	Sensor_31	89
5.29.	Sensor_32	89
5.30.	Sensor_33	89
5.31.	Sensor_34	90
5.32.	Sensor_35	90
5.33.	Sensor_36	90
5.34.	Sensor_37	90
5.35.	Sensor_38	91
5.36.	Sensor_39	91
5.37.	Sensor_40	91
5.38.	Sensor_41	91
5.39.	Sensor_42	92
5.40.	Sensor_43	92
5.41.	Sensor_44	92
5.42.	Sensor_45	92

5.43. Sensor_46	93
5.44. Sensor_47	93
5.45. Sensor_48	93
5.46. Sensor_49	93

Índice de cuadros

1.1.	Teamgantt	11
1.2.	Planificación	11
2.1.	Análisis comparativo de las ventajas e inconvenientes del mantenimiento reactivo y proactivo.	15
2.2.	Textos analizados	21
2.3.	Tabla resumen	27
3.1.	Especificaciones Hardware I/II	48
3.2.	Especificaciones Hardware II/II	49
3.3.	Sensores I	51
3.4.	Sensores II	52
3.5.	Head and Tail Dataset	54
3.6.	Estadísticas Dataset	55
3.7.	Comparación modelos	66

Capítulo 1

Introducción

1.1. Introducción

Como hemos visto durante el último siglo y medio, las máquinas - en general - durante su proceso de vida tienen periodos en que requieren de reparaciones o de sustitución de piezas por el desgaste de estas. Con la evolución de la tecnología inalámbrica y conectada 4G y 5G cada vez existe una mayor oferta de sensores inteligente, que permiten monitorizar las máquinas, y en base a sus comportamientos, predecir estos últimos. El TFM que presentamos va destinado a generar una WEB-APP donde se mostrarán los datos registrados por los sensores recopilados de diferentes maquinarias y se realizarán análisis de machine learning con el fin de predecir anomalías, fallos o paradas en dichas maquinarias.

1.2. Contexto y justificación del Trabajo

Este trabajo trata de concebir una herramienta / aplicación web con un enfoque de aprendizaje automático para la detección de anomalías en sistemas de control industrial basados en datos de medición.

El contexto de la elección del presente trabajo se basa en:

- Resido en Donostia - Gipuzkoa. Una provincia con gran tradición industrial, siderometalúrgica, maquina-herramienta, industria auxiliar y del transporte, al tener frontera con Francia. Destacando empresas tractoras como la cooperativa Mondragon, Ulma, Irizar, Orona, CAF, y multinacionales como DANA, GKN y Zardoya.
- Trabajo como Analista de Datos en una pequeña empresa y por ahora el nicho de mercado es la creación de Paneles de Control de carácter económico financiero para las empresas de servicios. Esta web-app puede ser una buena herramienta para poder ofrecer otros servicios

a las empresas, en particular, PYMEs radicadas en la provincia que se dedican al sector industrial y no tengan suficiente capacidad económica para contratar estos servicios a grandes empresas de consultoría.

- Como indicábamos antes, existe una gran cantidad de pequeña empresa que tiene matri-cería, fresadoras, troqueladoras, de corte, semiautomáticas, etc.. y que se beneficiarían de esta tecnología para poder reducir costes o evitar cortes de producción o parones no previstos o innecesarios.

1.3. Objetivos del Trabajo

Este proyecto consta de un objetivo general y tres específicos.

El proyecto general es el de proporcionar una herramienta analítica capaz de predecir la rotura de una máquina, en concreto una bomba de agua.

Primer objetivo específico En este Trabajo Final de Máster (TFM), se busca desarrollar un modelo analítico de mantenimiento predictivo que sea capaz de proporcionar resultados consistentes y precisos. Un sistema que pueda anticipar posibles fallos o problemas en las máquinas o equipos, de manera que se puedan realizar intervenciones preventivas antes de que se produzcan averías. Esto permitiría reducir el tiempo de inactividad de los equipos, minimizar los costes de reparación y mejorar la eficiencia y productividad de la empresa. Para lograr este objetivo llevaremos a cabo diversas actividades, como la recopilación y análisis de datos de las máquinas, la implementación de técnicas de análisis de fallos y la evaluación del rendimiento y fiabilidad del modelo desarrollado.

Segundo objetivo Nuestra segunda meta específica es desarrollar una aplicación web basada en el framework Django, con el propósito de crear un panel de control que muestre gráficas de los datos recogidos por los sensores. Además, utilizaremos un gráfico de dispersión para comparar los datos de diferentes sensores y una sección para predecir si la máquina tendrá problemas o no en el futuro, basándonos en la información que se ingrese. Esta herramienta será construida a partir de los resultados obtenidos en el objetivo anterior.

Tercer objetivo Poner la aplicación-web en producción, utilizando AWS, GITHUB, además de conocer sintaxis bash para poder utilizar GNU Screen con varias consolas (terminales) a la vez y VIM como editor de texto para editar código dentro de la consola de la instancia que nos proporcione AWS

1.4. Impacto en sostenibilidad, ético-social y de diversidad

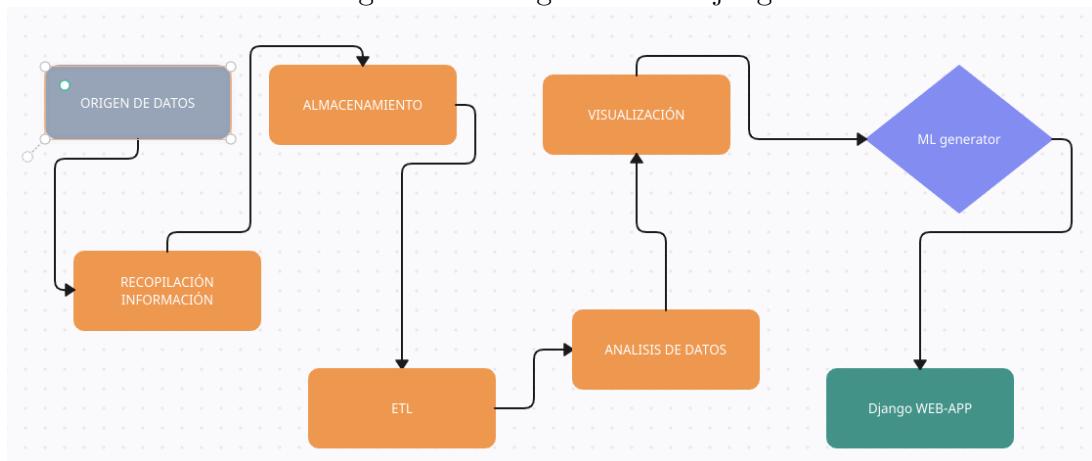
Actuar de manera honesta, ética, sostenible, socialmente responsable y respetuosa con los derechos humanos y la diversidad, tanto en la práctica académica como en la profesional, y diseñar soluciones para mejorar estas prácticas.

1.5. Enfoque y método seguido

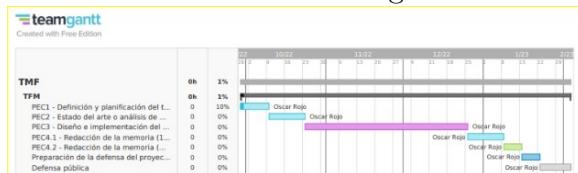
El método elegido es el siguiente:

- Analizar el origen de los datos.
- Recopilar información.
- Almacenamiento.
- Extracción, Transformación y Carga.
- Analizar los datos.
- Visualización / representación gráfica.
- Generación de modelo predictivo.
- Integrar todo ello en una aplicación web.

Figura 1.1: Diagrama-ML-Django



Cuadro 1.1: Teamgantt



1.6. Planificación del Trabajo

Para la gestión del TFM hemos utilizado teamgantt.com.

Es una aplicación web de planificación y colaboración que se utiliza para visualizar y organizar el trabajo en proyectos. Nos permitió crear gráficos de Gantt para diseñar y seguir el progreso de los proyectos, asignar tareas y plazos, y colaborar en tiempo real con comentarios y documentos adjuntos.

Detallamos:

Cuadro 1.2: Planificación

Título	Descripción	Inicio	Fin
Definición y planificación del trabajo final	Aquí hemos planteado y definido el objetivo de la temática del TFM, justificando su relevancia, definiendo los objetivos principales y la planificación temporal del proyecto.	28/09/2022	09/10/2022
Estado del arte o análisis del mercado del proyecto	Entrevistar a empresarios de la industria del metal en Gipuzkoa, jefes de Taller, responsables de laboratorio y comercial de multinacionales de la automoción ha sido uno de los componentes principales para recopilar la información necesaria para el TFM, además de recopilar otros trabajos de investigación vinculados con la temática planteada	10/10/2022	23/10/2022
Diseño e implementación del trabajo	Programar y desarrollar la web-app utilizando Python como lenguaje de programación y la librería principal Django uno de los frameworks de servidores web más populares, para configurar un entorno de desarrollo y crear aplicaciones web. Posteriormente hemos procedido a generar el Pipeline necesario ponerlo en producción en AWS	24/10/2022	25/12/2022
Redacción de la memoria.	Este apartado ha estado centrado en redactar la memoria del TFM, plastando en un documento todo el código generado en el anterior apartado	26/12/2022	08/01/2023
Preparación de la defensa del proyecto.	Creación de un vídeo de presentación del Trabajo de Fin de Máster.	09/01/2023	15/01/2023
Defensa del proyecto.	Delante de un tribunal evaluador, se realizará la defensa del TFM. Esta defensa síncrona constará de una presentación-resumen y de la respuestas a las consultas realizadas por el tribunal evaluador	16/01/2023	22/01/2023

Capítulo 2

Estado del Arte

2.1. Introducción

El mantenimiento predictivo (PdM) es una técnica que emplea el análisis basado en datos para detectar condiciones de trabajo anómalas y predecir los riesgos de fallos futuros de los activos. A pesar de su amplia aplicación en las industrias manufacturera, del petróleo y el gas, la aplicación del mantenimiento predictivo en instalaciones de infraestructura -en el sector de PYMEs industriales en Gipuzkoa- es escasa, de acuerdo a las consultas realizadas a diferentes empresarios del sector industrial en el territorio. En este sentido destacamos:

1. Utilizan los sensores instalados en la maquinaria para controlar el output, es decir ,el producto final(calidad, resistencia, etc).
2. Varios empresarios no les interesa esta tecnología de PdM, ya que creen que les supone un esfuerzo muy grande en personal, en tiempo y en coste (no inversión).
3. Directamente quitan o desconectan todos los sensores conectados a las máquinas.

La llegada de las TICs y de la IA ofrece una gran oportunidad para mejorar la práctica del mantenimiento de infraestructuras mediante la integración de técnicas de PdM.

2.2. Un poco de historia

La Revolución industrial constituyó uno de los períodos más decisivos de la trayectoria de la Humanidad. Las principales áreas a las que se dirigió la revolución industrial fueron la tecnológica, la socio-económica y la cultural, cambiando el mundo tal y como es hoy, nuestra forma de vivir y la organización social, política y económica actual. Destacamos los siguientes cambios:

1. Utilización de nuevos materiales, principalmente el hierro y el acero.
2. Uso de nuevas fuentes de energía, como el carbón, la máquina de vapor, la electricidad, el petróleo y los motores de combustión interna.
3. La invención de nuevas máquinas para la industria textil (por ejemplo, la rueda de torsión).
4. La organización de la producción en el sistema tipo fábrica que conocemos hoy y la división del trabajo;
5. El desarrollo de los medios de transportes y de comunicación como: locomotoras de vapor, barcos de vapor, aviones, telégrafo, radio.
6. La aplicación de los principios científicos en la industrialización.

Todos estos cambios tecnológicos han contribuido en una gran medida a la utilización de los recursos naturales y han permitido la producción en masa de bienes. Hoy en día, el mantenimiento es una cuestión de suma importancia en el entorno industrial y no hace más que mejorar el entorno de trabajo, los rendimientos y la rentabilidad.

2.3. Qué es el mantenimiento

El objetivo o elemento principal de las empresas son los **productos**. Por ello es necesario un plan de gestión de productos que garantiza el buen desarrollo y la organización de todas las etapas, recursos y medios implicados en el proceso de producción.

El mantenimiento presente desde la fase de diseño de un producto, debe garantizar el buen funcionamiento del producto en función de su vida útil. dentro de las cinco fases en el ciclo de vida de un producto: idea, definición, realización, uso y reciclaje. Fases comprendidas en 3 categorías:

1. La fase incipiente: idea, definición, realización;
2. La fase intermedia: uso;
3. Fase final: reciclaje.

La fase intermedia es la que más tiempo dura, ya que el producto está en fase de uso, por lo que es necesario mantenerlo para que funcione en parámetros óptimos.

El concepto de mantenimiento está definido por la norma UNE-EN 13306:2018: es la **Combinación de todas las acciones técnicas, administrativas y de gestión realizadas**

durante el ciclo de vida de un elemento, destinadas a conservarlo o a devolverlo a un estado en el que pueda desempeñar la función requerida.

El mantenimiento de los equipos ha evolucionado a lo largo del tiempo, desde el mantenimiento que se realizaba sólo cuando los elementos sufrían daños hasta los métodos modernos, el mantenimiento proactivo y el predictivo, siendo este último el más popular en la actualidad.

El mantenimiento realizado sólo en caso de daños o fallos, ha demostrado que es un método ineficiente por fallos en el sistema. Esto derivó en el mantenimiento programado (revisión total si hay problemas) y su consecuente problema de sustituir elementos sin haber llegado al final de su vida útil. Por ejemplo: **La Correa de distribución del coche, esta tiene programada su sustitución con 100.000 km, pero el nº de km recorridos sin que se rompa puede ser superior a los 135.000 km. con el consiguiente problema de que se rompa...** pero eso es otra historia.

El siguiente paso fue el mantenimiento predictivo. Según **A state of the art of predictive maintenance techniques** las tareas de mantenimiento se pueden clasificar en:

1. Mantenimiento reactivo: el sistema se utiliza hasta que se producen averías. Cuando se produce una avería, los sistemas se detienen y se sustituyen los elementos dañados para restablecer la capacidad de funcionamiento del sistema.
2. Mantenimiento proactivo - las acciones de mantenimiento se planifican o tienen lugar como resultado de los indicadores de seguimiento. La planificación puede realizarse mediante sensores que anuncian las primeras fases de una avería. Este tipo de mantenimiento tiene como objetivo mantener la funcionalidad del sistema.

Independientemente del tipo de mantenimiento que se aplique, el objetivo de estas actividades es reducir al máximo las paradas causadas por las averías. Y para ello es necesario entender los modos y mecanismos de los fallos.

Debemos de tener en cuenta que los procesos industriales se llevan a cabo con sistemas eléctricos y mecánicos.

Cuadro 2.1: Análisis comparativo de las ventajas e inconvenientes del mantenimiento reactivo y proactivo.

Table 1. Reactive and proactive maintenance advantages and disadvantages.

	Advantages	Disadvantages
Reactive maintenance	Low initial costs Easy to implement	Unscheduled stops High associated costs (work over schedule, delivery urgency, manufacturing urgency) Poorly optimized resources
Proactive maintenance	Increased system reliability Minimizing logistical stops Reduction of non-scheduled stops Lowers costs (optimizing parts, optimizing work) Maintenance planning Optimization of logistic support	High initial set-up costs The cost reduction is not immediate Not reliable for all equipment

2.4. El mantenimiento predictivo

El mantenimiento predictivo es un concepto enmarcado como un enfoque de mantenimiento proactivo.

Una de las técnicas más utilizadas es el **mantenimiento predictivo condicional**, el cual se realiza observando ciertos parámetros o ciertos componentes del sistema. En él, el estado del sistema se presenta en tiempo real, en función de los parámetros, siendo algunos de los más importantes:

- Análisis de vibraciones: es el método más eficiente para detectar problemas en los equipos que realizan movimientos rotativos.
- Análisis acústico: puede detectar o monitorizar grietas en tuberías o conductos;
- Análisis de aceites de lubricación: se analizan las partículas encontradas en los aceites utilizados para determinar el grado de desgaste de los componentes que utilizan.
- Análisis de partículas en el entorno de trabajo: método generalmente utilizado en equipos que trabajan en un entorno fluido.

- Análisis de corrosión: se realizan mediciones de ultrasonido para determinar la corrosión en diferentes estructuras.
- Análisis térmico: se utiliza especialmente en el caso de sistemas mecánicos y eléctricos para detectar sobrecaleamiento en general.
- Análisis de rendimiento: una técnica eficaz para determinar los problemas de funcionamiento del sistema.

Utilizando alguno o algunos de los métodos indicados, se desarrollan soluciones de mantenimiento para equipos y sistemas sistemas.

Suponiendo que 30 % de los costes de mantenimiento se deben a una mala planificación del mantenimiento, con costes añadidos en el proceso de producción, el mantenimiento predictivo es un método interesante en la industria, donde las paradas pueden causar grandes pérdidas.

2.4.1. El mantenimiento predictivo en la Industria 4.0

En estos momentos la industria se enfrenta a dificultades debido al desarrollo de la tecnología, la disminución de los recursos naturales, la incidencia de guerras y desastres naturales y al mismo tiempo cuestiones sociales como la globalización y el aumento de la edad de jubilación de la mano de obra, cuestiones que producen efectos económicos. Además los consumidores de hoy en día quieren una alta calidad y variedad de productos, así como una calidad servicios durante su uso.

La visión de la Industria 4.0 viene con un impacto masivo en la forma actual de trabajar en la industria caracterizada por un nuevo modelo de interacción socio-tecnológica: **Nuevas fábricas inteligentes**.

La industria 4.0 la define el artículo **The concept Industry 4.0** como que *representa básicamente una sinergia entre el Internet de las Cosas, el Internet de los Servicios y por supuesto, el proceso industrial.* y estos se pueden aprovechar para desarrollar una estrategia de mantenimiento predictivo utilizando las tecnologías mencionadas, siendo esto alcanzable con reducidos recursos materiales y recursos humanos. La Industria 4.0 está dando forma a los procesos de fabricación y mantenimiento y a los que se producen de la interacción máquina-hombre.

2.4.2. Técnicas

Las podemos dividir en tres técnicas básicas:

- Mantenimiento usando los sensores ya instalados.

- Mantenimiento basado en sensores de prueba.
- Mantenimiento basado en la técnica de señales de prueba.

Todas tienen como objetivo el de proporcionar una mejora en el análisis de fallos, aunque representan enfoques diferentes. Las dos primeras técnicas pueden considerarse **pasivas** y la tercera **activa**, cuya aplicación tiene en cuenta las respuestas del bucle y las pruebas en tiempo real.

2.5. Bombas de Agua

Las bombas de agua son componentes esenciales y costosos en los sistemas de distribución de agua. Su papel es clave en la transmisión y distribución del líquido, conectando todas las etapas del proceso. Estos equipos son propensos a fallos debido a su complejo funcionamiento en diferentes condiciones, tales como altas temperaturas, sobre-esfuerzos y uso prolongado al aire libre. En consecuencia, las bombas de agua representan un riesgo para la seguridad del sistema de distribución de agua potable en las ciudades.

2.5.1. Fallos en las Bombas de Agua

Los fallos de esta pieza clave del sistema de distribución de agua puede tener graves consecuencias, como costos de reparación o reemplazo y pérdidas de ingresos. Además, la frecuencia de fallos puede afectar la confiabilidad del sistema a largo plazo. Por ello, es fundamental conocer los componentes de las bombas de agua y entender cómo pueden fallar. Algunos de estos componentes incluyen el platillo o polea, la carcasa, los rodamientos, el cierre, la turbina, los circuitos eléctricos y de aceite, y los controles de presión. Un problema en cualquiera de estos elementos puede poner en riesgo la operación de la bomba y llevar a su retiro del sistema de distribución de agua en las ciudades.

2.5.1.1. Curvas de fallo en equipos industriales

En la actualidad existen seis curvas que se consideran modelos de fallos para equipos industriales. Estas curvas se pueden dividir en dos grupos. El primer grupo es el mantenimiento basado en el tiempo y el segundo grupo es el mantenimiento basado en la condición.

Los mantenimientos basados en el tiempo, también conocidos como mantenimiento preventivo, se realizan de forma regular a intervalos predeterminados de tiempo. Estos mantenimientos tienen como objetivo evitar fallos y prolongar la vida útil de la bomba. Algunas tareas comunes incluyen:

- Inspecciones visuales: consisten en examinar la bomba y sus componentes para detectar signos de desgaste o daño.
- Limpieza: se realiza para eliminar suciedad, polvo y otros contaminantes que pueden afectar el funcionamiento de la bomba.
- Lubricación: se aplica para reducir la fricción y el desgaste en las piezas móviles de la bomba.
- Cambio de filtros: se realiza para mantener el flujo de agua limpio y evitar obstrucciones o daños a la bomba.

El intervalo de tiempo entre los mantenimientos preventivos puede variar según el tipo de bomba y el entorno en el que se utiliza. Es importante seguir el plan de mantenimiento recomendado por el fabricante para garantizar el correcto funcionamiento y prolongar la vida útil de la bomba.

Existen tres tipos comunes de curvas utilizadas en el mantenimiento basado en el tiempo:

- Curva de bañera: muestra el tiempo de vida útil de un componente según la frecuencia de uso. Los componentes que se usan con mayor frecuencia tienen una vida útil más corta y requieren mantenimiento más frecuente.
- Curva de desgaste: muestra el tiempo de vida útil de un componente según el desgaste o el deslizamiento. Los componentes que experimentan más desgaste tienen una vida útil más corta y requieren mantenimiento más frecuente.
- Curva de basura: muestra el tiempo de vida útil de un componente según la acumulación de basura o contaminantes. Los componentes que se contaminan más rápidamente tienen una vida útil más corta y requieren mantenimiento más frecuente.

Estas curvas se utilizan para establecer planes de mantenimiento preventivo y determinar cuándo deben realizarse las tareas de mantenimiento.

Los mantenimientos basados en la condición son aquellos que se realizan en función de la condición actual de la bomba, en lugar de siguiendo una frecuencia predeterminada. Algunos ejemplos de mantenimientos basados en la condición son:

- Mantenimiento predictivo: se basa en el monitoreo de la bomba para detectar posibles fallos antes de que ocurran. Esto puede incluir pruebas de rendimiento o mediciones de parámetros como la vibración o el consumo de energía.
- Mantenimiento basado en el tiempo de funcionamiento: se realiza en función de la cantidad de tiempo que ha estado en funcionamiento la bomba, en lugar de seguir una frecuencia fija.

- Mantenimiento basado en el uso: se realiza en función de la cantidad de uso que ha tenido la bomba, en lugar de mantener una frecuencia fija.

Los mantenimientos basados en la condición pueden ser más eficientes que otros tipos de mantenimiento, ya que se realizan cuando es necesario y no siguiendo una frecuencia predeterminada. Sin embargo, es importante contar con un sistema de monitoreo adecuado para poder llevar a cabo este tipo de mantenimiento de manera efectiva.

Las curvas de mantenimiento basado en la condición, son gráficos que se utilizan para determinar cuándo se deben realizar los mantenimientos en función de la condición actual de la bomba. Algunos ejemplos de curvas que se pueden utilizar en el mantenimiento basado en la condición son:

- Curva de Degradación: muestra cómo la condición de la bomba se va deteriorando con el tiempo. Se pueden establecer umbrales en la curva para indicar cuándo se debe realizar un mantenimiento preventivo o correctivo.
- Curva de Cumplimiento: muestra el porcentaje de tiempo en el que la bomba cumple con ciertos parámetros de rendimiento o calidad. Se pueden establecer umbrales en la curva para indicar cuándo se debe realizar un mantenimiento preventivo o correctivo.
- Curva de Carga: muestra el porcentaje de carga de la bomba en función del tiempo. Se pueden establecer umbrales en la curva para indicar cuándo se debe realizar un mantenimiento preventivo o correctivo.

Estas curvas pueden ser útiles para planificar el mantenimiento de las bombas de agua y tomar decisiones sobre cuándo realizar ciertas tareas de mantenimiento.

2.5.2. Métodos de mantenimiento de las bombas de agua

El mantenimiento es considerado una actividad estratégica que garantiza la credibilidad de la operación de equipos y procesos industriales.

El mantenimiento debe buscar la intervención en los equipos reduciendo el tiempo de intervención, dejando el sistema inaccesible por el menor tiempo posible .

Existen varios métodos de mantenimiento para las bombas de agua y algunos de ellos son:

- Mantenimiento preventivo: se realiza de forma regular para evitar fallos y prolongar la vida útil de la bomba. Puede incluir tareas como inspecciones visuales, limpieza y lubricación de piezas, y cambio de filtros.

- Mantenimiento correctivo: se realiza cuando se detecta un problema o fallo en la bomba. Puede incluir reparaciones o reemplazo de piezas dañadas.
- Mantenimiento predictivo: se basa en el monitorización de la bomba para detectar posibles fallos antes de que ocurran. Esto puede incluir pruebas de rendimiento o mediciones de parámetros como la vibración o el consumo de energía.
- Mantenimiento adaptativo: se realiza para adaptar la bomba a nuevas condiciones de trabajo o cambios en el sistema en el que está instalada.

Es importante seguir un plan de mantenimiento adecuado para garantizar el correcto funcionamiento y prolongar la vida útil de la bomba de agua.

2.5.2.1. Flujo de trabajo del sistema de mantenimiento predictivo

Es fundamental conocer los posibles fallos que pueden presentar los equipos en el **mantenimiento predictivo (PdM)**, ya que este sistema se basa en un conjunto de indicadores que reflejan el estado del equipo y son utilizados para tomar decisiones.

Por lo tanto, se llevan a cabo diferentes tipos de análisis para detectar estos fallos, como el análisis físico-químico, el análisis de la firma eléctrica, el análisis de partículas, la inspección termográfica, el método de emisión acústica y el análisis de gases disueltos, entre otros.

Para hacer predicciones sobre el estado de los equipos, una buena opción es utilizar algoritmos de aprendizaje automático.

Por lo general, el proceso de **PdM** se divide en cuatro fases.

- La primera fase es la adquisición de datos, en la que se recogen los datos de los sensores y los análisis mencionados anteriormente.
- Luego, se lleva a cabo una fase de preprocesamiento para limpiar los datos adquiridos.
- A continuación, los datos procesados se pasan a un algoritmo de aprendizaje automático para entrenar un modelo.
- Finalmente, se utiliza el modelo para predecir anomalías en un nuevo conjunto de datos. Si se detecta alguna anomalía, se informa al usuario para que decida si es necesario intervenir.

2.6. Líneas de investigación

En cuanto a investigación, hemos elegido los siguientes trabajos relacionados con el tema de este trabajo fin de máster.

Cuadro 2.2: Textos analizados

Titulo	Autores	Año
Continuous time predictive maintenance scheduling for a deteriorating system	L. Dieulle, C. Berenguer, A. Grall and M. Roussignol	2001
Predictive maintenance techniques	Bin Lu; David B. Durocher; Peter Stempfer	2009
A predictive maintenance policy with imperfect monitoring	Giuseppe Curcurù, Giacomo Galante, Alberto Lombardo	2010
A new paradigm of cloud-based predictive maintenance for intelligent manufacturing	Wang, J., Zhang, L., Duan, L.	2015
Predictive Maintenance of Power Substation Equipment by Infrared Thermography Using a Machine-Learning Approach	Ullah I, Yang F, Khan R, Liu L, Yang H, Gao B, Sun K.	2017
Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture	Cachada, Ana and Barbosa, Jose and Leitão, Paulo and Geraldes, Carla A.S. and Deusdado, Leonel and Costa, Jacinta and Teixeira, Carlos and Teixeira, João and Moreira, António H.J. and Moreira, Pedro Miguel and Romero, Luís	2018

A continuación detallamos dichos trabajos científicos.

2.6.1. Continuous time predictive maintenance scheduling for a deteriorating system, L. Dieulle, C. Berenguer, A. Grall and M. Roussignol. 2001

Los investigadores proponen un método utilizando sistemas que están sometidos a un deterioro continuo, para tratar:

- La creación de una estructura para aplicar el mantenimiento predictivo condicional, y la determinación de un modelo matemático de análisis de costes a partir de la aparición de los fallos.
- Demostrar que los costes de mantenimiento a largo plazo pueden reducirse sustancialmente, utilizando dicho enfoque.

Utiliza un modelo aleatorio para simular el deterioro continuo del sistema. Puede simular un envejecimiento en el caso de los modelos mecánicos, la evolución de los productos defectuosos en el caso de una línea de producción y el nivel de corrosión / erosión en el caso de las estructuras. El modelo elegido ofrece una rentabilidad teniendo en cuenta el tiempo necesario para realizar el mantenimiento durante un periodo indefinido.

El objetivo es realizar una estimación mínima de los costes teniendo en cuenta el nivel de desgaste y el momento adecuado para detener la máquina.

Como el mantenimiento está basado en la monitorización continua de los parámetros, se tiene un rendimiento mejor que otros métodos de mantenimiento. El modelo matemático presentado debe ser capaz de prevenir los aleatorios.

La solución se perfila en torno a dos ideas principales:

- Determinar el método de mantenimiento del sistema en cuestión, en función de la evolución de los daños.
- Determinar y establecer los datos para la siguiente inspección. Las simulaciones realizadas ofrecen desde una amplia gama de soluciones para determinar el modo de mantenimiento o la utilización del equipo hasta un fallo inminente para obtener el resultado deseado: la eficiencia de los costes de mantenimiento.

2.6.2. Predictive maintenance techniques, Bin Lu; David B. Durocher; Peter Stemer, 2009

Consideran como un dato principal el rendimiento de los motores eléctricos y los fallos en los rodamientos, siendo éstos los problemas más comunes.

Se trata de un estudio basado en dos casos prácticos realizados en un motor de soplador de 75 hp y en un motor de compresor de aire de 200 hp en una planta activa.

De ambos experimentos se obtuvieron resultados y conclusiones que confirman una desalineación en el eje del motor del soplador, una pérdida de rendimiento y una degradación para el motor del compresor debido a pequeños períodos de sobrecarga.

2.6.3. A predictive maintenance policy with imperfect monitoring, Giuseppe Curcurù, Giacomo Galante, Alberto Lombardo, 2010

Se trata de un método de mantenimiento predictivo que se ejecuta con un sistema de monitorización sujeto a errores. Para la generación de datos, se considera un sistema sujeto a degradación continua que se modela mediante cadenas de Markov, que permiten realizar una simulación eficaz para seguir la evolución del proyecto principal: Correlacionar la eficacia de los equipos de análisis y adquisición de datos con la reducción de costes en el mantenimiento predictivo en comparación con otros métodos de mantenimiento.

Su valoración depende de la calidad de los sensores y del coste de reparación de los daños. Cuando se modifican los parámetros de simulación y disminuye la calidad de los sensores utilizados para la adquisición, la eficacia del mantenimiento predictivo disminuye considerablemente, situándose por debajo del mantenimiento preventivo.

Los resultados de esta simulación refuerzan la idea de adoptar sistemas de mantenimiento predictivo, que mejoran los costes de mantenimiento, incluso cuando se toma el coste de los equipos de análisis (siempre que los sensores y los sistemas de adquisición proporcionen datos cualitativos).

2.6.4. A new paradigm of cloud-based predictive maintenance for intelligent manufacturing, Wang, J., Zhang, L., Duan, L., 2015

Aquí se proponen un sistema de mantenimiento predictivo basado en un nuevo sistema de control. Es una nueva arquitectura en la nube que utiliza un cliente móvil en lugar de la clásica arquitectura servidor-cliente, con el que se pretende incrementar la flexibilidad/adaptabilidad del sistema, reducir el volumen de datos brutos que se transmiten y mejorar el tiempo de respuesta a los cambios dinámicos que se producen en los sistemas monitorizados.

Inconvenientes: la planificación automática del mantenimiento, la gestión de la energía, la gestión de análisis y transmisión de datos, el almacenamiento de datos, la implementación de sistemas a gran escala. Para abordar algunas de estos problemas, como se menciona desde el principio, esta solución propone el uso de agentes móviles para distribuir tareas en la nube.

El **agente móvil** es un método derivado del estudio de la Inteligencia Artificial (IA) que pretende dividir las tareas y su ejecución en paralelo. Los agentes están representados por programas de software que migran dentro de la red.

Las principales características de un agente móvil son la autonomía, la inteligencia y la adaptabilidad, siendo adecuado para sistemas Cloud. Esto reduce la cantidad de datos transmitidos y permite la modificación y adaptación de los algoritmos que se ejecutan en los equipos, aumentando así su versatilidad.

Para ello se utilizaron seis motores de corriente alterna, cinco de ellos con diferentes defectos. Con el uso de agentes móviles, se envían programas de software para que se ejecuten y adquieran diferentes parámetros, según la metodología de mantenimiento predictivo. Luego, los datos se procesan con algoritmos específicos, consiguiendo una característica del equipo monitorizado. Los resultados confirmaron la eficacia del sistema y proporcionaron datos relevantes sobre el estado de los motores analizados en comparación con el motor estándar.

2.6.5. Predictive Maintenance of Power Substation Equipment by Infrared Thermography Using a Machine-Learning Approach, Ullah I, Yang F, Khan R, Liu L, Yang H, Gao B, Sun K., 2017

Los autores proponen una solución de mantenimiento predictivo mediante la **termografía** utilizando una cámara termográfica de infrarrojos y utilizando técnicas de ML (Machine Learning). Este tipo de anomalía se produce principalmente en los equipos de energía, donde los contactos imperfectos, la corrosión, el aislamiento imperfecto, etc. provocan el sobrecalentamiento del equipo.

Es método permite monitorizar el equipo en funcionamiento. El análisis se realiza sobre un total de 150 fotos, en las que se determinan unos 300 puntos de interés. Mediante Machine Learning los puntos de interés se clasifican como defectos o funcionamiento en parámetros. Utilizando la cámara de infrarrojos, como en el deterioro de los equipos eléctricos el principal efecto del envejecimiento de los cables está representado por un aumento de la resistencia, el análisis termográfico puede ofrecer información relevante para la implementación de las prácticas de mantenimiento predictivo.

2.6.6. Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture, Cachada, Ana and Barbosa, Jose and Leitño, Paulo and Gcraldcs, Carla A.S. and Deusdado, Leonel and Costa, Jacinta and Teixeira, Carlos and Teixeira, Joao and Moreira, António H.J. and Moreira, Pedro Miguel and Romero, Luís, 2018

Aquí se propone una innovadora estructura de mantenimiento predictivo basado en la arquitectura OSA-CBM (Open System Architecture for Condition Based Monitoring), donde describe la arquitectura de un sistema de mantenimiento inteligente y predictivo, alineado con los principios de la Industria 4.0. Esta arquitectura/estructura considera el análisis avanzado y va en línea de los datos recogidos para la detección más temprana de posibles fallos de la máquina. También apoya a los técnicos y operarios durante las intervenciones en el mantenimiento, proporcionando un soporte de decisión inteligentemente guiado.

Esta estructura consta de seis pasos:

1. Adquisición de datos: proporciona el acceso a los datos digitalizados del sensor y registra estos datos.
2. Manipulación de datos: puede realizar transformaciones de señales de uno o varios canales y aplicar algoritmos especializados de extracción de características a los datos recopilados.
3. Detección de estados: realiza la supervisión de las condiciones comparando las características con los valores esperados o los límites operativos y devolviendo indicadores de condiciones y/o alarmas.
4. Evaluación de la salud: determina si la salud del sistema está sufriendo una degradación, teniendo en cuenta las tendencias en el historial de salud, el estado operativo y el historial de mantenimiento.
5. Evaluación de pronóstico: proyecta el estado de salud actual del activo teniendo en cuenta una estimación de los perfiles de uso futuros.
6. Generación de consejos: proporciona recomendaciones relacionadas con el mantenimiento y modificación de la configuración del activo, teniendo en cuenta el historial operativo, los perfiles de perfiles de misión actuales y futuros y las limitaciones de recursos.

2.6.7. Resumen

Como broche final a este apartado, hemos generado una tabla resumen que presenta de manera concisa y precisa la información relevante de cada trabajo científico analizado. En esta tabla se incluye un pequeño resumen del contenido de los documentos, el algoritmo o técnica utilizada, las variables o parámetros específicos que se han considerado y el caso de aplicación en el que se ha desarrollado el estudio. Esta tabla es una herramienta valiosa para aquellos que buscan una visión general de los avances en el campo, y permite una fácil comparación entre los diferentes enfoques y resultados obtenidos en los distintos trabajos.

Cuadro 2.3: Tabla resumen

Titulo	Autores	Año	Resumen	Algoritmo	Variables, Parámetros	Caso de Aplicación
Continuous time predictive maintenance scheduling for a deteriorating system	L. Dieulle, C. Berenguer, A. Grall and M. Roussignol	2001	Se desarrolla un modelo matemático para el coste del sistema mantenido utilizando la teoría de los procesos de renovación. Los experimentos numéricos muestran que la tasa de coste de mantenimiento en un horizonte infinito puede minimizarse mediante una optimización conjunta del umbral de reposición y los tiempos de inspección aperiódica, y que la estructura de mantenimiento propuesta rinde más que las políticas clásicas de mantenimiento preventivo, que pueden tratarse como casos particulares.	Modelo matemático para el coste del sistema mantenido utilizando la teoría de los procesos de renovación	VARIABLES DE DECISIÓN DE MANTENIMIENTO: el umbral de sustitución preventiva y el programa de inspección basado en el estado del sistema.	
Predictive maintenance techniques	Bin Lu; David B. Durocher; Peter Stember	2009	Aquí se analiza la importancia del Mantenimiento Predictivo para las aplicaciones de procesos industriales e investiga tecnologías emergentes, como la evaluación de la eficiencia energética en línea y la supervisión continua del estado. También se discuten dos métodos para la detección de fallos en los rodamientos y la estimación de la eficiencia energética.	Algoritmo matemático. No específica	Velocidad, Ruido, Vibración, Desajustes	Industria Papelera. La planta de envasado de cartón de Weyerhaeuser en Manitowoc (Wisconsin, EE.UU.) supervisa tres motores de inducción críticos: un motor de soprador de 75 CV, un motor de bomba hidráulica de 50 CV y un motor de compresor de 200 CV.
A predictive maintenance policy with imperfect monitoring	GiuseppeCurcurùGiacomoG alanteAlbertoLombardo	2010	Adopta un modelo estocástico para el proceso de degradación e hipotetizando el uso de un sistema de monitorización imperfecto, el procedimiento actualiza, mediante un enfoque bayesiano, la información a-priori, utilizando los datos procedentes del sistema de monitorización.	Markovian degradation process		
A new paradigm of cloud-based predictive maintenance for intelligent manufacturing	Wang, J., Zhang, L., Duan, L.	2015	Se genera un nodo de detección y computación en la nube de bajo coste, un middleware de agente móvil y bibliotecas numéricas de código abierto. El intercambio de información y la interacción se logran mediante un agente móvil que distribuye los algoritmos de análisis al nodo de detección y computación en la nube para procesar localmente los datos y compartir los resultados del análisis. El "agente móvil" mejora la flexibilidad y adaptabilidad del sistema, reduce la transmisión de datos en bruto y responde instantáneamente a los cambios dinámicos de las operaciones y tareas.	Se seleccionan cinco características estadísticas, tres de frecuencia y los coeficientes del modelo autorregresivo de la envolvente de la corriente del motor para diagnosticar fallos motor. SVM(Support vector machine)	Se extraen 600 conjuntos de vectores de características correspondientes a seis motores diferentes. Cada vector consta de 23 características: 5 estadísticas, 3 dominio de la frecuencia y 15 coeficientes AR.	Se utilizan seis motores de inducción con diferentes modos de fallo en un sistema de prueba de motores para imitar los procesos de fabricación distribuidos.
Predictive Maintenance of Power Substation Equipment by Infrared Thermography Using a Machine-Learning Approach	Ullah I, Yang F, Khan R, Liu L, Yang H, Gao B, Sun K.	2017	Se aborda un mecanismo de prevención subestaciones eléctricas utilizando un enfoque de visión por ordenador aprovechando las imágenes térmicas infrarrojas, para prevenir problemas de contacto, cargas irregulares, grietas en el aislamiento, relés defectuosos, uniones de terminales y otros problemas similares, aumentan la temperatura interna de los instrumentos eléctricos.	Perceptrón multicapa (MLP) para clasificar las condiciones térmicas de los componentes de las subestaciones eléctricas en clases "defectuosas" y "no defectuosas". Las redes neuronales artificiales (ANN) se utilizan para la clasificación de un defecto en diferentes materiales.	150 imágenes térmicas de diferentes equipos eléctricos.	Subestaciones eléctricas
Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture	Cachada, Ana and Barbosa, Jose and Leitão, Paulo and Giraldo, Carla A.S. and Deusdado, Leonel and Costa, Jacinta and Teixeira, Carlos and Teixeira, João and Moreira, Antônio H.J. and Moreira, Pedro Miguel and Romero, Luis	2018	El artículo describe la arquitectura de un sistema de mantenimiento inteligente y predictivo, alineado con los principios de la Industria 4.0, que considera el análisis avanzado y en línea de los datos recogidos para la detección temprana de la ocurrencia de posibles fallos de la máquina, y apoya a los técnicos durante las intervenciones de mantenimiento proporcionando un soporte de decisión inteligente guiado.	Neural Networks, Bayesian Belief Network, Fuzzy Logic Prediction	Tipo de defecto, Día y hora, ID, Presión, Temperatura, Humedad, Vibraciones, Ruido Operacional	Máquina de prensado

2.7. La gestión de los datos

Con el avance de la Industria 4.0, la implantación del mantenimiento predictivo cambia en comparación con el clásico, sobre todo en el campo de la gestión de los datos, debido al exponencial incremento en el número de datos que se generan.

Los procesos de gestión de datos tienen como objetivo proporcionar un procedimiento estándar para el análisis de datos con el fin de evaluar y proponer una solución basada en los datos analizados.

Por supuesto, hay muchos procesos de datos disponibles, cada uno de los cuales se adapta a una necesidad de gestión de datos diferente. Destacamos algunos de los procesos de datos disponibles más importantes:

- El modelo de proceso Cross Industry Standard Process for data Mining (CRISP-DM).
- El modelo de proceso Sample, Explore, Modify, Model and Access (SEMMA).
- La metodología Team Data Science Process.

Todos estos métodos representan un enfoque novedoso en términos de técnicas de mantenimiento predictivo, convirtiéndose en el estándar en las técnicas de mantenimiento debido a la multitud de beneficios.

Con los nuevos avances tecnológicos y el movimiento de la Industria 4.0, las fábricas , las maquinarias empezaron a ser más avanzadas y más conectadas. Esto abrió el camino a la **monitorización de parámetros en tiempo real**, que es el pilar fundacional en el mantenimiento predictivo.

La rapidez y facilidad con la que ahora se adquieren y envían los datos es algo que hay que aprovechar. Con las nuevas innovaciones, como el Internet de las cosas y el Internet de los servicios, aparecen nuevos retos, siendo la gestión y el procesamiento de datos uno de ellos.

En los últimos años, la ciencia de datos ha acaparado mucha atención y ha dedicado grandes esfuerzos a desarrollar análisis sofisticados, mejorar los modelos de datos y cultivar nuevos algoritmos. Sin embargo, estos proyectos pueden enfrentarse a retos organizativos y sociotécnicos a medida que avanzan, como la falta de visión, estrategia y objetivos claros, un énfasis sesgado en cuestiones técnicas, la falta de reproducibilidad y la ambigüedad de roles, por nombrar algunos. Estos retos contribuyen a un bajo nivel de madurez en los proyectos de ciencia de datos que se gestionan al azar.

Dicho esto, las metodologías de gestión de proyectos y procesos son beneficiosas para los proyectos de ciencia de datos. Metodologías como éstas pueden ayudar a tener éxito y superar algunos de los problemas mencionados anteriormente. Por otro lado, a los equipos de ciencia de

datos puede resultarles difícil ceñirse a una metodología de proyecto. Los proyectos de ciencia de datos pueden planificarse utilizando muchas metodologías. Una de las metodologías más utilizada es CRISP-DM.

2.7.1. CRISP-DM

CRISP-DM son las siglas de Cross-Industry Standard Process for Data Mining, y fue creado a mediados de los años 90 por SPSS y Teradata. Describe enfoques comunes utilizados por los expertos en minería de datos. Se desglosa en 6 fases del ciclo de vida de un proyecto de minería de datos: comprensión del negocio, comprensión de datos, preparación de datos, modelado, evaluación y despliegue.

- Entendimiento del negocio - Esta es la primera etapa, y es aquí donde se definen los objetivos y necesidades del proyecto desde el punto de vista empresarial. Aquí es también donde se proyecta el plan del proyecto.
- Comprensión de los datos - Es fundamental analizar y familiarizarse con los datos una vez recopilados. El principal objetivo de esta fase es estudiar los datos y garantizar su calidad. Esta fase suele estar vinculada a la fase de comprensión del negocio, ya que es fundamental tener en cuenta la calidad y las características de los datos para garantizar que los objetivos del proyecto estén claramente definidos.
- Preparación de datos - El objetivo principal de esta fase es manejar los datos y crear el conjunto final de datos que se introducirá en el modelado. En este proceso se lleva a cabo la selección de características, la transformación de datos su la limpieza.
- Modelización - En esta fase se eligen y aplican las técnicas de modelización. Se divide el conjunto de datos, se generan los conjuntos de datos de prueba y de entrenamiento, y se construyen y aplican los modelos. Este paso también puede estar relacionado con la fase de preparación de los datos si es necesario realizar alguna transformación o selección para obtener mejores resultados.
- Evaluación: es la fase en la que se analizan y revisan los resultados del modelo para comprobar si se han alcanzado o no los objetivos definidos en la fase de comprensión del negocio.
- Despliegue: en esta fase del ciclo de vida, el modelo se organiza y se entrega al cliente.

El uso del aprendizaje automático en este tipo de problemas es una práctica muy extendida hoy en día.

A continuación, analizaremos algunos algoritmos de aprendizaje automático.

2.8. Aprendizaje automático

La cantidad de datos que se recopilan ha aumentado enormemente en los últimos años, lo que ha llevado a un auge en el uso de técnicas de aprendizaje automático. Este subcampo de la ciencia de datos es muy valioso porque permite obtener información relevante de los datos de una manera que sería casi imposible para una persona debido al tamaño de la información.

El auge de los sistemas de mantenimiento predictivo (**PdM**) se debe en gran medida a la creciente utilización de enfoques basados en datos, como el aprendizaje automático. Este tipo de tecnología ha revolucionado el mantenimiento, permitiendo predecir fallos en los equipos y otros sucesos relevantes durante su ciclo de vida.

Los enfoques de aprendizaje automático utilizados en los sistemas de **PdM** pueden variar dependiendo de los datos disponibles. Muchos artículos de investigación han abordado este tema. En el contexto del **PdM**, las metodologías de apoyo a las máquinas más importantes son la agrupación, la clasificación, la regresión y la detección de anomalías.

El aprendizaje automático puede dividirse en cuatro subcampos principales:

- Aprendizaje supervisado.
- Aprendizaje no supervisado.
- Aprendizaje semisupervisado.
- Aprendizaje por refuerzo.

2.9. Aprendizaje supervisado

En este subcampo del aprendizaje automático, el objetivo es predecir el resultado de una tarea basándose en las características de los datos. El modelo recibe un conjunto de características y una variable objetivo. Con esto, el modelo aprende la función que relaciona las características con la variable objetivo. El aprendizaje supervisado puede dividirse en dos tipos principales:

- Regresión: Encuentra un modelo de relación (función matemática) que relaciona un conjunto de variables numéricas o categóricas con una variable numérica.
- Clasificación: Encontrar un modelo de relación (función matemática) que relacione un conjunto de variables numéricas o categóricas con una variable categórica.

2.9.1. Modelos de aprendizaje supervisado

Muchos algoritmos de aprendizaje supervisado pueden utilizarse para resolver problemas de clasificación. Los más relevantes para este trabajo son las redes bayesianas, Naive Bayes (NB), Support Vector Machine (SVM), Decision Tree (DT), Random Forest, K-Nearest Neighbors (KNN), Artificial Neural Network (ANN). A continuación se describe cada algoritmo en su propia sección.

2.9.1.1. Redes bayesianas

Una red bayesiana es un modelo gráfico de relaciones de probabilidad entre un conjunto de variables. La red debe representarse. A continuación, se determinan los parámetros, lo que dificulta su aplicación sin la opinión de un experto. Las redes bayesianas tampoco tienen éxito con grandes conjuntos de datos porque las redes grandes no son viables en términos de tiempo y espacio.

2.9.1.2. Naive Bayes

Naive Bayes es un clasificador probabilístico basado en el teorema de Bayes. Se basa en la suposición ingenua de que cada par de características es independiente, lo que significa que cada característica es independiente de las demás para una clase determinada. Este método es sencillo, intuitivo y puede funcionar con gran eficacia.

2.9.1.3. Support vector machine

Las máquinas de vectores de soporte son algoritmos que utilizan una función kernel para transformar las características de los datos en un espacio de alta dimensión. El objetivo es encontrar un hiperplano que separe los datos en dos clases. El algoritmo se basa en la idea de que la distancia entre los puntos de datos y el hiperplano es el factor más crítico para determinar la clase del punto de datos.

2.9.1.4. Decision trees and random forest

Los árboles de decisión son un algoritmo muy utilizado para problemas de clasificación. Son fáciles de entender y explicar una vez que muestra la decisión de dividir los datos. Este algoritmo es robusto frente al ruido de los datos. También proporciona un alto rendimiento para un tiempo de cálculo relativamente rápido. Un problema es que le resulta difícil manejar conjuntos de datos de alta dimensión. Otro problema es que sin el uso adecuado de la poda puede llevar fácilmente a un sobreajuste. Para resolver este problema, se utilizan los bosques

aleatorios. Un bosque aleatorio es una colección de árboles de decisión entrenados utilizando una muestra bootstrap de los datos originales. El objetivo es encontrar un conjunto de árboles de decisión que sean más robustos al ruido de los datos.

2.9.1.5. Vecinos más próximos (K-Nearest Neighbors)

K-Nearest Neighbors (KNN) es un método no paramétrico de clasificación. Es un algoritmo sencillo que puede utilizarse para encontrar los vecinos más cercanos de un punto dado en un conjunto de datos. El objetivo es encontrar la clase de los vecinos más cercanos. Se trata de un algoritmo simple de aprendizaje perezoso cuya eficacia depende en gran medida del valor del parámetro k y del tamaño de los datos.

2.9.2. Red neuronal artificial

Las redes neuronales artificiales (RNA) son una interconexión entre modelos computacionales y una estructura en capas. Esta red consta de nodos (neuronas artificiales), conexiones ponderadas y funcionalidad. La idea de las RNA es parametrizar una estructura de forma repetitiva para ajustar los parámetros durante el entrenamiento. Las neuronas están dispuestas en capas, y cada una de ellas está asociada a 2 variables, un conjunto de pesos y un sesgo. Las RNA pueden dividirse en 3 fases: entrada, procesamiento y salida. Cuanto mayor es la fase de procesamiento, más profunda es la red neuronal.

2.9.3. Problemas de datos desequilibrados

Los conjuntos de datos desequilibrados son un problema común en el aprendizaje automático. Es frecuente encontrar problemas con conjuntos de datos desequilibrados en el mundo real. Por ejemplo, en la detección de fallos hay una gran diferencia entre el número de puntos de datos con fallos y sin fallos. Esto puede suponer un problema a la hora de entrenar un modelo de detección de fallos, ya que los algoritmos no funcionan bien porque suelen estar diseñados para manejar conjuntos de datos equilibrados. Una de las soluciones más comunes para tratar este tipo de problema es utilizar técnicas de remuestreo.

2.9.4. Overfitting y Underfitting

El overfitting y el underfitting son dos problemas frecuentes en los algoritmos de aprendizaje automático. El sobreajuste(overfitting) se produce cuando el algoritmo se ajusta a los datos de entrenamiento y memoriza su ruido. Esto conduce a un deterioro de la generalización de las propiedades del modelo, lo que se traduce en un bajo rendimiento cuando se aplica a los datos de

prueba. Los conjuntos de datos con tamaños pequeños son más propensos al sobreajuste que los conjuntos de datos con tamaños grandes, aunque puede ocurrir en conjuntos de datos grandes debido a la complejidad de los datos. Por otro lado, el infraajuste se produce cuando el algoritmo no puede detectar la variabilidad de los datos. Esto conduce a un rendimiento deficiente tanto en los datos de entrenamiento como en los de prueba. Para solucionar el overfitting y el underfitting, se pueden utilizar varias técnicas. Algunas de ellas son:

- Validación cruzada: Esta técnica divide los datos en uno o varios conjuntos de entrenamiento y de prueba. El objetivo es entrenar el modelo sólo con el conjunto de entrenamiento original.
- Regularización: es una técnica que penaliza el modelo para evitar el sobreajuste. También puede ser un hiperparámetro que puede ajustarse en función del algoritmo utilizado.
- Selección de características: es una técnica que selecciona las características más relevantes de los datos.
- Detención temprana: es una técnica que detiene el proceso de entrenamiento cuando el modelo no mejora.
- Entrenar con más datos: entrenar con más datos puede ser útil para que los algoritmos detecten mejor la señal. El problema es que si los datos añadidos añaden ruido, esta técnica no es útil.

Las técnicas relevantes para este trabajo son la selección de características y el entrenamiento con más datos.

2.9.5. Métricas más comunes para la clasificación

Es crucial evaluar el rendimiento del modelo para saber si tiene un buen rendimiento y validarla. Se pueden utilizar muchas métricas para evaluar el rendimiento del modelo. Detallamos las métricas más comunes.

2.9.5.1. Precisión

La precisión es el porcentaje de predicciones correctas o la capacidad de un modelo para predecir correctamente los patrones convencionalmente considerados positivos. Es la métrica más utilizada en el aprendizaje automático. Se calcula dividiendo el número de predicciones correctas por el número total de predicciones. La precisión es una buena métrica si los datos están equilibrados. De lo contrario, puede dar una falsa sensación de alcanzar un alto rendimiento. Donde:

- TP: verdadero positivo
- TN: verdadero negativo
- FP: falso positivo
- FN: falso negativo

Se calcula dividiendo el número de patrones positivos predichos correctamente por el número total de patrones positivos predichos. En otras palabras, se divide el número de verdaderos positivos por la suma de verdaderos positivos y falsos positivos.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.1)$$

2.9.5.2. Recuperación

La recuperación mide cuántos patrones positivos se clasifican correctamente. Se puede calcular dividiendo el número de verdaderos positivos entre la suma de verdaderos positivos y verdaderos negativos.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.2)$$

2.9.5.3. ROC AUC

La área bajo la curva (AUC) es una medida muy utilizada para evaluar el rendimiento de un clasificador binario. Esta métrica proporciona una visión general del rendimiento del clasificador. La AUC ROC es una curva de probabilidad que muestra la tasa de verdaderos positivos frente a la tasa de falsos positivos.

$$TFP = \frac{FP}{TN + FP} \quad (2.3)$$

2.9.5.4. F1 Score

La F1 Score es una medida que combina la precisión y la recuperación en una sola métrica. Se calcula como la media armónica de estas dos medidas. Esta métrica puede ser útil para evaluar el desempeño y la fiabilidad del modelo, ya que busca encontrar un equilibrio entre la precisión y la recuperación.

$$F1 = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.4)$$

2.9.5.5. Matriz de confusión

La matriz de confusión es una herramienta comúnmente utilizada para evaluar el rendimiento de un modelo en problemas de clasificación binaria. Una de las métricas derivadas de la matriz de confusión que se suele utilizar es la precisión. Sin embargo, esta métrica puede no ser apropiada cuando los datos están desequilibrados, es decir, cuando una de las clases es mucho más frecuente que la otra. En este caso, la clase mayoritaria puede tener un mayor impacto en el rendimiento del modelo, lo que puede dar lugar a una alta precisión pero un mal rendimiento con la clase minoritaria.

Cuando se trata de conjuntos de datos desequilibrados, se pueden utilizar algunas métricas para evaluar el rendimiento del modelo. Algunas de las métricas que pueden ser útiles son la F1 Score, que es una medida promedio ponderada de precisión y recuperación, y el AUC ROC, que es el área bajo la curva ROC. Estas dos medidas no están sesgadas, ni hacia las clases mayoritarias ni hacia las minoritarias.

2.10. Aprendizaje no supervisado

El aprendizaje no supervisado se centra en buscar patrones y relaciones entre las características de los datos de entrada, por lo que se basa principalmente en el uso de datos no etiquetados. Estos métodos pueden ser útiles para descubrir patrones previamente desconocidos en un conjunto de datos.

Los usos más comunes del aprendizaje no supervisado son:

- Clustering: un enfoque para encontrar patrones similares y relaciones entre características en el conjunto de datos, agrupando los puntos de datos con características comunes.
- Reglas de asociación: como su nombre indica, son simples reglas de asociación que ayudan a descubrir relaciones entre conjuntos de datos aparentemente independientes. Este enfoque se utiliza con grandes conjuntos de datos transaccionales. Más concretamente, en estudios de cestas de mercado para analizar los hábitos de compra de los clientes.
- Reducción de la dimensionalidad: es el proceso de proyectar conjuntos de datos de alta dimensión a un espacio de menor dimensión. Uno de los métodos más utilizados es el Análisis de Componentes Principales (PCA).

Seguidamente presentaremos una visión general de algunos de sus algoritmos.

2.10.1. Algoritmos de clustering

Debido al aumento de los datos y de la potencia de cálculo, se desarrollan constantemente nuevos algoritmos para responder a las necesidades de las empresas. Con este aumento, es esencial estructurar una taxonomía para catalogar los diferentes algoritmos. El enfoque más utilizado en la literatura es distinguir entre algoritmos de clustering, jerárquicos, basados en partición, basados en densidad, basados en malla y basados en modelos. Los algoritmos basados en la partición dividen los datos en un conjunto de k conglomerados y, a continuación, asignan cada punto de datos al conglomerado más cercano.

Algunos ejemplos de algoritmos basados en particiones son k-means, k-medoids, fuzzy c-means

Los algoritmos jerárquicos organizan los datos en forma de árbol. La raíz del árbol es el primer clúster, y las hojas son los clústeres más cercanos a la raíz. Algunos ejemplos de algoritmos jerárquicos son BIRCH, CURE, ROCK.

Los algoritmos basados en la densidad se utilizan para encontrar clusters en los datos cercanos entre sí en regiones de alta densidad. Algunos ejemplos de algoritmos basados en la densidad son DBSCAN, OPTICS y Mean-Shift.

En los algoritmos basados en rejilla, los datos se dividen en una estructura de rejilla definida. Cuantifica las áreas de los objetos en un número finito de celdas que forman una estructura de rejilla en la que se implementan todas las operaciones para la agrupación. La ventaja del método es su rápido tiempo de procesamiento, que suele ser independiente del número de objetos de datos, y sigue dependiendo únicamente de las múltiples celdas de cada dimensión en el espacio cuantificado. Algunos ejemplos de algoritmos basados en cuadrículas son WaveCluster, STING, CLIQUE.

Por último, los algoritmos basados en modelos pretenden optimizar el ajuste entre la base de datos dada y un modelo concreto para cada conglomerado. Algunos ejemplos de algoritmos basados en modelos son EM, COBWEB, SOM.

2.10.2. Clases de algoritmos

2.10.2.1. K-Means

K-means es un algoritmo basado en la partición que divide los datos en k clusters diferentes. Inicializando k centroides diferentes, el algoritmo asigna cada punto de datos al cluster más cercano. A continuación, el algoritmo vuelve a calcular los centroides de cada clúster y repite el proceso hasta que los centroides no cambian. El algoritmo es rápido y puede utilizarse para encontrar patrones en los datos.

2.10.2.2. DBSCAN

DBSCAN es un algoritmo basado en la densidad que encuentra clusters en los datos que están muy juntos y marca los valores atípicos que no están cerca de ninguna región. El algoritmo es sencillo y rápido y puede utilizarse para encontrar patrones en los datos.

2.10.3. Métricas para el aprendizaje no supervisado

Después de utilizar los algoritmos de clustering, es esencial evaluar el rendimiento del algoritmo. Varios aspectos son cruciales a considerar cuando se evalúa el rendimiento del clustering. Estos aspectos son:

- Las tendencias de clustering en los datos.
- El número correcto de conglomerados.
- La calidad de los clusters sin información externa.
- La comparación de los resultados con información externa.

Por lo tanto, existen dos tipos de validaciones para los algoritmos de clustering, la validación interna y la validación externa.

La validación interna es la evaluación del rendimiento del algoritmo sin información externa, utilizando únicamente la información proporcionada por los datos de entrada. Existen dos tipos de métricas: medidas de cohesión y de separación. La cohesión evalúa la proximidad entre los elementos de un mismo cluster, mientras que las medidas de separación cuantifican el nivel de separación entre clusters.

Algunos ejemplos de métricas que miden la separación y la cohesión al mismo tiempo:

- El coeficiente Calisnki-Harabasz: también conocido como criterio de relación de varianza, se basa en la dispersión interna y la dispersión entre clusters.
- La puntuación Xie-Beni: esta métrica se diseñó para la agrupación difusa. Sin embargo, puede aplicarse al clustering duro. Es un cociente que divide el nivel de compactación de los datos dentro de un mismo cluster y la separación de los datos de clusters diferentes.
- El índice Ball-Hall: El índice de Ball-Hall: se basa en las distancias cuadráticas entre los puntos del cluster y el centroide del cluster.
- Coeficiente de silueta: es la medida más común que combina cohesión y separación.

Esta medida se define en el intervalo $[-1, 1]$ para cada punto de datos. En caso de valor positivo, se experimenta una gran separación entre clusters. En cambio, si es negativo, los clusters están mezclados. Por último, si es cero, indica que el conjunto de datos está uniformemente distribuido en el espacio euclídeo. La validación externa es la evaluación del rendimiento del algoritmo con información externa. Los métodos de validación externa se dividen en 3 grandes grupos, que son: conjuntos coincidentes, correlación entre pares y teoría de la información. Los métodos de conjuntos coincidentes comparan los clusters detectados con la correspondencia natural. Algunos ejemplos de métodos de conjuntos coincidentes son:

- Precisión: mide los verdaderos positivos, es decir, el número de puntos de datos clasificados adecuadamente dentro del mismo cluster.
- Recall: mide el porcentaje de elementos que se incluyen adecuadamente en el mismo clúster.
- F1 Score: combinación de precisión y recuperación.
- Pureza: mide si cada clúster contiene sólo muestras de la misma clase.

La correlación entre pares mide la similitud entre dos particiones en condiciones similares, como un proceso de agrupación para el mismo conjunto. Se supone que los ejemplos de un mismo cluster deben pertenecer a la misma clase y viceversa. Algunos ejemplos de métodos de correlación entre iguales son:

- Coeficiente de Jaccard: evalúa la similitud de un cluster detectado con una partición proporcionada.
- Coeficiente de Rand: es el equivalente a la precisión en un enfoque de aprendizaje supervisado.
- Coeficiente de Folkes y Mallows: calcula la similitud entre los clusters encontrados por el algoritmo con respecto a los marcadores independientes.

Por último, los métodos de teoría de la información se basan en conceptos de la Teoría de la Información, como la incertidumbre actual en la predicción de las clases naturales proporcionadas por otras particiones. Algunos ejemplos de métodos de la Teoría de la Información son

- Entropía: una medida recíproca de pureza que mide el grado de desorden en la agrupación.
- Información mutua: una métrica que mide la reducción de la incertidumbre sobre los resultados de la agrupación los resultados de la agrupación a partir de un conocimiento previo.

2.11. Aprendizaje semisupervisado

El aprendizaje semisupervisado es una rama del aprendizaje automático que combina técnicas de aprendizaje supervisado y no supervisado. Esta metodología utiliza tanto datos etiquetados como no etiquetados para entrenar el modelo. Normalmente, se utiliza para ayudar a mejorar el rendimiento en uno de esos tipos de tareas de aprendizaje mediante el uso de métodos que pertenecen a la otra tarea de aprendizaje. La mayor parte del uso del aprendizaje semisupervisado se centra en la clasificación. Para situaciones con datos etiquetados limitados, los enfoques de clasificación semisupervisada son útiles porque las técnicas de aprendizaje supervisado son insuficientes para resolver el problema y no son fiables. Esto es posible porque los datos etiquetados pueden ser caros o difíciles de recopilar. Si los datos no etiquetados son suficientes en esas circunstancias, pueden mejorar el rendimiento del modelo.

El aprendizaje semisupervisado se basa en tres supuestos principales:

- Suposición de suavidad: Según este supuesto, si dos puntos de entrada en el espacio de entrada están próximos entre sí, lo más probable es que pertenezcan a la misma clase. Este supuesto también es común en el aprendizaje supervisado, pero la ventaja del aprendizaje semisupervisado es que puede manejar datos no etiquetados.
- Suposición de baja densidad: Según este supuesto, la frontera de decisión debe atravesar zonas de baja densidad en lugar de zonas de alta densidad. La hipótesis de suavidad está estrechamente relacionada con esta hipótesis.
- Hipótesis múltiple: La hipótesis de los colectores afirma que el espacio de entrada está formado por colectores de dimensiones inferiores en los que se encuentran todos los puntos de datos y que los puntos de datos de un mismo colector pertenecen a la misma clase.

2.11.1. Métodos inductivos

Los métodos inductivos son aquellos que buscan construir un modelo que pueda hacer predicciones para cualquier tipo de datos disponibles en el espacio de entrada. Estos métodos son una ampliación de los métodos de aprendizaje supervisado que incluyen tanto datos etiquetados como no etiquetados.

2.11.2. Métodos envolventes

Los métodos envolventes utilizan técnicas de aprendizaje supervisado para entrenar clasificadores en datos previamente etiquetados, y luego producen más datos etiquetados utilizando las predicciones del modelo. Una vez que se han generado estos datos etiquetados adicionales,

se vuelve a entrenar al clasificador utilizando tanto los datos previamente etiquetados como los nuevos datos etiquetados. De esta manera, el enfoque envolvente convierte los datos no etiquetados en datos etiquetados, y luego se utilizan para construir el modelo final mediante un algoritmo de aprendizaje puramente supervisado.

Los enfoques envolventes incluyen los siguientes, que son los más conocidos:

- El autoentrenamiento es el método de pseudoetiquetado más sencillo. Estos métodos utilizan un clasificador supervisado para entrenar iterativamente sobre datos etiquetados y pseudo-etiquetados hasta que no se clasifican más datos.
- Co-entrenamiento: una extensión del autoentrenamiento en la que se utilizan dos o más clasificadores supervisados en lugar de uno solo. Para que esto funcione, los clasificadores supervisados no deben estar demasiado conectados en sus predicciones. En este caso, la cantidad de datos nuevos generados será limitada.
- Refuerzo: Un conjunto de clasificadores se construye creando sucesivamente clasificadores individuales, de forma similar a los algoritmos de refuerzo estándar.

2.11.3. Preprocesamiento no supervisado

El preprocesamiento no supervisado utiliza los datos etiquetados y no etiquetados en dos etapas diferentes, a diferencia de los métodos envolventes. Normalmente, los datos no etiquetados se procesan primero en la etapa no supervisada para extraer características, agrupar los datos para etiquetarlos después o preentrenar un aprendiz basado e inicializarlo con los pesos adecuados. El siguiente proceso es la aplicación de un algoritmo de aprendizaje supervisado.

Las técnicas utilizadas en esta etapa son:

- Extracción de características: Se trata de una técnica ventajosa que ha desempeñado un papel esencial en la construcción de clasificadores. Esta técnica encuentra transformaciones en los datos de entrada que pueden mejorar el rendimiento o la eficiencia del clasificador.
- Cluster-then-label: Como su nombre indica, este enfoque une los procesos de agrupación y clasificación. En primer lugar, se agrupan todos los datos disponibles y, a continuación, los grupos resultantes se utilizan para guiar el proceso de clasificación.
- Pre-entrenamiento: El preentrenamiento es una técnica muy utilizada actualmente en el aprendizaje profundo. Los datos no etiquetados sugieren el límite hacia regiones potencialmente interesantes antes de aplicar el algoritmo supervisado.

2.11.4. Métodos intrínsecamente semisupervisados

Los métodos intrínsecamente semisupervisados son aquellos que pueden funcionar tanto con datos etiquetados (supervisados) como con datos sin etiquetar (no supervisados). Estos métodos son capaces de aprender de los datos sin necesidad de una etiqueta o clase predefinida para cada ejemplo de datos.

Los métodos utilizados en esta etapa son:

- Máximo-margen: Es un enfoque que busca maximizar la distancia entre dos clases de datos al mismo tiempo que se minimiza el error de clasificación. Es el método más directo e intenta maximizar la distancia entre los puntos de datos de entrada y la frontera de decisión. Esta técnica corresponde a la hipótesis de baja densidad semisupervisada.
- Métodos basados en la perturbación: consiste en añadir ruido o perturbaciones a los datos no etiquetados para generar múltiples conjuntos de datos modificados que se pueden utilizar para entrenar un modelo. Esta técnica se basa en el supuesto de suavidad. El modelo de predicción debe ser robusto a las perturbaciones locales en el espacio de entrada, lo que significa que cuando un punto de datos es perturbado por una pequeña cantidad de ruido, la predicción para los datos ruidosos y los datos limpios debe ser similar. Estos métodos suelen aplicarse con redes neuronales.
- Métodos mainfold: es un enfoque que busca preservar la estructura de los datos al proyectarlos a un espacio de menor dimensión. Como se ha visto antes con los métodos basados en perturbaciones, añadir pequeñas perturbaciones al espacio de entrada funciona bien bajo el supuesto de suavidad. Sin embargo, en algunos conjuntos de datos de baja dimensión, las perturbaciones pueden diferir de los datos de entrada. Por este motivo, aquí se utiliza el supuesto de la multiplicidad.
- Modelos generativos: son modelos que intentan generar nuevos ejemplos de datos a partir de una distribución de datos conocida.

Todos los métodos anteriores son discriminativos. Su único objetivo es suponer una función que pueda clasificar los puntos de datos. En cambio, el objetivo de los modelos generativos es modelar la distribución $p(x, y)$, de la que se pueden extraer muestras (x, y) .

2.11.5. Métodos transductivos

A diferencia de los métodos inductivos, que producen un modelo que puede clasificar cualquier punto de datos en el espacio de entrada, las técnicas transductivas no tienen en cuenta la

distinción entre el conjunto de entrenamiento y el de prueba. Se proporcionan tanto datos etiquetados como no etiquetados como entrada, y la salida consiste exclusivamente en predicciones para los datos no etiquetados.

Estos métodos a menudo se definen mediante un grafo que conecta todos los puntos de datos y codifica las relaciones entre ellos a través de aristas que pueden estar ponderadas. Se define y optimiza una función objetivo que asegura que las etiquetas predichas coincidan con las etiquetas reales de los datos etiquetados, y que los puntos de datos similares, según el grafo de similitud, tengan las mismas predicciones de etiquetas. Hay una cierta similitud entre los métodos transductivos e inductivos, ya que ambos construyen un grafo sobre los puntos de datos y utilizan relaciones entre pares para aproximar estructuras más complejas.

La principal diferencia es que los métodos inductivos tratan de crear un modelo capaz de clasificar cualquier punto de datos en el espacio de entrada, mientras que los métodos transductivos solo dan predicciones para un conjunto de datos específico sin etiquetar.

Capítulo 3

Diseño e Implementación

En esta sección, se describirá el software y hardware utilizado así como una descripción del dataset, para finalizar detallando el proceso de desarrollo del proyecto.

Tras ello, se realizará un análisis exhaustivo del conjunto de datos que se ha obtenido para el proyecto. Durante este análisis, se examinarán las diferentes características de los datos y se discutirá su relevancia y importancia para el desarrollo del modelo que se está construyendo.

Una vez que hayamos superado este obstáculo y hayamos desarrollado una forma eficiente de clasificar los datos, se presentarán los resultados de la clasificación obtenidos. Se detallará cómo se han dividido los datos en diferentes categorías y se analizará la precisión y eficacia del modelo utilizado.

Comenzamos:

3.1. Requerimientos técnicos

En este trabajo final de máster, se han utilizado una serie de herramientas de software y hardware para llevar a cabo el análisis y la visualización de los datos. En cuanto al hardware, se ha utilizado un portatil equipada con un procesador de alta potencia y suficiente memoria RAM para manejar el procesamiento de grandes cantidades de datos.

Detallamos las herramientas de Software y Hardware utilizados.

3.2. Software

En lo que respecta al software, y bajo el paraguas de Linux y utilizando VSCode se ha trabajado con Python y librerías y paquetes especializados en el análisis de datos y la ciencia de datos, como Pandas, NumPy, Matplotlib y Scikit-Learn. Además, se han utilizado diversas herramientas de visualización de datos, como Plotly, para crear gráficos y visualizaciones

atractivas y fáciles de interpretar. Detallamos las herramientas utilizadas.

3.2.1. Sistema Operativo: Linux

Linux es un sistema operativo basado en el kernel del sistema operativo Unix. Es un sistema operativo de código abierto, lo que significa que el código fuente está disponible para cualquier persona para examinar, modificar y mejorar. Linux es conocido por ser un sistema operativo seguro, estable y altamente configurable.

Las razones de elegir Linux para el análisis de datos y la ciencia de datos son:

- Libre: Linux es un sistema operativo libre y de código abierto, .
- Estabilidad: Linux es conocido por ser un sistema operativo estable y fiable.
- Herramientas de análisis de datos: Linux viene con una gran cantidad de herramientas de análisis de datos y ciencia de datos preinstaladas, como R, Python y Julia.
- Comunidad: Linux tiene una gran comunidad de usuarios y desarrolladores que contribuyen al sistema operativo y crean paquetes de software adicionales.

Ubuntu Ubuntu es una distribución de Linux, lo que significa que es una versión específica del sistema operativo Linux que viene con un conjunto particular de programas y herramientas. Ubuntu fue creado con el objetivo de ser fácil de usar y está diseñado para ser intuitivo para usuarios que no son expertos en informática.

3.2.2. IDE

Un IDE (Integrated Development Environment, o Entorno de Desarrollo Integrado en español) es un software que proporciona a los desarrolladores un entorno de trabajo completo para crear aplicaciones de software. Un IDE normalmente incluye un editor de código, un depurador y herramientas de construcción. Son muy útiles para los desarrolladores ya que facilitan y agilizan el proceso de creación de software. Al tener todas las herramientas necesarias en un mismo entorno, los desarrolladores pueden trabajar de manera más eficiente y tener un mayor control sobre el código que están creando. Características:

- Sintaxis de destacado: resaltado de diferentes elementos del código para hacerlo más legible.
- Autocompletado: sugerencia de código mientras se escribe.

- Depuración: herramientas para encontrar y solucionar errores en el código.
- Consola: una consola integrada para ejecutar código y ver los resultados.
- Control de versiones: herramientas para trabajar con repositorios de código y controlar los cambios realizados.

VSCode Visual Studio Code (también conocido como Visual Studio Code o simplemente VS Code) es un editor de código fuente y un entorno de desarrollo integrado (IDE) desarrollado por Microsoft para Windows, Linux y macOS. Es gratuito y de código abierto, y está diseñado para ser una herramienta ligera y fácil de usar para desarrolladores de todos los niveles.

VS Code incluye una amplia gama de características para facilitar el desarrollo de software, como:

- Sintaxis de destacado: resaltado de diferentes elementos del código para hacerlo más legible.
- Autocompletado: sugerencia de código mientras se escribe.
- Depuración: herramientas para encontrar y solucionar errores en el código.
- Integración con control de versiones: soporte para Git y otras herramientas de control de versiones.
- Extensiones: miles de extensiones disponibles para añadir funcionalidades adicionales al editor.

3.2.3. Lenguajes de Programación

Un lenguaje de programación es un lenguaje que se utiliza para escribir y ejecutar programas de computadora. Un programa de computadora es un conjunto de instrucciones que le dice a la computadora qué hacer. Los lenguajes de programación se utilizan para crear todo tipo de aplicaciones, desde juegos hasta programas de análisis de datos.

PYTHON, HTML, CSS Los lenguajes utilizados son:

- Python es un lenguaje de programación de alto nivel y orientado a objetos que se utiliza ampliamente en el análisis de datos, la ciencia de datos, el aprendizaje automático y el desarrollo de aplicaciones web. Es conocido por su sintaxis clara y fácil de leer, lo que lo hace ideal para principiantes y programadores experimentados.

- HTML (HyperText Markup Language) es un lenguaje de marcado utilizado para estructurar y dar formato a documentos web. Es el lenguaje principal utilizado para crear páginas web y se utiliza junto con CSS (Cascading Style Sheets) para dar estilo y diseño a las páginas.
- CSS es un lenguaje de diseño utilizado para dar estilo y diseño a las páginas web. Se utiliza junto con HTML para definir cómo se deben mostrar los elementos en una página web, como los colores, fuentes, márgenes y posicionamiento.

3.2.4. Control de versiones

Un control de versiones es un sistema que registra los cambios realizados en un archivo o conjunto de archivos a lo largo del tiempo, de manera que pueda recuperar versiones específicas más adelante. Los sistemas de control de versiones son muy útiles para el desarrollo de software, ya que permiten a los desarrolladores revertir fácilmente los cambios si algo sale mal o comparar versiones del código para ver qué ha cambiado. Algunos ejemplos populares incluyen Git, Subversion y Mercurial.

Github GitHub es una plataforma en línea que ofrece alojamiento de repositorios de código y herramientas para el control de versiones. Se basa en el sistema de control de versiones Git, que permite a los desarrolladores controlar y gestionar los cambios en el código de un proyecto de software.

3.2.5. Cloud

Un sistema cloud para ciencia de datos es un servicio en línea que proporciona a los usuarios acceso a una plataforma de análisis de datos en la nube. Los usuarios pueden subir sus datos al sistema cloud, procesarlos y analizarlos utilizando diversas herramientas y lenguajes de programación, y luego guardar los resultados en la nube.

Ejemplos de sistemas cloud para ciencia de datos incluyen AWS (Amazon Web Services), Azure (de Microsoft) y Google Cloud Platform.

AWS Amazon Web Services (AWS) es una plataforma en la nube que ofrece una amplia gama de servicios para el desarrollo de aplicaciones, incluyendo servidores virtuales. Una de las opciones disponibles para el despliegue de este proyecto Django en AWS es utilizar EC2 (Amazon Elastic Compute Cloud), que es un servicio de Amazon que proporciona servidores virtuales a través de la nube.

3.2.6. Navegador web

Un navegador web es una aplicación que se utiliza para acceder a Internet y ver páginas web.

Brave Brave es el navegador rutilizado y enfocado en la privacidad y la seguridad de los usuarios y bloquea automáticamente los anuncios y el seguimiento de terceros. Brave también tiene una función de privacidad integrada que permite a los usuarios navegar de manera anónima y proteger su privacidad en línea. Está basado en Chromium y es compatible con todas las páginas web estándar y admite extensiones de Chrome y Firefox.

3.2.7. Latex

LaTeX es un lenguaje de marcado de documentos utilizado principalmente en el campo de la ciencia y la tecnología. Se utiliza para crear documentos profesionales de alta calidad, como artículos científicos, libros y presentaciones. Es utilizado ampliamente en la comunidad científica y académica debido a su soporte para la notación matemática y formato de alta calidad.

Ventajas:

- Produce documentos de alta calidad.
- Facilita la colaboración.
- Permite la creación de documentos largos y complejos.
- Formatea automáticamente los elementos del documento.
- Mejora la legibilidad del código.

Inconvenientes:

- Aprendizaje curva: LaTeX tiene una sintaxis especial y puede llevar un tiempo aprender a utilizarlo de manera efectiva.
- No es tan intuitivo como otros procesadores de texto.
- Está diseñado especialmente para la creación de documentos científicos y técnicos y puede ser menos adecuado para otros tipos de documentos.
- Puede ser más lento que otros procesadores de texto.

Overleaf Overleaf es una plataforma en línea que permite a los usuarios crear y colaborar en documentos LaTeX en tiempo real. La plataforma ofrece un editor LaTeX en línea y una interfaz de usuario amigable que hace que sea fácil de usar para personas sin experiencia previa en LaTeX.

3.3. Hardware

Para realizar el trabajo final (TFM), se utilizaron diversas herramientas de hardware para almacenar y procesar los datos. Esto incluyó servidores en la nube, computadoras de escritorio y dispositivos móviles. Los servidores en la nube se utilizaron para almacenar y procesar grandes cantidades de datos, mientras que las computadoras de escritorio y dispositivos móviles se utilizaron para acceder a los datos y realizar análisis y visualizaciones. Además, se utilizaron diversas herramientas de hardware para la captura y el procesamiento de datos, como sensores y dispositivos de medición. Estas herramientas de hardware fueron esenciales para poder realizar el TFM de manera eficiente y obtener resultados precisos y confiables.

Cuadro 3.1: Especificaciones Hardware I/II

Clase	Descripción
system	ROG Strix G713IC_G713IC
bus	G713IC
memory	64KiB BIOS
memory	16GiB Memoria de sistema
memory	8GiB SODIMM DDR4 Síncrono Unbuffered 3200 MHz (0,3 ns)
memory	8GiB SODIMM DDR4 Síncrono Unbuffered 3200 MHz (0,3 ns)
memory	512KiB L1 caché
memory	4MiB L2 caché
memory	8MiB L3 caché
processor	AMD Ryzen 7 4800H with Radeon Graphics
bridge	Renoir/Cezanne Root Complex
generic	Renoir/Cezanne IOMMU
bridge	Renoir PCIe GPP Bridge
display	GA107M [GeForce RTX 3050 Mobile]
multimedia	NVIDIA Corporation
bridge	Renoir/Cezanne PCIe GPP Bridge
network	RTL8111/8168/8411 PCI Express Gigabit Ethernet Controller
bridge	Renoir/Cezanne PCIe GPP Bridge
network	MT7921 802.11ax PCI Express Wireless Network Adapter
bridge	Renoir/Cezanne PCIe GPP Bridge
storage	SAMSUNG MZVLQ1T0HBLB-00B00

Cuadro 3.2: Especificaciones Hardware II/II

Clase	Descripción
disk	NVMe disk
disk	NVMe disk
disk	1024GB NVMe disk
volume	99MiB Windows FAT volumen
volume	15MiB reserved partition
volume	482GiB Windows NTFS volumen
volume	616MiB Windows NTFS volumen
volume	470GiB partición EXT4
bridge	Renoir Internal PCIe GPP Bridge to Bus
display	Renoir
multimedia	Renoir Radeon High Definition Audio Controller
input	HD-Audio Generic HDMI/DP,pcm=3
generic	Family 17h (Models 10h-1fh) Platform Security Processor
bus	Renoir/Cezanne USB 3.1
bus	xHCI Host Controller
input	Asus Keyboard
bus	xHCI Host Controller
bus	Renoir/Cezanne USB 3.1
bus	xHCI Host Controller
input	USB OPTICAL MOUSE Keyboard
communication	Wireless_Device
bus	xHCI Host Controller
multimedia	Raven/Raven2/FireFlight/Renoir Audio Processor
multimedia	Family 17h (Models 10h-1fh) HD Audio Controller
input	HD-Audio Generic Headphone
bus	FCH SMBus Controller
bridge	FCH LPC Bridge
system	PnP device PNP0c01
system	PnP device PNP0b00
generic	PnP device ATK3001
system	PnP device PNP0c02
input	Lid Switch
input	Power Button
input	Asus Wireless Radio Control
input	Asus WMI hotkeys
input	Sleep Button
input	ASUE120A:00 04F3:319B Mouse
input	ASUE120A:00 04F3:319B Touchpad
input	Video Bus

3.4. Contexto y dataset

El conjunto de datos fue creado por el Laboratorio Nacional de Energías Renovables (NREL) como parte de un proyecto de investigación sobre sistemas de bombeo de agua.

El National Renewable Energy Laboratory (NREL) es un laboratorio de investigación financiado por el Departamento de Energía de Estados Unidos. El NREL se creó en 1974 con el nombre de Instituto de Investigación de la Energía Solar, y pasó a denominarse Laboratorio Nacional de Energías Renovables en 1977. Está situado en Golden, Colorado, y se centra en la investigación y el desarrollo de energías renovables y tecnologías de eficiencia energética.

El NREL es:

- Un laboratorio de investigación líder en el campo de las energías renovables y la eficiencia energética, y se dedica a impulsar el uso de tecnologías energéticas limpias y sostenibles. Investiga una amplia gama de tecnologías de energías renovables, como la solar, la eólica, la geotérmica y la bioenergía.
- Cuenta con varias instalaciones de investigación, así como varios bancos de pruebas y proyectos piloto.
- Colabora estrechamente con la industria, el mundo académico y otras organizaciones de investigación para impulsar el desarrollo y la implantación de tecnologías de energías renovables.

Como parte de sus actividades de investigación, el NREL ha realizado varios estudios sobre sistemas de bombeo de agua, incluida la recogida de datos de 52 sensores en un sistema de bombeo de agua.

Estos datos se recogieron como parte de un proyecto de investigación sobre sistemas de bombeo de agua, y el objetivo era recopilar datos que pudieran utilizarse para optimizar el diseño y el funcionamiento de los sistemas de bombeo de agua.

Los datos recopilados por el NREL se han puesto a disposición a través del conjunto de datos de Kaggle denominado "Dataset from Water Pump with 52 sensors". Este conjunto de datos puede ser utilizado por investigadores e ingenieros que trabajen en el desarrollo y la optimización de sistemas de bombas de agua, así como para el mantenimiento predictivo, el diagnóstico de fallos y la optimización de sistemas de bombas de agua.

El conjunto de datos incluye datos sin procesar y datos procesados, con los datos procesados transformados y limpiados para facilitar el análisis. Se proporciona en formato CSV.

Los datos se refieren a una bomba de agua de una zona pequeña que sufrió 7 fallos en el sistema durante el año 2018. Al analizar los datos, el equipo no ha podido identificar ningún

patrón en los momentos en que el sistema falló, por lo que no saben con certeza dónde deben enfocar sus esfuerzos para evitar futuros problemas.

El objetivo es predecir futuros fallos de las bombas de agua utilizando los datos históricos de los sensores, lo que permitirá al equipo reaccionar de forma proactiva y planificar la solución de mantenimiento más adecuada.

Detallamos los sensores:

Cuadro 3.3: Sensores I

SENSOR_00 – Motor Casing Vibration
SENSOR_01 – Motor Frequency A
SENSOR_02 – Motor Frequency B
SENSOR_03 – Motor Frequency C
SENSOR_04 – Motor Speed
SENSOR_05 – Motor Current
SENSOR_06 – Motor Active Power
SENSOR_07 – Motor Apparent Power
SENSOR_08 – Motor Reactive Power
SENSOR_09 – Motor Shaft Power
SENSOR_10 – Motor Phase Current A
SENSOR_11 – Motor Phase Current B
SENSOR_12 – Motor Phase Current C
SENSOR_13 – Motor Coupling Vibration
SENSOR_14 – Motor Phase Voltage AB
SENSOR_16 – Motor Phase Voltage BC
SENSOR_17 – Motor Phase Voltage CA
SENSOR_18 – Pump Casing Vibration
SENSOR_19 – Pump Stage 1 Impeller Speed
SENSOR_20 – Pump Stage 1 Impeller Speed
SENSOR_21 – Pump Stage 1 Impeller Speed
SENSOR_22 – Pump Stage 1 Impeller Speed
SENSOR_23 – Pump Stage 1 Impeller Speed
SENSOR_24 – Pump Stage 1 Impeller Speed
SENSOR_25 – Pump Stage 2 Impeller Speed
SENSOR_26 – Pump Stage 2 Impeller Speed
SENSOR_27 – Pump Stage 2 Impeller Speed
SENSOR_28 – Pump Stage 2 Impeller Speed
SENSOR_29 – Pump Stage 2 Impeller Speed
SENSOR_30 – Pump Stage 2 Impeller Speed

Cuadro 3.4: Sensores II

SENSOR_31 – Pump Stage 2 Impeller Speed
SENSOR_32 – Pump Stage 2 Impeller Speed
SENSOR_33 – Pump Stage 2 Impeller Speed
SENSOR_34 – Pump Inlet Flow
SENSOR_35 – Pump Discharge Flow
SENSOR_36 – Pump UNKNOWN
SENSOR_37 – Pump Lube Oil Overhead Reservoir Level
SENSOR_38 – Pump Lube Oil Return Temp
SENSOR_39 – Pump Lube Oil Supply Temp
SENSOR_40 – Pump Thrust Bearing Active Temp
SENSOR_41 – Motor Non Drive End Radial Bearing Temp 1
SENSOR_42 – Motor Non Drive End Radial Bearing Temp 2
SENSOR_43 – Pump Thrust Bearing Inactive Temp
SENSOR_44 – Pump Drive End Radial Bearing Temp 1
SENSOR_45 – Pump non Drive End Radial Bearing Temp 1
SENSOR_46 – Pump Non Drive End Radial Bearing Temp 2
SENSOR_47 – Pump Drive End Radial Bearing Temp 2
SENSOR_48 – Pump Inlet Pressure
SENSOR_49 – Pump Temp Unknown
SENSOR_50 – Pump Discharge Pressure 1
SENSOR_51 – Pump Discharge Pressure 2
Pump Status

El problema de las bombas de agua es un problema de clasificación en el que se utiliza el aprendizaje automático para predecir si una bomba de agua está funcionando correctamente o no en base a los datos proporcionados por 52 sensores.

Los sensores proporcionan datos sobre diversos aspectos del rendimiento de la bomba, como la presión del agua, la temperatura y el caudal. El objetivo del aprendizaje automático es analizar estos datos y predecir si la bomba está funcionando correctamente o no.

3.5. Métricas de rendimiento

En este estudio de caso, es importante que el modelo de aprendizaje automático sea capaz de clasificar adecuadamente tanto las bombas de agua que están funcionando correctamente como las que no lo están.

Si el modelo predice incorrectamente la clase de una bomba, esto puede tener consecuencias graves, como averías, costes de reparación y problemas de seguridad. Por ejemplo, si el

modelo predice que una bomba que en realidad está funcionando correctamente no lo está, se podría llevar a cabo un mantenimiento innecesario en la bomba, lo que podría ocasionar costes adicionales y pérdida de tiempo.

Por otro lado, si el modelo predice que una bomba que en realidad está fallando está funcionando correctamente, esto podría tener consecuencias aún más graves, como averías y problemas de seguridad.

Para evaluar el rendimiento del modelo en este problema de clasificación, se utilizan dos métricas: la puntuación F1-Score y la matriz de confusión.

- La macro F1-Score se calcula tomando la F1-Score de cada clase (es decir, la precisión y el recall de cada clase) y calculando su media. Esta métrica nos permite dar la misma importancia a ambas clases y evaluar el rendimiento del modelo en términos de precisión y recall promedio.
- La matriz de confusión, por otro lado, nos permite visualizar el rendimiento del modelo y ver cuántos puntos ha clasificado correctamente y cuántos ha clasificado incorrectamente para cada clase. Esta información es útil para identificar las fortalezas y debilidades del modelo y para tomar medidas para mejorar su rendimiento.

3.6. Resumen de datos

Los datos del sensor de la bomba se recogen de kaggle:

<https://www.kaggle.com/datasets/nphantawee/pump-sensor-data>

Los datos contienen lecturas de 52 sensores y su correspondiente marca de tiempo. Se proporcionan los datos de los sensores de 5 meses, de abril a agosto. Cada fila contiene lecturas de sensores después de un minuto y no se especifica qué parámetro mide cada sensor. El conjunto de datos contiene un total de 220320 puntos de datos.

Las proximas figuras corresponden a las primeras y últimas filas del dataset y a una descripción del dataset (Utilizamos el método describe de pandas para obtener las estadísticas descriptivas incluyen las que resumen la tendencia central, la dispersión y la forma de la distribución de un conjunto de datos, excluyendo los valores NaN).

Cuadro 3.5: Head and Tail Dataset

Output exceeds the [size limit](#). Open the full output data [in a text editor](#) \

	timestamp	sensor_01	sensor_02	sensor_03	sensor_04	...		
0	2018-04-01 00:00:00	47.09201	53.211800	46.310760	634.375000			
1	2018-04-01 00:01:00	47.09201	53.211800	46.310760	634.375000			
2	2018-04-01 00:02:00	47.35243	53.211800	46.397570	638.888900			
3	2018-04-01 00:03:00	47.09201	53.168400	46.397568	628.125000			
4	2018-04-01 00:04:00	47.13541	53.211800	46.397568	636.458300			
...		
220315	2018-08-31 23:55:00	47.69965	50.520830	43.142361	634.722229			
220316	2018-08-31 23:56:00	47.69965	50.564240	43.142361	630.902771			
220317	2018-08-31 23:57:00	47.69965	50.520830	43.142361	625.925903			
220318	2018-08-31 23:58:00	47.69965	50.520832	43.142361	635.648100			
220319	2018-08-31 23:59:00	47.69965	50.520832	43.142361	639.814800			
	sensor_05	sensor_06	sensor_07	sensor_08	sensor_09	...	sensor_41	\
0	76.45975	13.41146	16.13136	15.56713	15.05353	...	30.989580	
1	76.45975	13.41146	16.13136	15.56713	15.05353	...	30.989580	
2	73.54598	13.32465	16.03733	15.61777	15.01013	...	30.468750	
3	76.98898	13.31742	16.24711	15.69734	15.08247	...	30.468750	
4	76.58897	13.35359	16.21094	15.69734	15.08247	...	30.989580	
...
220315	64.59095	15.11863	16.65220	15.65393	15.16204	...	30.468750	
220316	65.83363	15.15480	16.70284	15.65393	15.11863	...	30.208332	
220317	67.29445	15.08970	16.70284	15.69734	15.11863	...	29.947920	
220318	65.09175	15.11863	16.56539	15.74074	15.11863	...	29.947916	
220319	65.45634	15.11863	16.65220	15.65393	15.01013	...	29.947916	
...								
220317	217.3032	155.38190		NORMAL				
220318	222.5116	153.93520		NORMAL				
220319	227.4306	150.46300		NORMAL				

[220320 rows x 50 columns]

Cuadro 3.6: Estadísticas Dataset

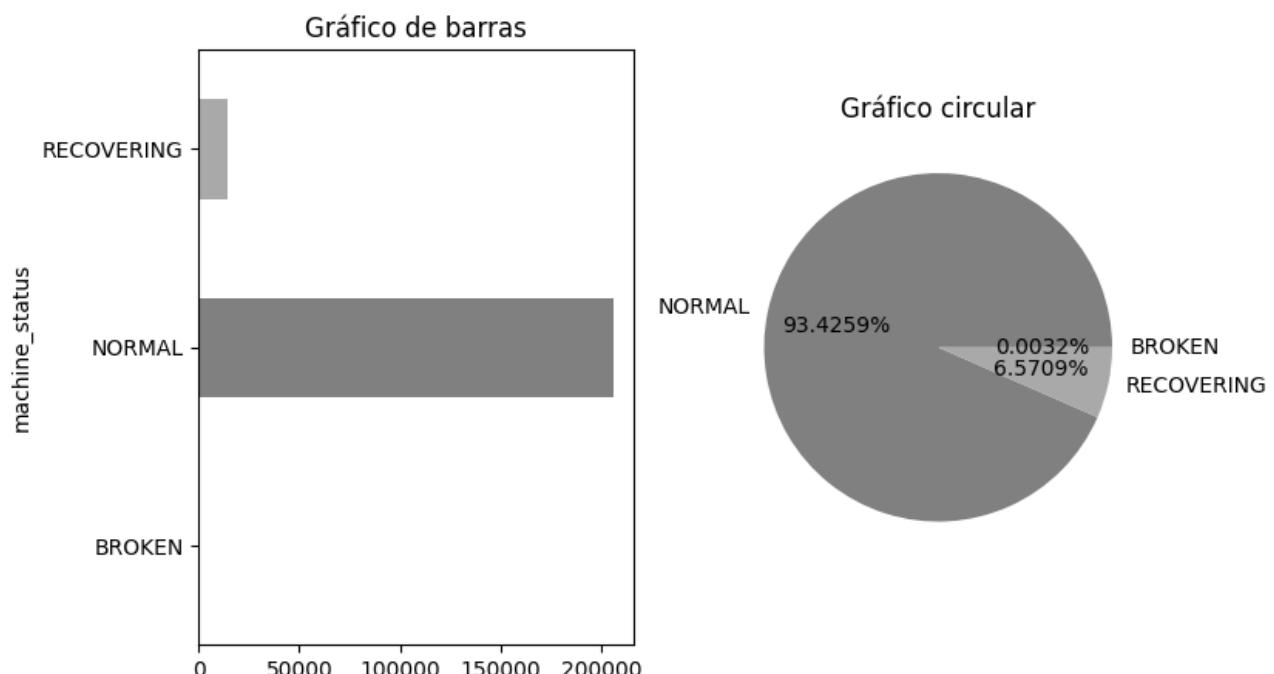
	index	count	mean	std	min	25%	50%	75%	max
0	sensor_01	219951.0	47.591611	3.296666	0.000000	46.310760	48.133678	49.479160	56.727430
1	sensor_02	220301.0	50.867392	3.666820	33.159720	50.390620	51.649300	52.777770	56.032990
2	sensor_03	220301.0	43.752481	2.418887	31.640620	42.838539	44.227428	45.312500	48.220490
3	sensor_04	220301.0	590.673936	144.023912	2.798032	626.620400	632.638916	637.615723	800.000000
4	sensor_05	220301.0	73.396414	17.298247	0.000000	69.976260	75.576790	80.912150	99.999880
5	sensor_06	215522.0	13.501537	2.163736	0.014468	13.346350	13.642940	14.539930	22.251160
6	sensor_07	214869.0	15.843152	2.201155	0.000000	15.907120	16.167530	16.427950	23.596640
7	sensor_08	215213.0	15.200721	2.037390	0.028935	15.183740	15.494790	15.697340	24.348960
8	sensor_09	215725.0	14.799210	2.091963	0.000000	15.053530	15.082470	15.118630	25.000000
9	sensor_10	220301.0	41.470339	12.093519	0.000000	40.705260	44.291340	47.463760	76.106860
10	sensor_11	220301.0	41.918319	13.056425	0.000000	38.856420	45.363140	49.656540	60.000000
11	sensor_12	220301.0	29.136975	10.113935	0.000000	28.686810	32.515830	34.939730	45.000000
12	sensor_13	220301.0	7.078858	6.901755	0.000000	1.538516	2.929809	12.859520	31.187550
13	sensor_14	220299.0	376.860041	113.206382	32.409550	418.103250	420.106200	420.997100	500.000000
14	sensor_16	220289.0	416.472892	126.072642	0.000000	459.453400	462.856100	464.302700	739.741500
15	sensor_17	220274.0	421.127517	129.156175	0.000000	454.138825	462.020250	466.857075	599.999939
16	sensor_18	220274.0	2.303785	0.765883	0.000000	2.447542	2.533704	2.587682	4.873250
17	sensor_19	220304.0	590.829775	199.345820	0.000000	662.768975	665.672400	667.146700	878.917900
18	sensor_20	220304.0	360.805165	101.974118	0.000000	398.021500	399.367000	400.088400	448.907900
19	sensor_21	220304.0	796.225942	226.679317	95.527660	875.464400	879.697600	882.129900	1107.526000
20	sensor_22	220279.0	459.792815	154.528337	0.000000	478.962600	531.855900	534.254850	594.061100
21	sensor_23	220304.0	922.609264	291.835280	0.000000	950.922400	981.925000	1090.808000	1227.564000
22	sensor_24	220304.0	556.235397	182.297979	0.000000	601.151050	625.873500	628.607725	1000.000000
23	sensor_25	220284.0	649.144799	220.865166	0.000000	693.957800	740.203500	750.357125	839.575000
24	sensor_26	220300.0	786.411781	246.663608	43.154790	790.489575	861.869600	919.104775	1214.420000
25	sensor_27	220304.0	501.506589	169.823173	0.000000	448.297950	494.468450	536.274550	2000.000000
26	sensor_28	220304.0	851.690339	313.074032	4.319347	782.682625	967.279850	1043.976500	1841.146000
27	sensor_29	220248.0	576.195305	225.764091	0.636574	518.947225	564.872500	744.021475	1466.281000
28	sensor_30	220059.0	614.596442	195.726872	0.000000	627.777800	668.981400	697.222200	1600.000000
29	sensor_31	220304.0	863.323100	283.544760	23.958330	839.062400	917.708300	981.249900	1800.000000
30	sensor_32	220252.0	804.283915	260.602361	0.240716	760.607475	878.850750	943.877625	1839.211000
31	sensor_33	220304.0	486.405980	150.751836	6.460602	489.761075	512.271750	555.163225	1578.600000
32	sensor_34	220304.0	234.971776	88.376065	54.882370	172.486300	226.356050	316.844950	425.549800
33	sensor_35	220304.0	427.129817	141.772519	0.000000	353.176625	473.349350	528.891025	694.479126
34	sensor_36	220304.0	593.033876	289.385511	2.260970	288.547575	709.668050	837.333025	984.060700
35	sensor_37	220304.0	60.787360	37.604883	0.000000	28.799220	64.295485	90.821928	174.901200
36	sensor_38	220293.0	49.655946	10.540397	24.479166	45.572910	49.479160	53.645830	417.708300
37	sensor_39	220293.0	36.610444	15.613723	19.270830	32.552080	35.416660	39.062500	547.916600
38	sensor_40	220293.0	68.844530	21.371139	23.437500	57.812500	66.406250	77.864580	512.760400
39	sensor_41	220293.0	35.365126	7.898665	20.833330	32.552080	34.895832	37.760410	420.312500
40	sensor_42	220293.0	35.453455	10.259521	22.135416	32.812500	35.156250	36.979164	374.218800
41	sensor_43	220293.0	43.879591	11.044404	24.479166	39.583330	42.968750	46.614580	408.593700
42	sensor_44	220293.0	42.656877	11.576355	25.752316	36.747684	40.509260	45.138890	1000.000000
43	sensor_45	220293.0	43.094984	12.837520	26.331018	36.747684	40.219910	44.849540	320.312500
44	sensor_46	220293.0	48.018585	15.641284	26.331018	40.509258	44.849540	51.215280	370.370400
45	sensor_47	220293.0	44.340903	10.442437	27.199070	39.062500	42.534720	46.585650	303.530100
46	sensor_48	220293.0	150.889044	82.244957	26.331018	83.912030	138.020800	208.333300	561.632000
47	sensor_49	220293.0	57.119968	19.143598	26.620370	47.743060	52.662040	60.763890	464.409700

3.7. EDA - Análisis Exploratorio de Datos

3.7.1. Distribución de las clases

Los datos contienen 3 clases: Normal, Recuperación y Roto. 205836 puntos de datos pertenecen a la clase Normal, 14477 puntos de datos pertenecen a la clase Recuperación y 7 puntos de datos pertenecen a la clase Roto.

Figura 3.1: Distribución de clases



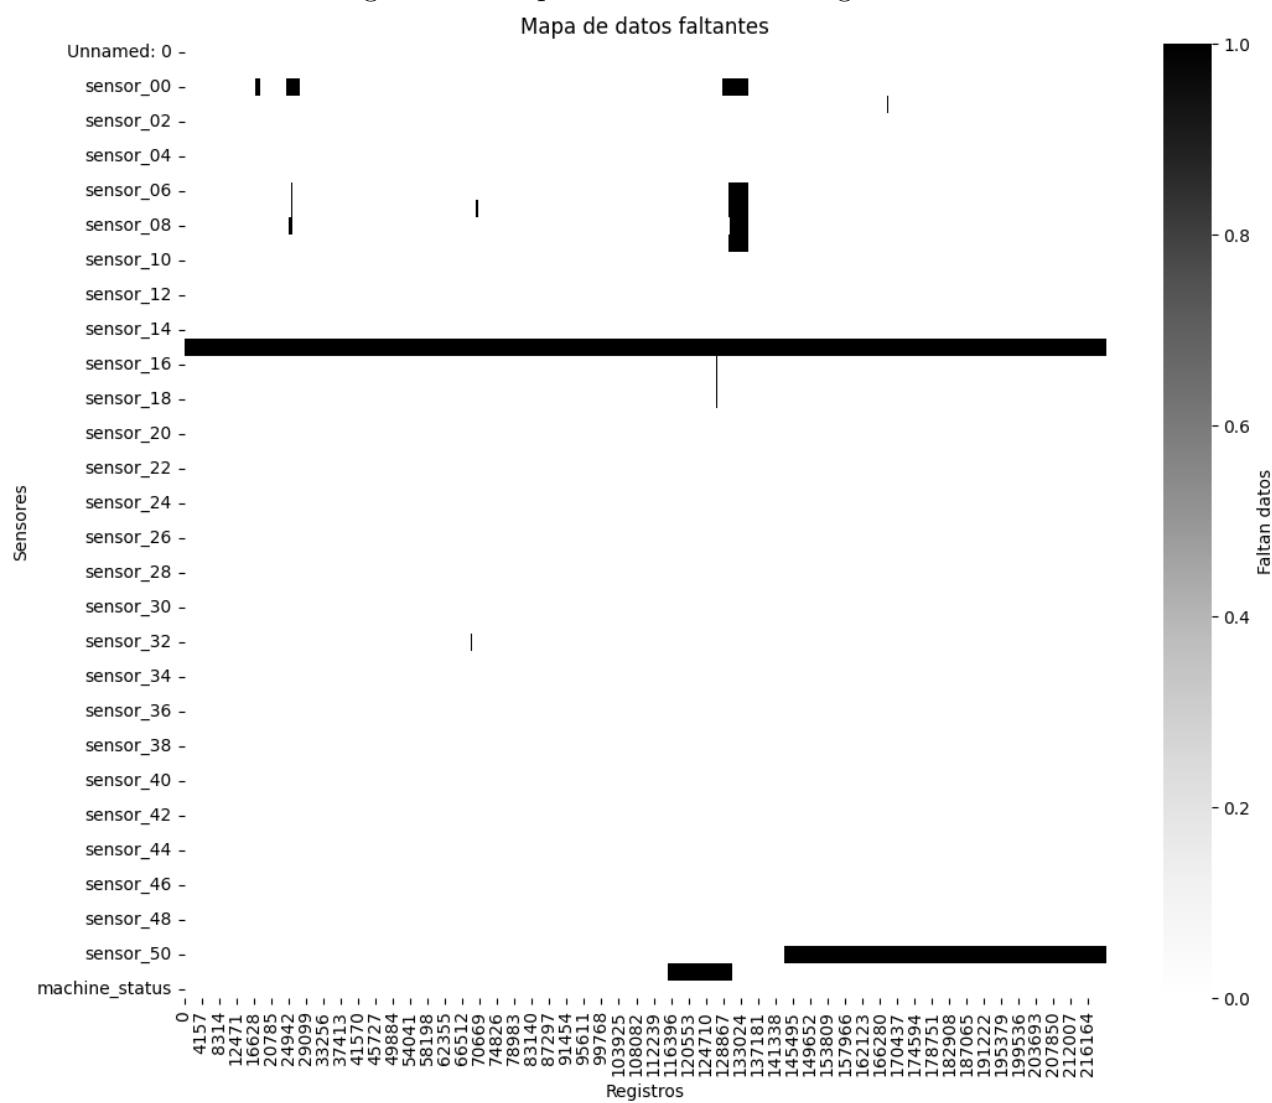
3.7.2. Missing Values

Para crear el gráfico, primero se utiliza el método `isna` de pandas para seleccionar solo los valores faltantes del conjunto de datos. Luego, se utiliza el método `transpose` para transponer el conjunto de datos, de modo que las columnas se conviertan en filas y las filas en columnas.

A continuación, se utiliza la función `heatmap` de seaborn para crear un mapa de calor del conjunto de datos. El mapa de calor muestra una tabla de valores en forma de mapa de colores, donde los colores más oscuros indican valores más altos y los colores más claros indican valores más bajos. En este caso, el mapa de calor muestra la cantidad de valores faltantes en cada columna.

Es importante tener en cuenta que esta función solo muestra el gráfico y no devuelve ningún valor.

Figura 3.2: Mapa de Calor de Missing Values



3.7.3. Visualización de sensores

En esta sección, mostramos gráficas con los datos de los sensores tras eliminar los sensores con mayor número de **Missing Values**. Estas gráficas nos permiten visualizar de manera clara y precisa la información obtenida de cada sensor y analizar cómo varían los valores a lo largo del tiempo. Además, nos ayudan a detectar patrones y tendencias que pueden ser útiles para el análisis y la clasificación de los datos. Por tanto, la visualización de los datos es una herramienta esencial para comprender y explotar al máximo el potencial de los datos que se han recogido.

Aunque no tenemos mucho conocimiento sobre las bombas de agua y sus sensores, es importante examinar los datos y buscar patrones que puedan ser útiles para predecir fallos o anomalías. Al observar las gráficas, podemos ver que hay grandes cambios en los valores de muchos de los sensores en determinados momentos. En estos momentos, algunos sensores caen a valores muy bajos, mientras que otros aumentan y otros, que normalmente son más estables, fluctúan mucho.

Figura 3.3: Sensor_01

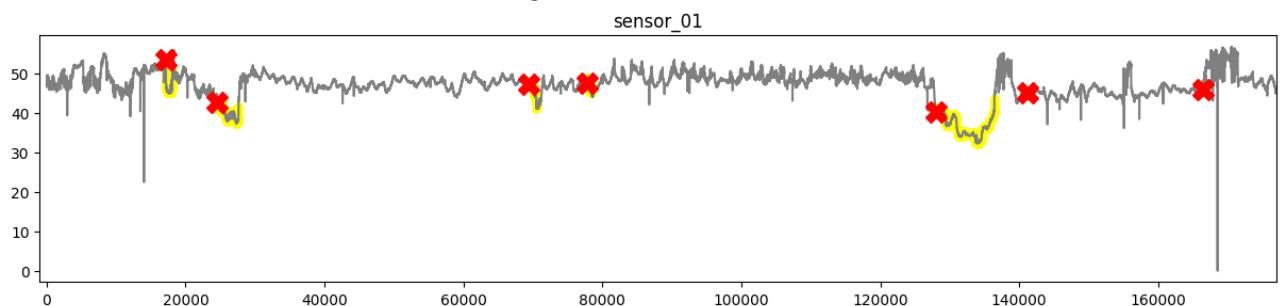
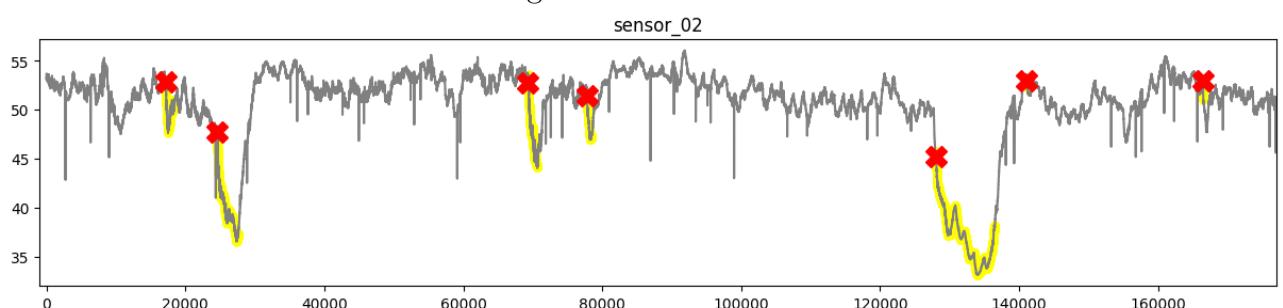


Figura 3.4: Sensor_02



El resto de gráficas de los sensores se encuentran en el [Anexo I](#).

Para las 2 últimas gráficas hemos generado 2 nuevos valores:

- Primero, se define un diccionario m que asigna valores numéricos a los distintos estados de la máquina: 'NORMAL' se asigna el valor 2, 'RECOVERING' se asigna el valor 1 y 'BROKEN' se asigna el valor 0.
- Luego, se utiliza el método map de pandas para reemplazar los valores de la columna 'machine_status' con los valores numéricos del diccionario m. El resultado se asigna a la nueva columna 'stat'.
- A continuación, se utiliza el método rolling de pandas para calcular el promedio móvil de la columna 'stat'. El promedio móvil es el promedio de una ventana de datos móviles a lo largo del tiempo. En este caso, se utiliza una ventana de dos elementos, lo que significa que se calcula el promedio de cada par de elementos consecutivos. El resultado se asigna a la nueva columna 'rol'.

Figura 3.5: Stat

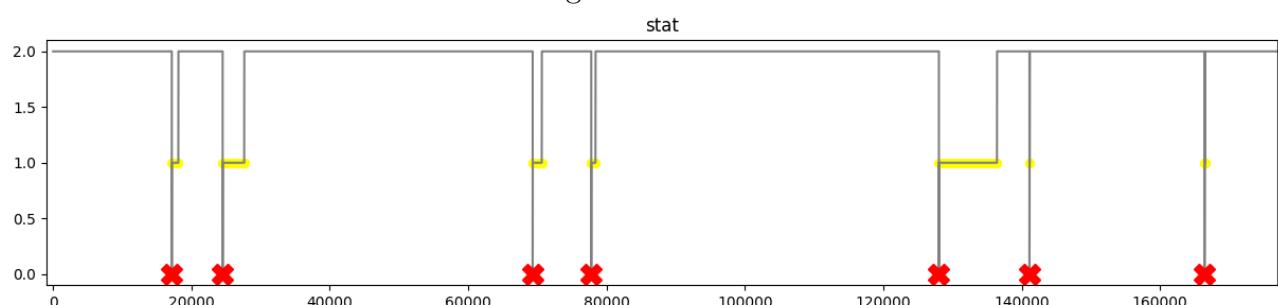
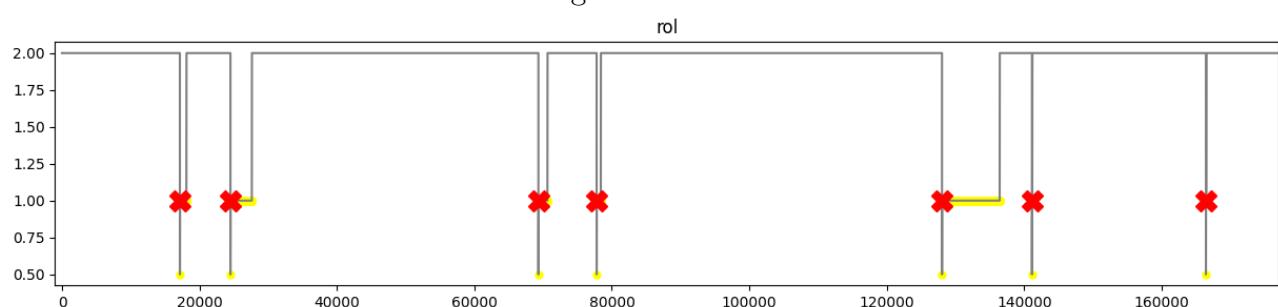


Figura 3.6: Rol



3.7.4. Matriz de correlaciones

La correlación es uno de los muchos términos estadísticos que se encuentran con más frecuencia en muchos casos científicos. En términos generales, la correlación es un parámetro que describe la relación direccional entre dos variables, estén o no relacionadas.

Una correlación positiva (+) significa que las dos variables tienden a moverse en la misma dirección. Una correlación negativa (-) significa que las dos variables tienden a moverse en la dirección opuesta.

Además, una correlación alta indica que las variables están estrechamente relacionadas y una correlación baja indica que las variables no están relacionadas.

Tipos de correlación:

- La correlación de Pearson mide la relación lineal entre las variables X e Y. Las dos variables tienden a tener una correlación fuerte si muestran un valor de +1 (correlacionadas en el mismo sentido) o -1 (correlacionadas en sentido inverso) y no tienen correlación si el valor se aproxima a 0.
- La Correlación de Spearman mide la medida de correlación ordinal (la magnitud no es importante en absoluto, sólo lo es el rango) entre las variables X e Y. Al igual que la correlación de Pearson, el resultado varía entre -1 y +1, siendo 0 la ausencia de correlación.
- Kendall Tau utiliza medidas ordinales como base para los cálculos. La diferencia con la correlación de Spearman radica en el tratamiento de los valores de rango obtenidos a partir de las variables X e Y.

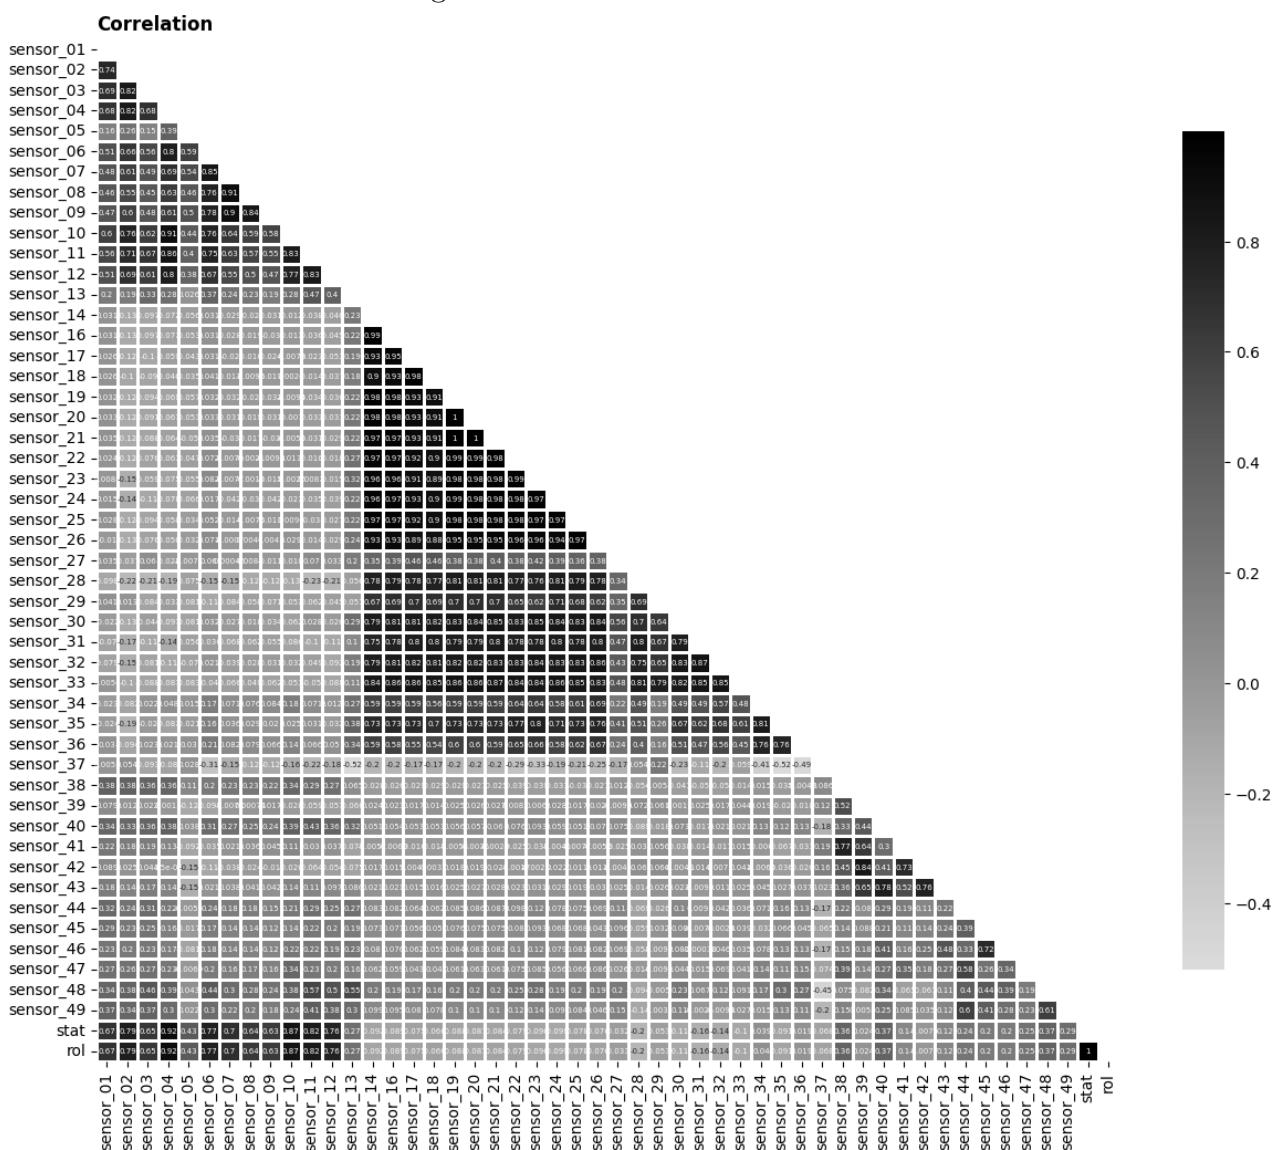
La matriz de correlación muestra los valores de correlación de Pearson, que miden el grado de relación lineal entre cada par de elementos o variables. Los valores de correlación se pueden ubicar entre -1 y +1. Sin embargo, en la práctica, los elementos por lo general tienen correlaciones positivas.

Para calcular la correlación, se utiliza el método corr de pandas, que calcula la correlación entre todas las parejas de columnas del conjunto de datos. El resultado se asigna a la variable data_clean_corr.

A continuación, se utiliza la función heatmap de seaborn para crear un mapa de calor de la matriz de correlación. El mapa de calor muestra una tabla de valores en forma de mapa de colores, donde los colores más oscuros indican valores más altos y los colores más claros indican valores más bajos. En este caso, el mapa de calor muestra la correlación entre las columnas numéricas del conjunto de datos.

Para la selección de las variables seleccionamos los sensores con una correlación superior al 75 % con la variable Stat.

Figura 3.7: Matriz de correlaciones



3.7.4.1. Resumen de EDA:

- El conjunto de datos contiene 3 clases: Normal, Recuperación y Roto. 205836 puntos de datos pertenecen a la clase Normal, 14477 puntos de datos pertenecen a la clase Recuperación y 7 puntos de datos pertenecen a la clase Roto.
- El gráfico de la variación del estado de la máquina con el tiempo muestra que el estado de recuperación sigue al estado de avería y que en el estado de recuperación la bomba intenta recuperarse del estado de avería, por lo que el estado de recuperación se considera estado de avería.
- Hemos reasignado 'NORMAL' con el valor 2, 'RECOVERING' con el valor 1 y 'BROKEN' con el valor 0.
- Al comprobar los valores que faltan, encontramos que todos los sensores tienen valores que faltan, todas las lecturas del sensor_15 faltan, el 34 % de las lecturas del sensor_50 faltan, el 6 % de las lecturas del sensor_51 faltan, el 4 % de las lecturas del sensor_00 faltan y todos los demás sensores tienen menos de un 2 % de valores que faltan.
- Hemos observado en el gráfico de valores perdidos que las lecturas de los sensores faltan tanto en el estado Normal como en el Roto, y que la mayoría de los datos faltan en el estado Roto.
- El sensor_15 se elimina del conjunto de datos, ya que faltan todos sus valores, y los valores que faltan de todos los demás sensores se rellenan con un valor fuera de distribución, -1.
- Se seleccionan los sensores 02, 04, 06, 10, 11 y 12 como características finales por tener una correlación superior al 75 % con la variable stat.

3.8. Modelado

Comenzamos el modelado, que es el proceso de entrenar un modelo a partir de datos de entrada para que pueda hacer predicciones precisas sobre datos futuros. El modelo se construye utilizando un algoritmo de aprendizaje automático y se entrena con un conjunto de datos de entrenamiento. Una vez que el modelo ha sido entrenado, se puede utilizar para hacer predicciones sobre nuevos datos.

Primeramente seleccionamos las variables X e Y

- X son los sensores previamente seleccionados
- Y es el output, en este caso stat.

3.8.1. Normalización de datos

La normalización de los datos es un proceso que se utiliza para ajustar los datos a una escala común.

$$X_norm = \frac{X - X.mean()}{X.std()} \quad (3.1)$$

En este caso, se están restando la media de cada columna a cada valor de la columna y luego dividiendo el resultado por la desviación estándar de la columna. Esto asegura que todas las columnas tengan una media de cero y una desviación estándar de uno.

La normalización de los datos es a veces útil cuando se comparan diferentes series de datos que pueden estar en escalas muy diferentes. También puede ser útil para algunos algoritmos de aprendizaje automático que se benefician de tener todas las características en la misma escala.

3.8.2. Seleccionar el tamaño de la muestra de validación

Con la función la función 'train_test_split' del módulo 'model_selection' de scikit-learn para dividir el conjunto de datos en dos conjuntos: un conjunto de entrenamiento y un conjunto de validación.

Los conjuntos de entrenamiento y validación se utilizan para evaluar y ajustar el modelo de aprendizaje automático. El conjunto de entrenamiento se utiliza para entrenar el modelo y el conjunto de validación se utiliza para evaluar cómo bien el modelo generaliza a datos que no ha visto antes. Esta división es importante porque queremos evaluar el rendimiento del modelo en datos que no ha visto durante el entrenamiento, ya que esto es más representativo de cómo el modelo se desempeñará en el mundo real.

En este caso, la función 'train_test_split' está dividiendo los datos de entrada 'X_norm' y las etiquetas 'y' en dos conjuntos: 'X_train' y 'X_validation' para los datos de entrada y 'Y_train' y 'Y_validation' para las etiquetas.

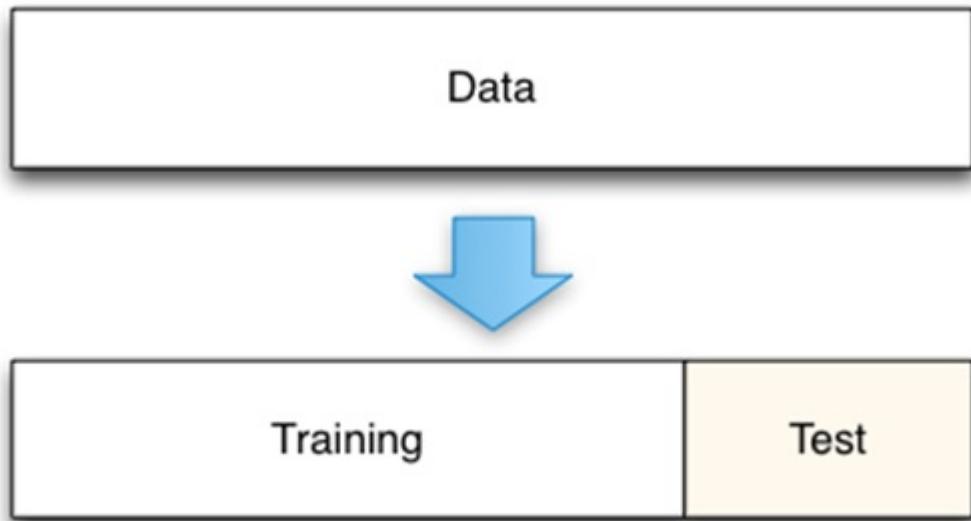
La proporción de datos en el conjunto de entrenamiento y el conjunto de validación se controla con el parámetro 'test_size'.

El parámetro 'random_state' asegura que los datos se dividen de manera consistente cada vez que se ejecuta el código.

$$validation_size = 0,20 \quad (3.2)$$

$$seed = 7 \quad (3.3)$$

Figura 3.8: División de datos



3.8.3. Modelos utilizados

Los modelos utilizados son en este trabajo son:

- Logistic Regression (LR)
- Linear Discriminant Analysis (LDA)
- K-Nearest Neighbors (KNN).
- Classification and Regression Trees (CART).
- Gaussian Naive Bayes (NB).
- Support Vector Machines (SVM).

Una de las razones por las cuales se ha realizado la evaluación con una mezcla de algoritmos lineales simples (LR y LDA) y no lineales (KNN, CART, NB y SVM) en lugar de otros, es porque estos algoritmos tienen diferentes fortalezas y debilidades.

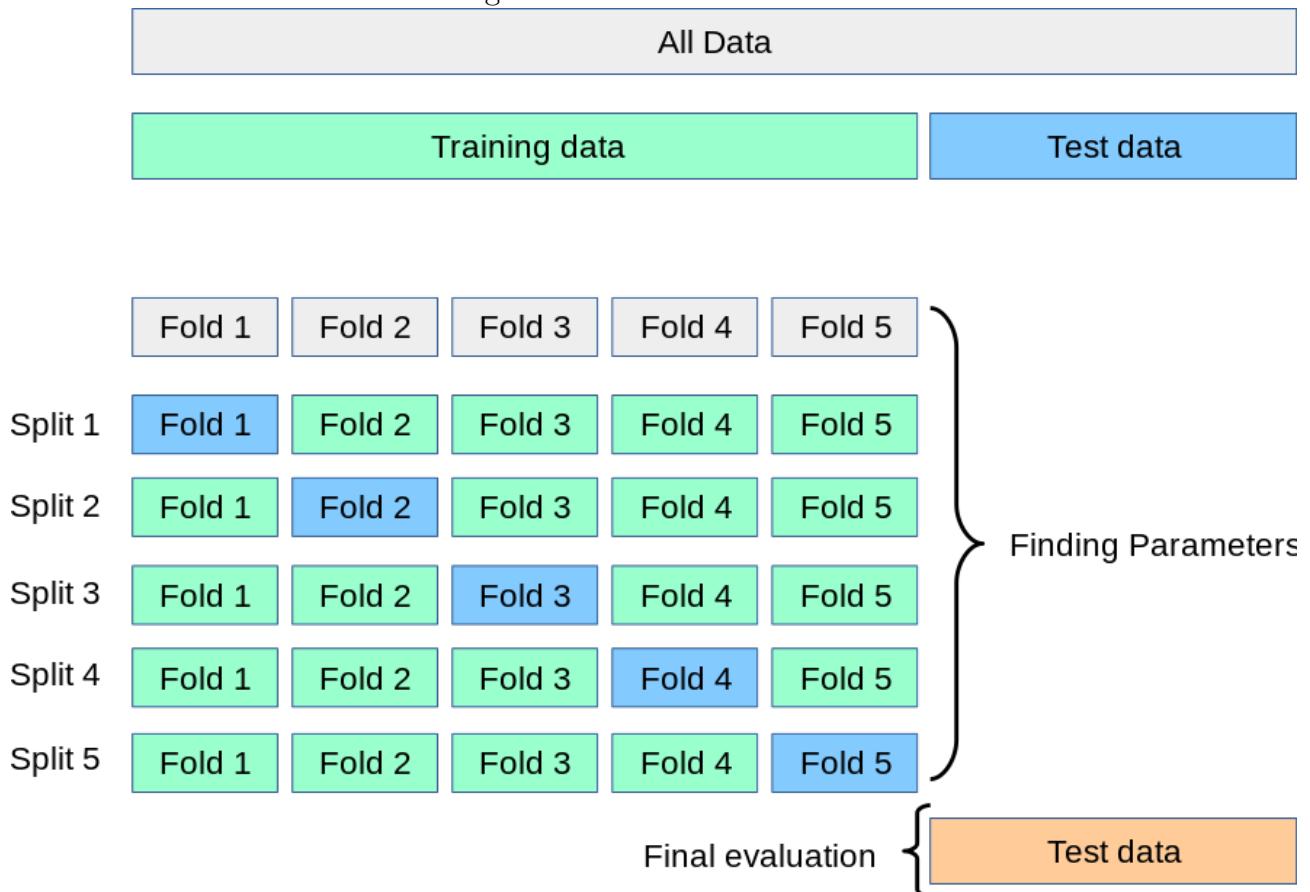
Los algoritmos lineales, como LR y LDA, son fáciles de entender y proporcionan una buena precisión en un gran número de casos. Sin embargo, pueden no ser tan precisos en casos más complejos, donde los datos no siguen un patrón lineal. Por otro lado, los algoritmos no lineales, como KNN, CART, NB y SVM, son capaces de manejar mejor casos complejos donde los datos no siguen un patrón lineal, son más difíciles de entender y requieren de una mayor cantidad de datos para su entrenamiento, pero proporcionan una mayor precisión en casos complejos.

También, es importante mencionar que al comparar los modelos entre sí, se pueden comparar las métricas de rendimiento para seleccionar el mejor modelo, ya sea mediante la comparación de las métricas de precisión, recall, entre otras.

Una vez seleccionado los algoritmos, procedemos a entrenarlos.

Para ello hemos utilizado la validación cruzada, que es una técnica utilizada para evaluar el rendimiento de un modelo de aprendizaje automático. Consiste en dividir el conjunto de datos en 'k' pliegues (o "folds"), donde 'k' es un número especificado por el usuario. Luego, se entrena el modelo 'k' veces, cada vez utilizando un pliegue diferente como el conjunto de validación y los 'k-1' pliegues restantes como el conjunto de entrenamiento. Finalmente, se calcula la puntuación media y la desviación estándar para cada modelo. Esto proporciona una medida más precisa del rendimiento del modelo que si simplemente entrenáramos y evaluáramos el modelo una vez con todos los datos.

Figura 3.9: División de datos



Cuadro 3.7: Comparación modelos

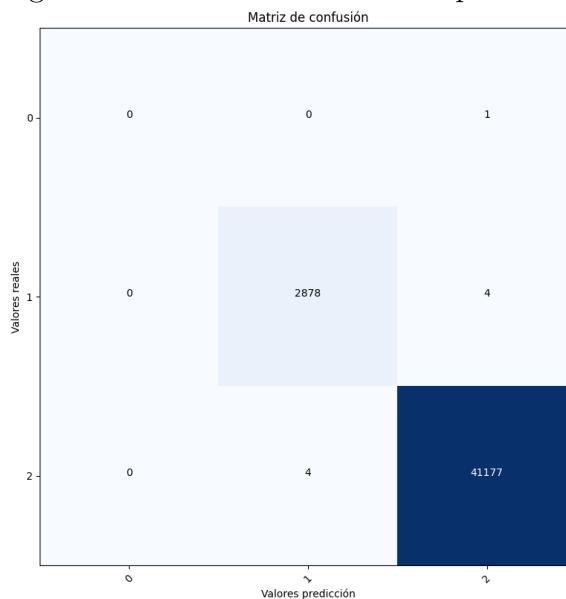
modelo	media	desviación Estandar
Logistic Regression (LR)	0.994117	(0.000545)
Linear Discriminant Analysis (LDA)	0.987059	(0.000673)
K-Nearest Neighbors (KNN).	0.999677	(0.000144)
Classification and Regression Trees (CART).	0.999523	(0.000132)
Gaussian Naive Bayes (NB).	0.982508	(0.001177)
Support Vector Machines (SVM).	0.998162	(0.000331)

3.8.4. Comparación de modelos

Tál y como vemos en la tabla anterior, el mejor modelo es KNN.

Con dicho modelo obtenemos la matriz de confusión. Muestra la cantidad de predicciones correctas y incorrectas que ha realizado un modelo de clasificación. Se suele presentar en forma de tabla con dos filas y dos columnas.

Figura 3.10: Matriz de confusión para KNN



La fila superior de la matriz de confusión se refiere a las predicciones positivas y la fila inferior se refiere a las predicciones negativas. La columna izquierda de la matriz se refiere a las etiquetas verdaderas negativas y la columna derecha se refiere a las etiquetas verdaderas positivas.

Hemos preprocessado nuestros datos de nuevo para asegurar una pizarra limpia en el nuevo modelo. Ahora usaremos GridSearchCV con KNN para encontrar los mejores parámetros para usar con este modelo.

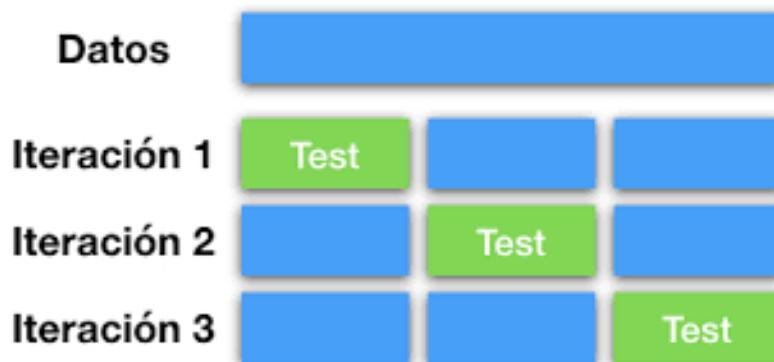
3.8.5. Ajuste de hiperparámetros

Para obtener el mejor rendimiento de los modelos de aprendizaje automático, ajustaremos los hiperparámetros mediante la técnica de validación cruzada. Debido a la naturaleza temporal de los datos, se debe tener cuidado al dividir los datos para evitar la fuga de datos.

scikit-learn dispone de varias clases que implementan la metodología de la validación cruzada. En el caso de que se desee utilizar para seleccionar los parámetros de entrenamiento de un modelo una de las opciones es GridSearchCV. El constructor de esta clase se ha de llamar indicándole la instancia de un modelo, los valores a probar y el número de conjuntos en el que se dividen los datos. Esto se realiza mediante los siguientes parámetros:

- estimator: el modelo que se ha de evaluar
- param_grid: un diccionario en que se indicar los parámetros a evaluar como clave y el conjunto elementos como valor
- cv: el número de conjuntos en los que se divide los datos para la validación cruzada.

Figura 3.11: CrossValidation



En la késima división, los k primeros pliegues se utilizan como datos de entrenamiento y el $(k+1)^o$ pliegue se utiliza como datos de prueba. Los hiperparámetros `n_estimators` (número de estimadores) y `max_depth` (profundidad máxima del árbol) se ajustan mediante Grid Search CV. Los parámetros utilizados son:

- '`n_neighbors`': [3, 5, 10]
- '`weights`': ['uniform', 'distance']
- '`algorithm`': ['ball_tree', 'kd_tree']
- '`p`': [1, 2]

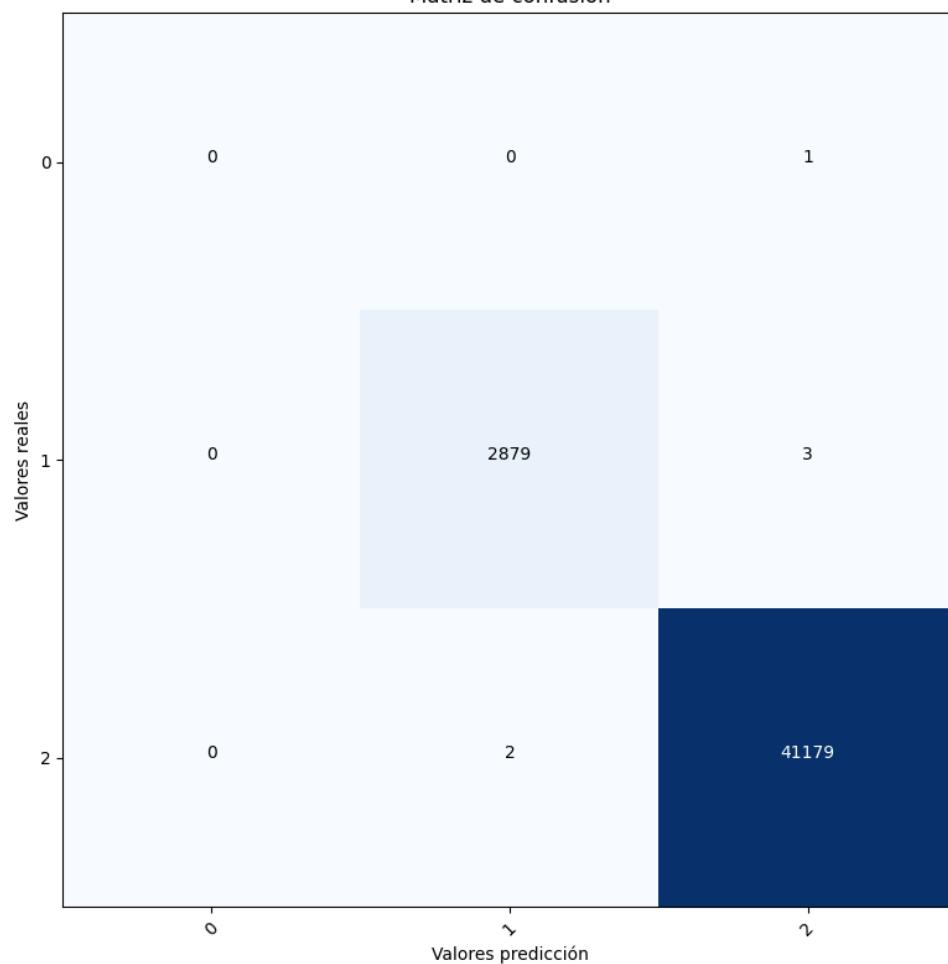
Y los mejores parámetros son: **Best parameters:** 'algorithm': 'ball_tree', 'n_neighbors': 5, 'p': 1, 'weights': 'distance'

Con dichos parámetros la precisión del modelo es de **0.9998638344226579**

Y la matriz de confusión es:

Figura 3.12: KNN Best

Matriz de confusión



Como se ve es más precisa que el anterior modelo.

3.9. Aplicación web

Se desarrolla una aplicación web utilizando HTML y el framework web Django que es capaz de predecir entradas de un único punto y entradas múltiples. Para obtener la predicción de múltiples puntos de datos se debe cargar un archivo csv. La predicción de clase y los valores de probabilidad correspondientes pueden descargarse como un archivo csv.

Para ello guardaremos el modelo con la función ”to_pickle” de pandas. La función ’to_pickle’ de pandas se utiliza para serializar un objeto de Python y guardarlo en un archivo con formato ’pickle’. En este caso, se está serializando el modelo de aprendizaje automático KNN y guardándolo en un archivo llamado ’KNN_model.pickle’ en la carpeta ’media’.

La serialización es el proceso de convertir un objeto en una secuencia de bytes, que se puede guardar en un archivo o transmitir a través de una red. El formato ’pickle’ es uno de los formatos más comunes para serializar objetos de Python. Al serializar el modelo y guardarlo en un archivo, podemos guardar el estado del modelo entrenado y luego cargarlo más tarde y utilizarlo sin tener que volver a entrenar el modelo.

El producto a obtener con este TFM es una web-app destinada a mostrar los datos recogidos por diferentes sensores instalados en maquinaria para conocer su comportamiento. También poder generar un algoritmo de Machine-Learning para la predicción de anomalías y comportamientos de dichas máquinas.

3.9.1. Codificación

Utilizando Django, un framework de desarrollo de aplicaciones web de código abierto escrito en Python, hemos generado esta página web.

Figura 3.13: Pantalla inicial.

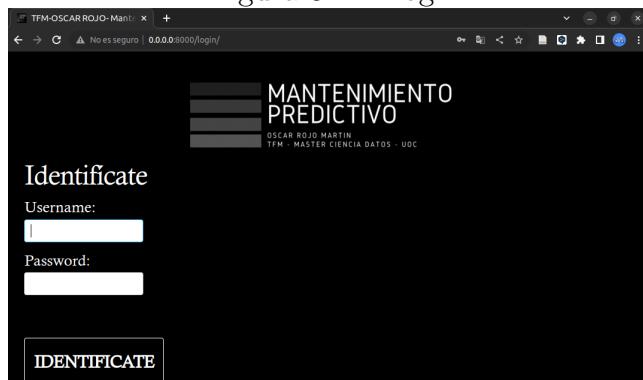


Django,fue diseñado para ser rápido, seguro y escalable y proporciona un conjunto de herra-

mientas para el desarrollo de aplicaciones web, como un sistema de gestión de bases de datos, un motor de plantillas y una capa de abstracción de URLs.

Se previsto que el acceso sea privado, por lo que se ha habilitado una opción para logearse.

Figura 3.14: Login



Para el almacenamiento de los datos, se utiliza una Base de Datos Relacional SQLite.

3.9.2. Apartados de la Aplicación-Web

Pasamos a describir brevemente los diferentes apartados de la aplicación web.

3.9.2.1. EDA - Exploratory Data Analysis

En este apartado tenemos un pequeño panel de control donde nos indica el número de registros, parámetros, Missing value, etc, del dataset así como las gráficas expuestas anteriormente : Distribucion de clases (Figura 3.1) en página 56, Mapa de Calor de Missing Values (Figura 3.2) en página 57 y Matriz de correlaciones (Figura 3.7) en página 61. Tambien se muestra en tabla html el Resumen dataset (Figura 3.6) en página 55.

Figura 3.15: EDA



3.9.2.2. Visualización

En este enlace mostramos las gráficas de los sensores mostrados en el apartado [3.7.3 Visualización de sensores](#)

Figura 3.16: Visualización

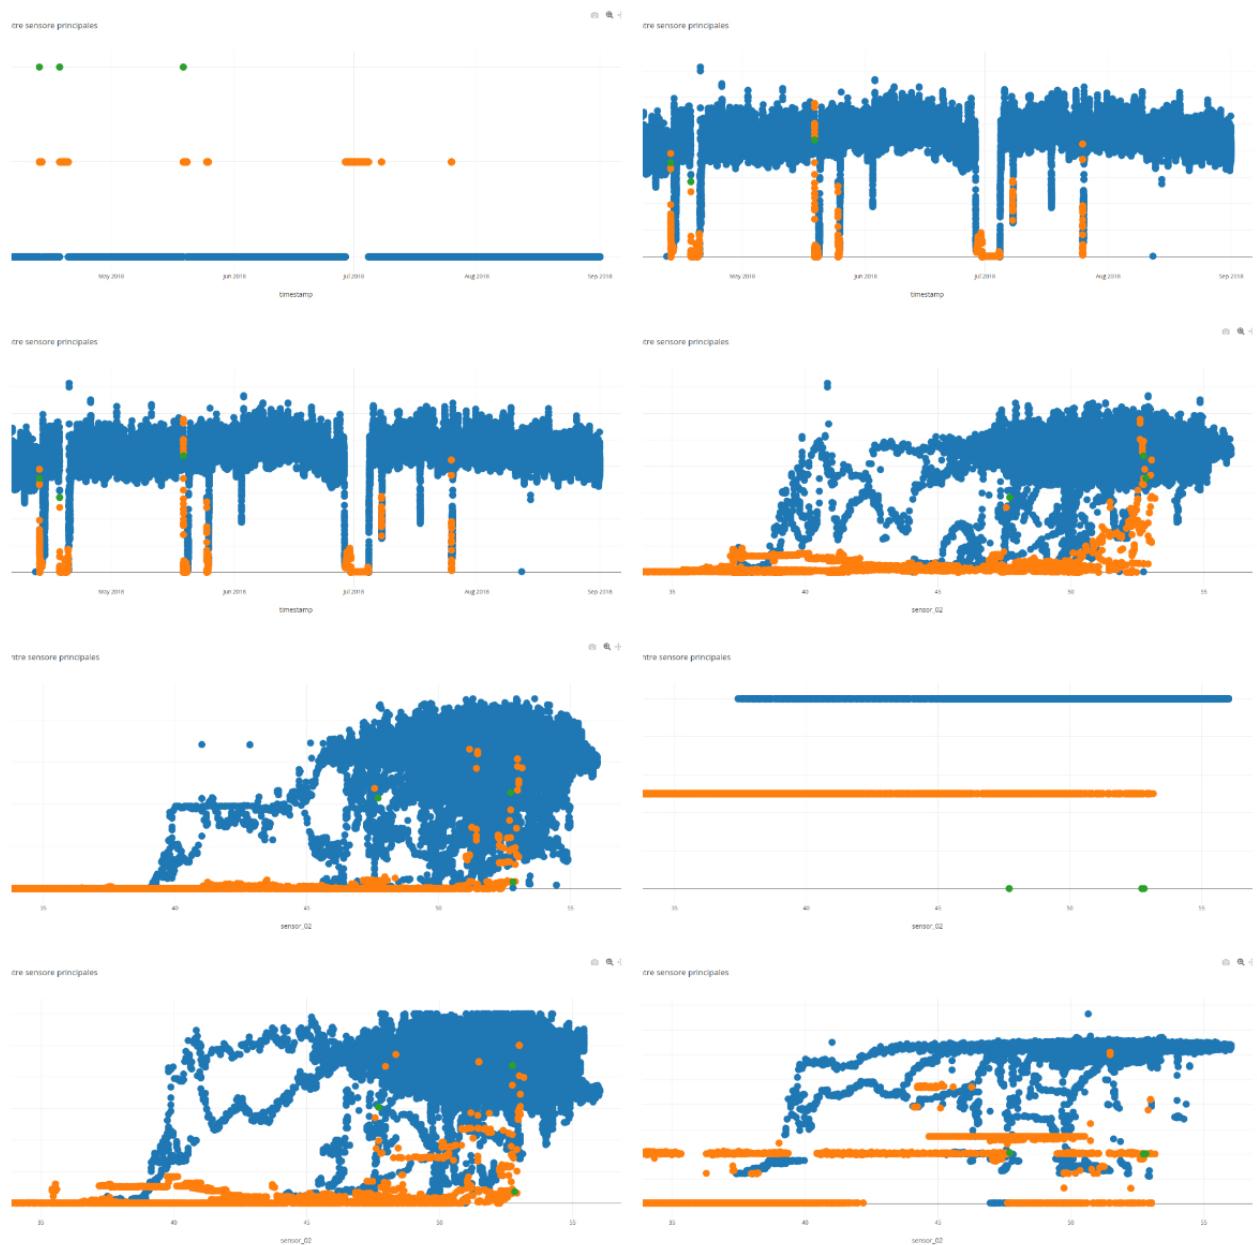


Se muestran las gráficas [Sensor_01](#), [Sensor_02](#), [Sensor_03](#), [Sensor_06](#), [Sensor_07](#), etc.

3.9.2.3. Comparativa de Sensores

Para este apartado utilizamos la biblioteca plotly, que nos permite realizar gráficos interactivo. El tipo de gráfico realizado es Scatter, con el fin de comparar dos registros simultáneamente. En este caso por los tiempos de carga y la gran necesidad de recursos que necesita el ordenador y AWS-EC2, hemos seleccionado los sensores destinados a realizar el modelo de predicción: [Sensor_02](#), [Sensor_04](#), [Sensor_05](#), [Sensor_10](#), [Sensor_11](#) y [Sensor_12](#) junto con [Stat](#), el output "machine_status y el las fechas de registros.

Figura 3.17: ScatterPlot by Plotly



3.9.2.4. Predicción

Para este apartado hemos generado unos cuadros de input de los valores de cada sensor e informamos en dichos input de la media, el valor mínimo y máximo de los sensores con el fin de aportar un valor adicional al input que inserten

Figura 3.18: Input predicción



3.9.2.5. Resultado

Este último aportado, es el resultado del calculo de las predicción según el modelo utilizado. Mostramos los datos de los input introducidos y el resultado correspondiente en una tabla... (pendiente de terminar)

Figura 3.19: Tabla de Resultados

INICIO EDA VISUALIZACIÓN COMPARATIVA SENSORES PREDICCIÓN RESULTADO IMPORTAR ARCHIVOS TFM-OSCAR ROJO

MANTENIMIENTO PREDICTIVO
ESTADÍSTICA - MÁSTER CIENCIAS DATOS - IMC

3.9.2.6. Importar archivos

Añadimos un apartado para la importación de fichero en caso en que se actualicen los datos recogidos

Figura 3.20: Importador de ficheros



3.9.2.7. TFM-Oscar Rojo

Y por último habilitamos un link en el que se descarga el TFM en formato pdf en una pestaña nueva del navegador.

3.9.3. Puesta en Producción de la aplicación

Ver el README del repositorio:

https://github.com/zumaiaUOC/TFM_dashboard

Allí se encontrará toda la información para darse de alta en AWS, clonar el repositorio, Generar y configurar la instancia de la MV. Así como información para utilizar varios terminales-shell mediante ScreenRC

3.10. Repositorio

El código del Trabajo Final de Master (TFM) se encuentra almacenado en un repositorio anteriormente indicado. Esto permite a los interesados en el proyecto acceder al código y utilizarlo para su propio uso, siempre y cuando se respeten las condiciones de la licencia indicada.

Capítulo 4

Conclusiones

4.1. Conclusiones

En conjunto, se considera que, a pesar de no haber completado todos los objetivos específicos, se ha alcanzado el objetivo general del proyecto, que era el de proporcionar una herramienta analítica capaz de predecir la rotura de una maquinaria, con especial atención al dataset de bombas de agua utilizado en el desarrollo del modelo.

Desglosamos los objetivos específicos del proyecto:

El primer objetivo específico del proyecto consistía en lograr un modelo predictivo mediante el uso de técnicas de Machine Learning con el objetivo de mejorar el mantenimiento predictivo de maquinaria y prevenir fallos en las mismas. Con este fin, se ha alcanzado un alto grado de precisión en el modelo desarrollado, lo cual se considera un logro significativo.

Un segundo proyecto en particular era la creación de una aplicación web que permitiera el acceso a los resultados del modelo en tiempo real y proporcionara una interfaz sencilla para su uso. Aunque se han realizado avances en este sentido, no se ha podido completar la implementación debido a limitaciones de tiempo.

El tercer proyecto en particular del proyecto suponía poner en producción la aplicación web y garantizar su accesibilidad desde cualquier lugar mediante una dirección IP. Se ha logrado cumplir este objetivo, permitiendo así el acceso a la herramienta desde cualquier punto.

4.2. Lineas Futuras

- Uno de los objetivos específicos del proyecto era el desarrollo de una aplicación web. Con este fin, se ha trabajado en su implementación y se ha alcanzado un avance significativo en su desarrollo, ya que se encuentra a un 80 % de su finalización. La línea de trabajo a seguir es la de continuar con los esfuerzos para completar la aplicación web y garantizar su funcionamiento de manera óptima.
- La tecnología de Machine Learning y Deep Learning está en constante evolución, y una de las líneas de investigación futura es el uso de diferentes algoritmos para mejorar la eficacia en tareas específicas. Uno de estos algoritmos es el de las redes neuronales con memoria a corto y largo plazo, conocidas como Long Short Term Memory (LSTM). Estas redes son especialmente eficaces en el aprendizaje de secuencias, lo que las hace ideales para aplicaciones en el campo del mantenimiento predictivo y la predicción de fallos en máquinas. En este sentido, el uso de LSTM podría mejorar significativamente la precisión y eficiencia en la detección y prevención de fallos en maquinaria y equipos industriales. Por lo tanto, el estudio y desarrollo de estas técnicas son altamente valiosos para mejorar la eficiencia operativa y reducir los costos de mantenimiento.
- Uno de los retos más interesantes en el campo del mantenimiento predictivo es la posibilidad de construir un sistema propio y personalizado para adaptarse a las necesidades específicas de una empresa. Esto implica el desarrollo de sensores utilizando dispositivos de hardware, como las Raspberry Pi, que permiten recopilar y analizar datos de las máquinas y equipos industriales. Además, se requiere de un sistema de almacenamiento de datos robusto y escalable para almacenar y procesar grandes cantidades de datos. Con estos componentes en su lugar, se puede utilizar una aplicación web para visualizar y analizar los datos recopilados, permitiendo a los usuarios obtener información valiosa sobre el estado de las máquinas y equipos. La ventaja de montar un sistema de este tipo es que se puede adaptar específicamente a las necesidades de la empresa y se tiene un mayor control sobre el proceso de recolección, almacenamiento y análisis de datos. Además, al tener un sistema personalizado se pueden obtener mejores resultados en la detección y prevención de fallos en maquinaria y equipos industriales, lo que a su vez puede ayudar a reducir costos y aumentar la eficiencia operativa.

Capítulo 5

Bibliografía

262588213843476. (n.d.). Hosting a Django application on AWS EC2 (running AMI Linux) - steps involved. Gist.

Retrieved from <https://gist.github.com/tanuka72/79ae58b16be4ac3fafe0>

An Introduction to Predictive Maintenance. (2002). doi:10.1016/B978-0-7506-7531-4.X5000-3

Bartodziej, C. J. (2017). The concept Industry 4.0. In C. J. Bartodziej (Ed.), The Concept Industry 4.0 : An Empirical Analysis of Technologies and Applications in Production Logistics (pp. 27–50). doi:10.1007/978-3-658-16502-4_3

Berry, M. W., Mohamed, A., & Yap, B. W. (2019). Supervised and Unsupervised Learning for Data Science (1st ed.). Springer Publishing Company, Incorporated.

Busche, R. (2022, July). Thesis Template. Retrieved from
<https://github.com/JarnoRFB/thesis-template>

Cachada, A., Barbosa, J., Leitño, P., Gcraldcs, C. A. S., Deusdado, L., Costa, J., ... Romero, L. (2018, September). Maintenance 4.0: Intelligent and Predictive Maintenance System Architecture. 2018 IEEE 23rd International Conference on Emerging Technologies and Factory Automation (ETFA), 1, 139–146. doi:10.1109/ETFA.2018.8502489

ChatGPT: Optimizing Language Models for Dialogue. (2022, November). OpenAI. Retrieved from <https://openai.com/blog/chatgpt/>

Chuang, S. (s. f.). Predictive Maintenance with Sensor Data Analytics on a Raspberry Pi-Based Experimental Platform. MDPI. <https://www.mdpi.com/1424-8220/19/18/3884>

- Coandă, P., Avram, M., & Constantin, V. (2020). A state of the art of predictive maintenance techniques. IOP Conference Series: Materials Science and Engineering, 997(1), 012039. doi:10.1088/1757-899X/997/1/012039
- Curcurù, G., Galante, G., & Lombardo, A. (2010). A predictive maintenance policy with imperfect monitoring. Reliability Engineering & System Safety, 95(9), 989–997. doi:10.1016/j.ress.2010.04.010
- Dieulle, L., Berenguer, C., Grall, A., & Roussignol, M. (2001, January). Continuous time predictive maintenance scheduling for a deteriorating system. Annual Reliability and Maintainability Symposium. 2001 Proceedings. International Symposium on Product Quality and Integrity (Cat. No.01CH37179), 150–155. doi:10.1109/RAMS.2001.902458
- Eckerson, W. W., Hanlon, N., & Barquin, R. (2000). DIRECTOR OF EDUCATION AND RESEARCH. 5(4).
- Garzón, J. I., Castellón, P., Wurtz, G., & Castellón, P. (2018, 6 noviembre). Cómo usar redes neuronales (LSTM) en la predicción de averías en las máquinas. Blog: GFT. <https://blog.gft.com/es/2018/11/06/como-usar-redes-neuronales-lstm-en-la-prediccion-de-averias-en-las-maquinias/>
- Ghavami, P. K. (2019). Big data analytics methods: analytics techniques in data mining, deep learning and natural language processing. De Gruyter.
- Grall, A., Dieulle, L., Berenguer, C., & Roussignol, M. (2002). Continuous-time predictive-maintenance scheduling for a deteriorating system. IEEE Transactions on Reliability, 51(2), 141-150. <https://doi.org/10.1109/tr.2002.1011518>
- Hashemian, H. M., & Bean, W. C. (2011). State-of-the-Art Predictive Maintenance Techniques*. IEEE Transactions on Instrumentation and Measurement, 60(10), 3480–3492. doi:10.1109/TIM.2009.2036347
- Ji, C., Li, Y. U., Qiu, D., Jin, Y., Xu, Y., Awada, U., ... Qu, W. (2013). Big data processing: Big challenges. Journal of Interconnection Networks, 13. doi:10.1142/S0219265912500090
- Kotsiantis, S. B. (n.d.). Supervised Machine Learning: A Review of Classification Techniques.
- Las tecnologías de la Industria 4.0 mejoran la economía circular. (n.d.). UPV/EHU. Retrieved from <https://www.ehu.eus/es/-/industria-4-0-economia-circular>

- Li, H., Parikh, D., He, Q., Qian, B., Li, Z., Fang, D., & Hampapur, A. (2014). Improving rail network velocity: A machine learning approach to predictive maintenance. *Transportation Research Part C: Emerging Technologies*, 45, 17–26. doi:10.1016/j.trc.2014.04.013
- Lu, B., Durocher, D., & Stemper, P. (2009). Predictive maintenance techniques. *IEEE Industry Applications Magazine*, 15(6), 52-60. <https://doi.org/10.1109/mias.2009.934444>
- Marr, B. (n.d.). 27 Incredible Examples Of AI And Machine Learning In Practice. *Forbes*. Retrieved from <https://www.forbes.com/sites/bernardmarr/2018/04/30/27-incredible-examples-of-ai-and-machine-learning-in-practice/>
- Martinez, I., Viles, E., & Olaizola, I. G. (2021). Data Science Methodologies: Current Challenges and Future Approaches. doi:10.48550/ARXIV.2106.07287
- Mokhtari, S., Abbaspour, A., Yen, K. K., & Sargolzaei, A. (2021). A Machine Learning Approach for Anomaly Detection in Industrial Control Systems Based on Measurement Data. *Electronics*, 10(4), 407. doi:10.3390/electronics10040407
- Mongkolchaichana, S., Phruksaphanrat, B., & Panjavongroj, S. (2021). Prioritization of Sustainable Supply Chain Management Practices in an Automotive Elastomer Manufacturer in Thailand Sustainable supply chain management Multiple attribute decision making Logarithmic fuzzy preference programming Prioritization A case study. *Advances in Science Technology and Engineering Systems Journal*, 6, 1079–1090.
- Morais, J., Pires, Y., Cardoso, C., & Klautau, A. (2009). An Overview of Data Mining Techniques Applied to Power Systems. doi:10.5772/6463
- Nangia, S. (2020, 29 marzo). IoT based Predictive Maintenance in Manufacturing Sector. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3563559
- Nantasesamat, C. (2021, June). How to Build a Machine Learning Model. *Medium*. Retrieved from <https://towardsdatascience.com/how-to-build-a-machine-learning-model-439ab8fb3fb1>
- Nasteski, V. (2017). An overview of the supervised machine learning methods. *HORIZONS*. B, 4, 51–62. doi:10.20544/HORIZONS.B.04.1.17.P05
- Olson, D., & Delen, D. (2008). Advanced Data Mining Techniques. doi:10.1007/978-3-540-76917-0
- Palacio-Niño, J.-O., & Berzal, F. (2019, May). Evaluation Metrics for Unsupervised Learning Algorithms. doi:10.48550/arXiv.1905.05667

- Park, C., Moon, D. H., Do, N., & Bae, S. (2016). A predictive maintenance approach based on real-time internal parameter monitoring. *The International Journal of Advanced Manufacturing Technology*, 85. doi:10.1007/s00170-015-7981-6
- Petrasch, R., & Hentschke, R. (2016). Process Modeling for Industry 4.0 Applications Towards an Industry 4.0 Process Modeling Language and Method. doi:10.1109/JCSSE.2016.7748885
- Practical Machinery Vibration Analysis and Predictive Maintenance - 1st Edition. (n.d.). Retrieved from <https://www.elsevier.com/books/practical-machinery-vibration-analysis-and-predictive-maintenance/scheffer/978-0-7506-6275-8>
- Saxena, A., Prasad, M., Gupta, A., Bharill, N., Patel, O. P., Tiwari, A., ... Lin, C.-T. (2017). A review of clustering techniques and developments. *Neurocomputing*, 267, 664–681. doi:10.1016/j.neucom.2017.06.053
- Seel, N. M. (Ed.). (2012). Encyclopedia of the sciences of learning. New York: Springer.
- Sahin, O. (2022, 20 junio). Water Pump Dataset Exploration – Ozan SAHİN. <http://sahinozan.com/index.php/2022/06/20/water-pump-dataset-exploration/>
- Sehra, S., Flores, D., & Montanez, G. (2021). Undecidability of Underfitting in Learning Algorithms.
- Sunilkumar. (2022, January). Predictive Maintenance of Pumps. Medium. Retrieved from <https://medium.com/@suniaidvpr/predictive-maintenance-of-pumps-7c358f0efe68>
- Susto, G. A., Wan, J., Pampuri, S., Zanon, M., Johnston, A. B., O’Hara, P. G., & McLoone, S. (2014, August). An adaptive machine learning decision system for flexible predictive maintenance. 2014 IEEE International Conference on Automation Science and Engineering (CASE), 806–811. doi:10.1109/CoASE.2014.6899418
- Theissler, A., Pérez-Velázquez, J., Kettelgerdes, M., & Elger, G. (2021). Predictive maintenance enabled by machine learning: Use cases and challenges in the automotive industry. *Reliability Engineering & System Safety*, 215, 107864. doi:10.1016/j.ress.2021.107864
- Tunkelang, D. (2017, September). 10 Things Everyone Should Know About Machine Learning. Medium. Retrieved from <https://dtunkelang.medium.com/10-things-everyone-should-know-about-machine-learning-15279c27ce96>

Ullah, I., Yang, F., Khan, R., Liu, L., Yang, H., Gao, B., & Sun, K. (2017). Predictive Maintenance of Power Substation Equipment by Infrared Thermography Using a Machine-Learning Approach. *Energies*, 10(12), 1987. doi:10.3390/en10121987

UNE-EN 13306:2018 Mantenimiento. Terminología del mantenimiento. (n.d.). Retrieved from <https://www.une.org/encuentra-tu-norma/busca-tu-norma/norma?c=N0060338>

Vij, A., Vijendra, S., Jain, A., Bajaj, S., Bassi, A., & Sharma, A. (2020). IoT and Machine Learning Approaches for Automation of Farm Irrigation System. *Procedia Computer Science*, 167, 1250–1257. doi:10.1016/j.procs.2020.03.440

Water Pump Dataset Exploration – Ozan ŞAHİN. (n.d.). Retrieved from <http://sahinozan.com/index.php/2022/06/20/water-pump-dataset-exploration/>

Zhu, X. (2008). Semi-Supervised Learning Literature Survey. *Comput Sci*, University of Wisconsin-Madison, 2.

Anexo I

Figura 5.1: Sensor_03

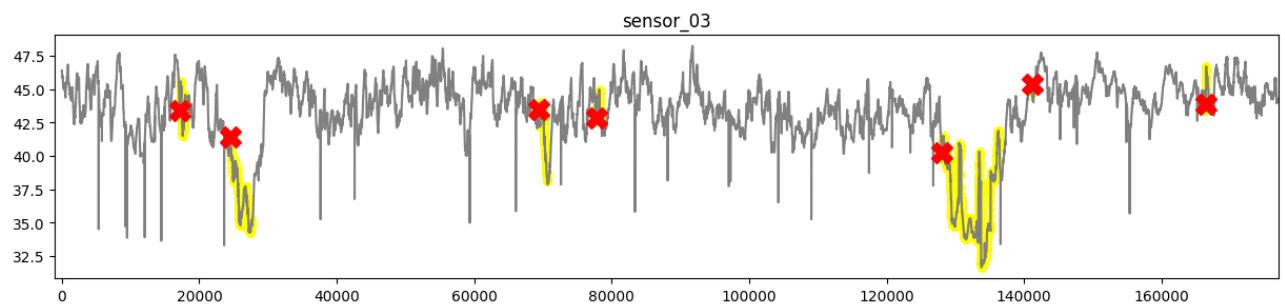


Figura 5.2: Sensor_04

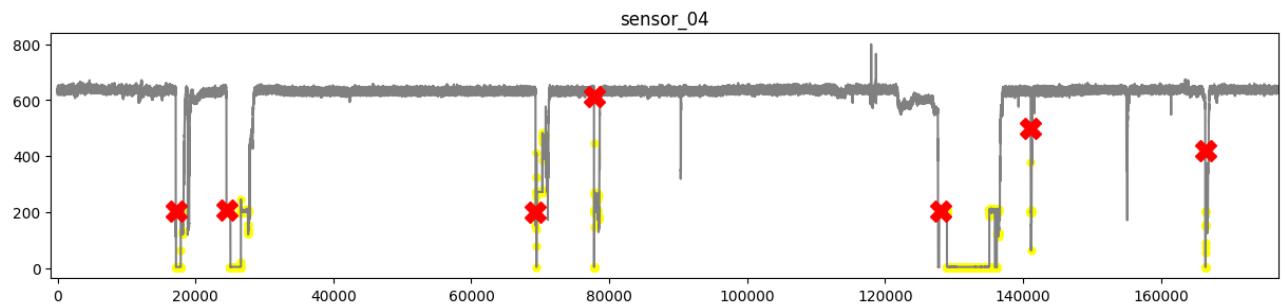


Figura 5.3: Sensor_05

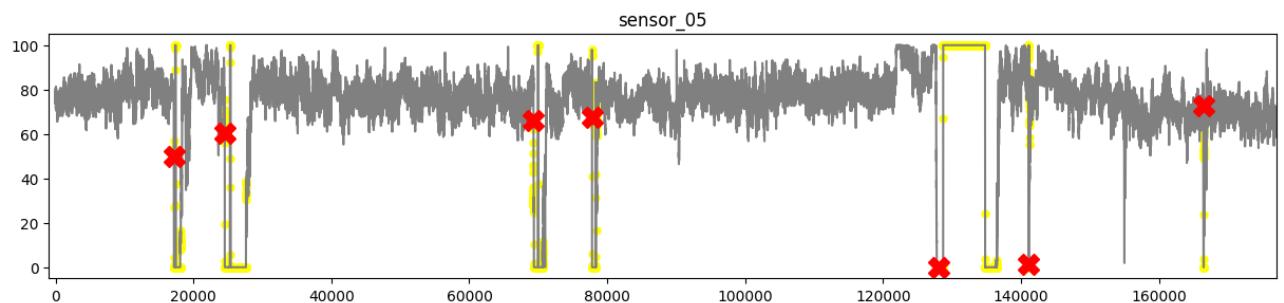


Figura 5.4: Sensor_06

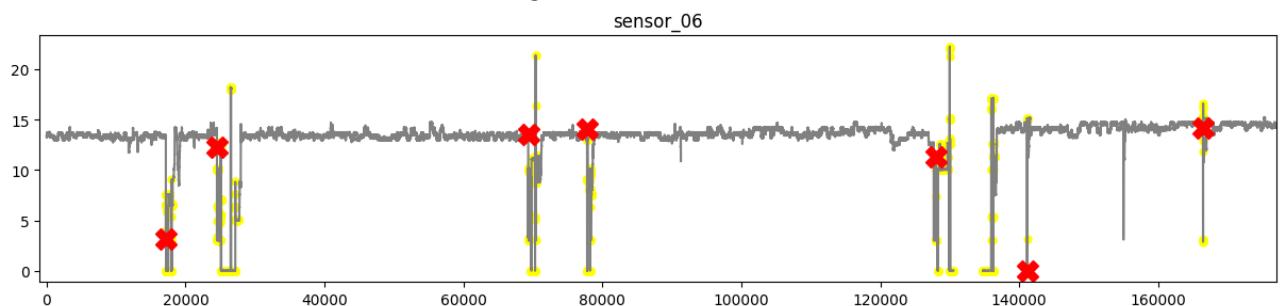


Figura 5.5: Sensor_07

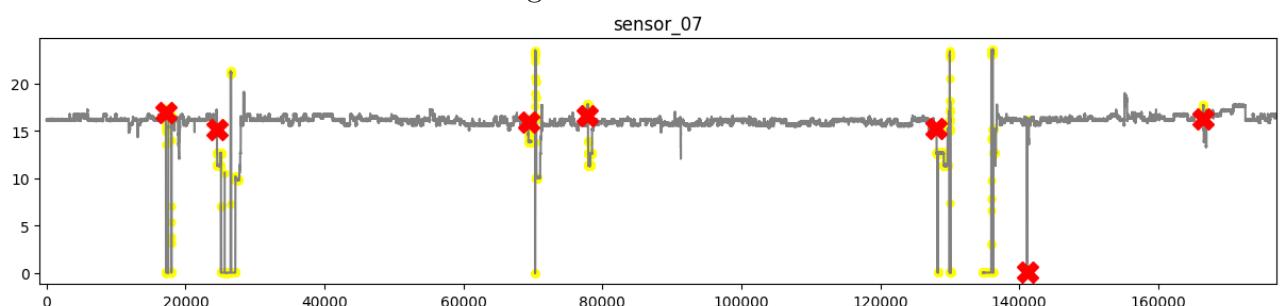


Figura 5.6: Sensor_08

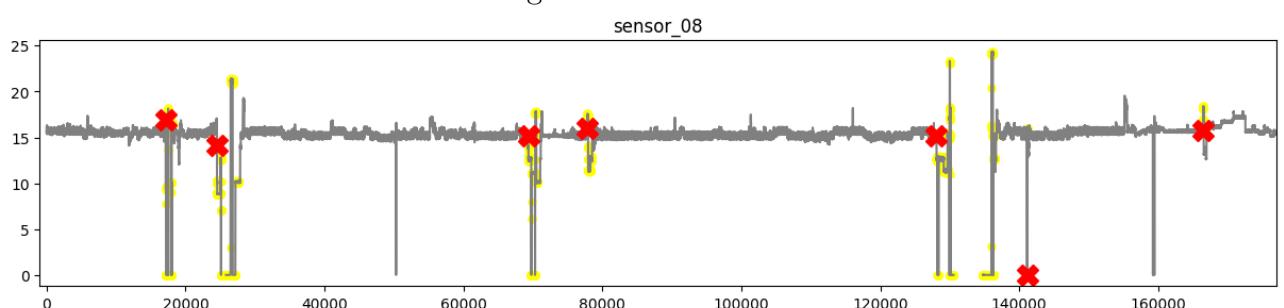


Figura 5.7: Sensor_09

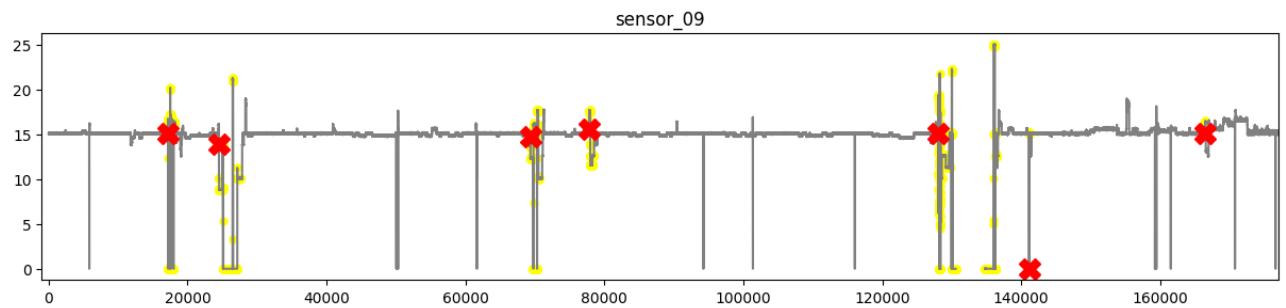


Figura 5.8: Sensor_10

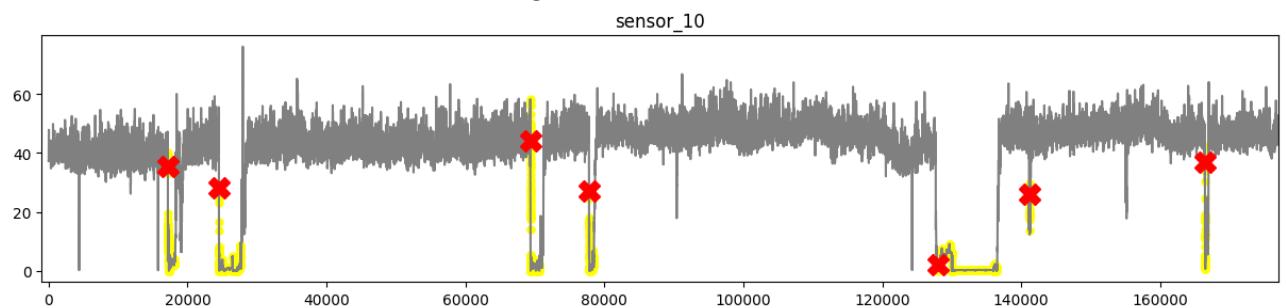


Figura 5.9: Sensor_11

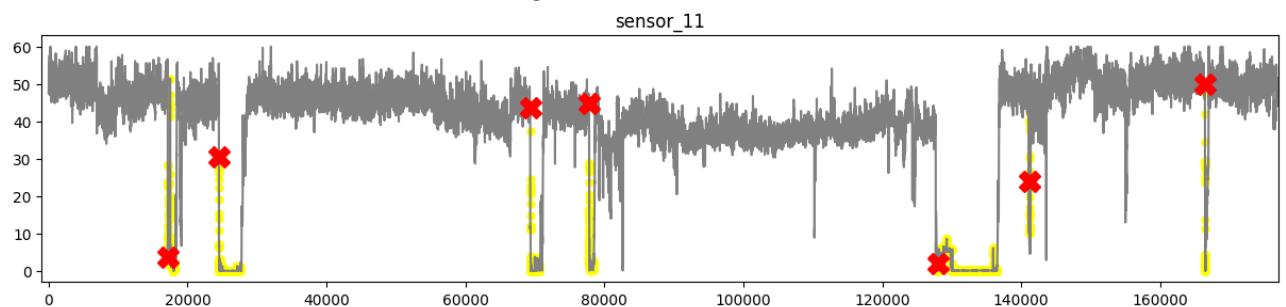


Figura 5.10: Sensor_12

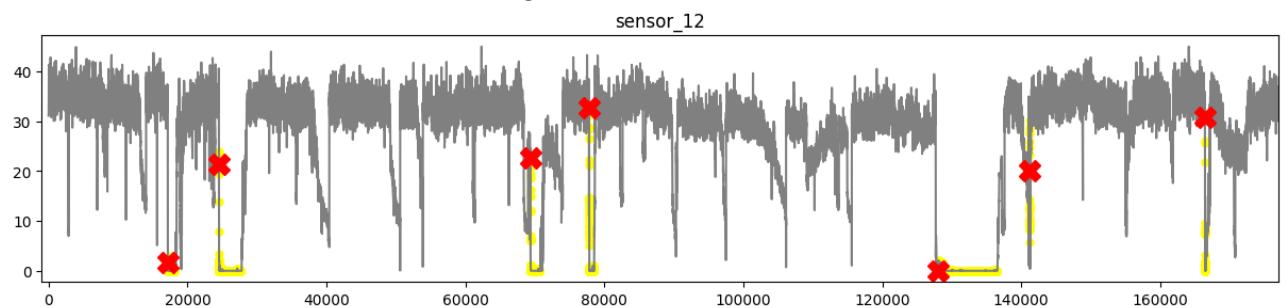


Figura 5.11: Sensor_13

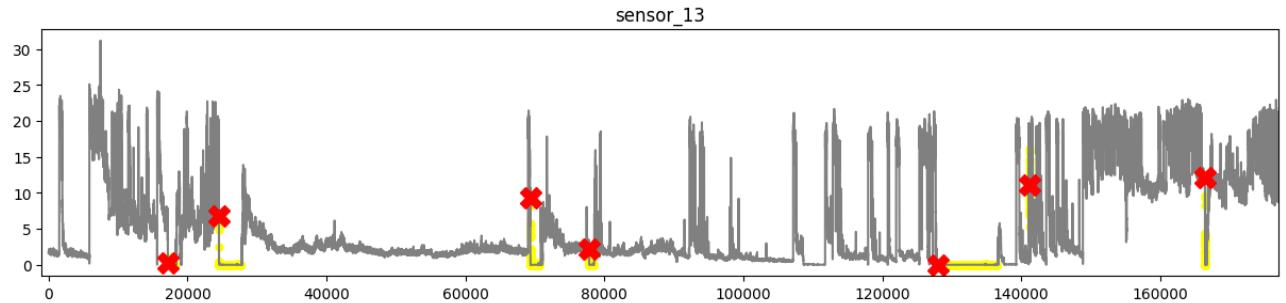


Figura 5.12: Sensor_14

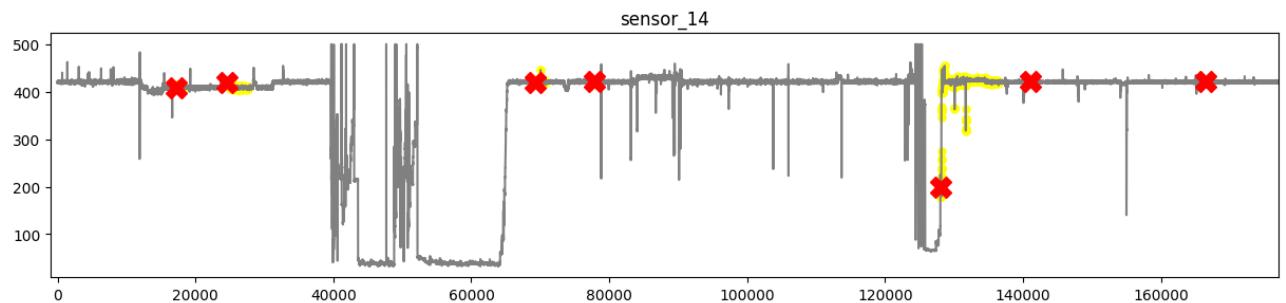


Figura 5.13: Sensor_16

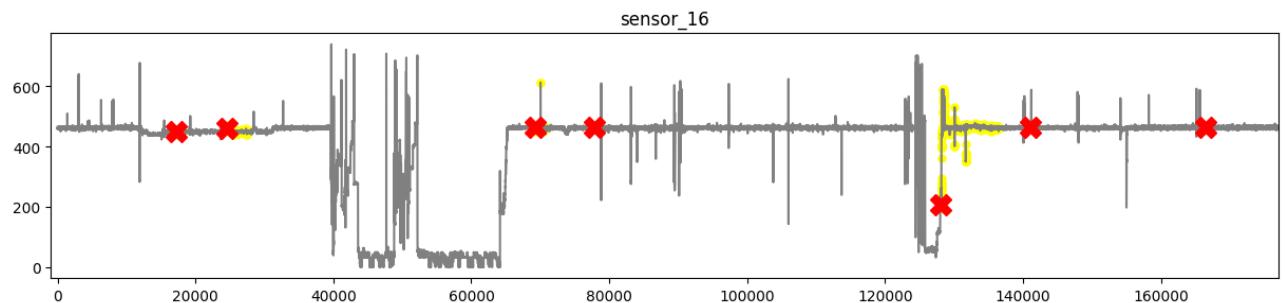


Figura 5.14: Sensor_17

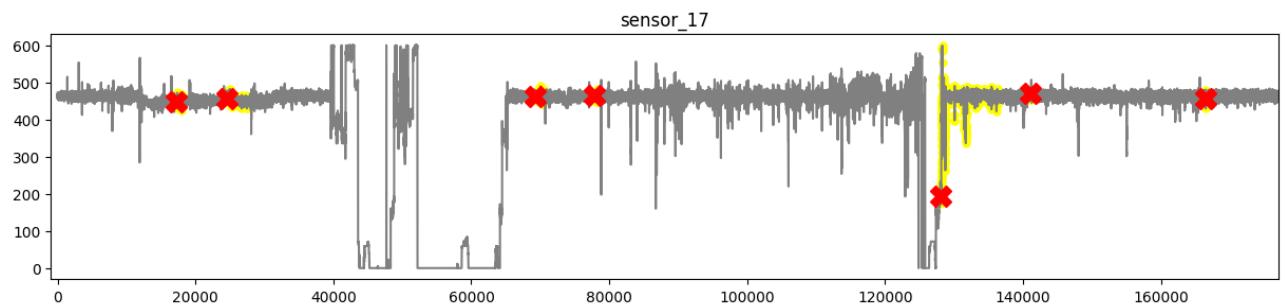


Figura 5.15: Sensor_18

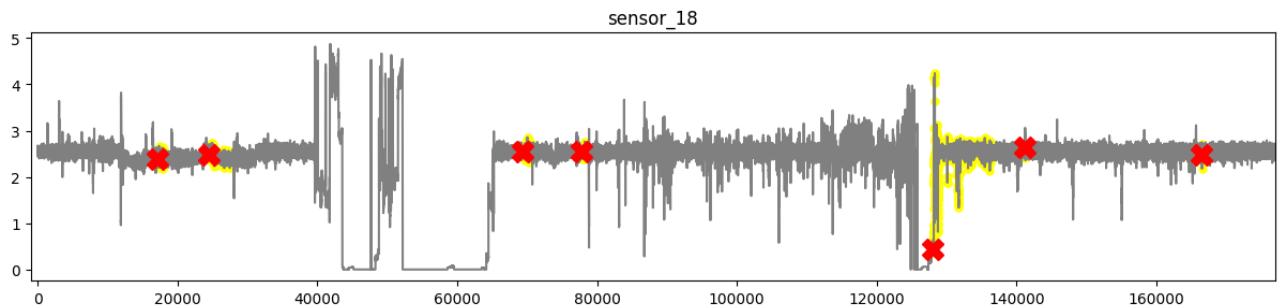


Figura 5.16: Sensor_19

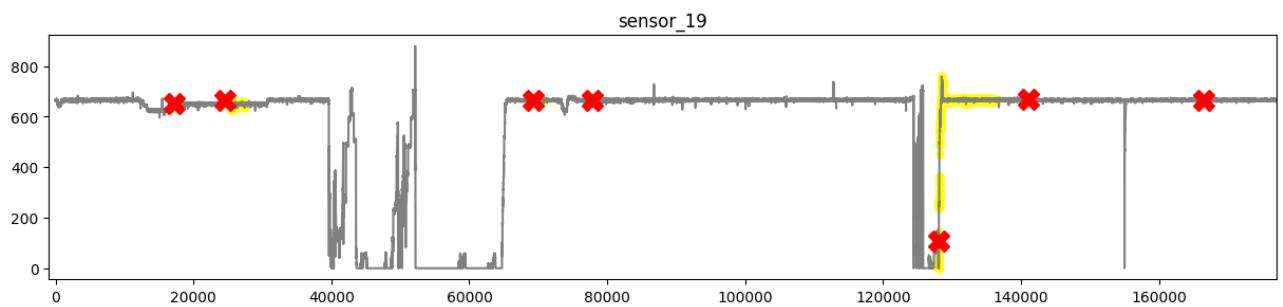


Figura 5.17: Sensor_20

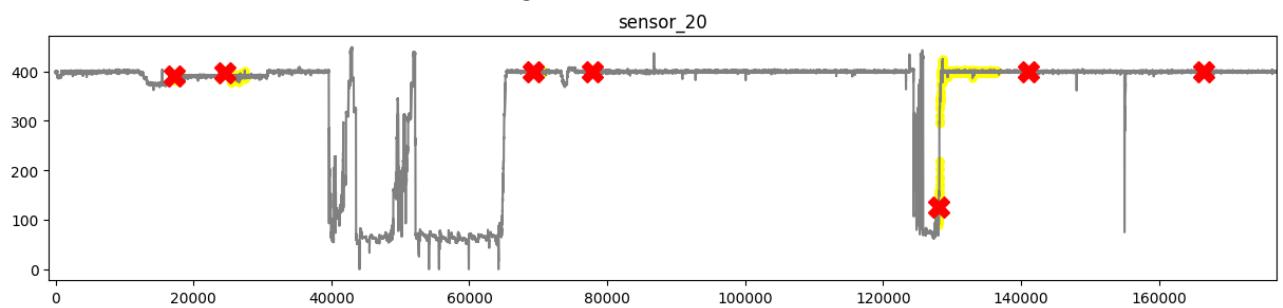


Figura 5.18: Sensor_21

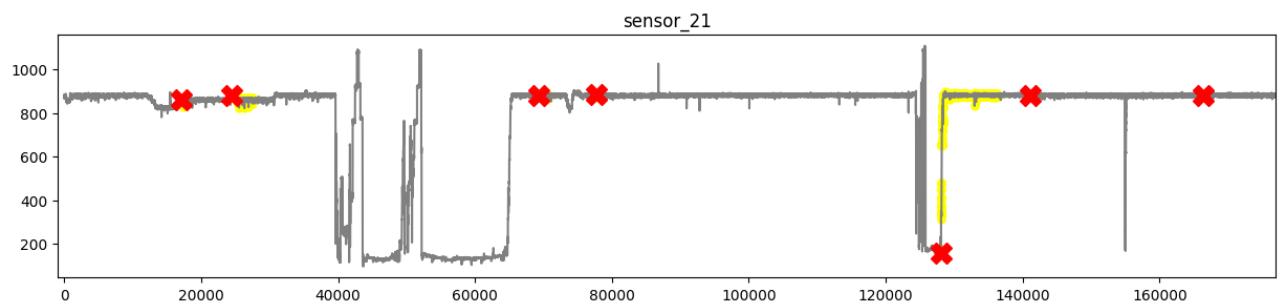


Figura 5.19: Sensor_22

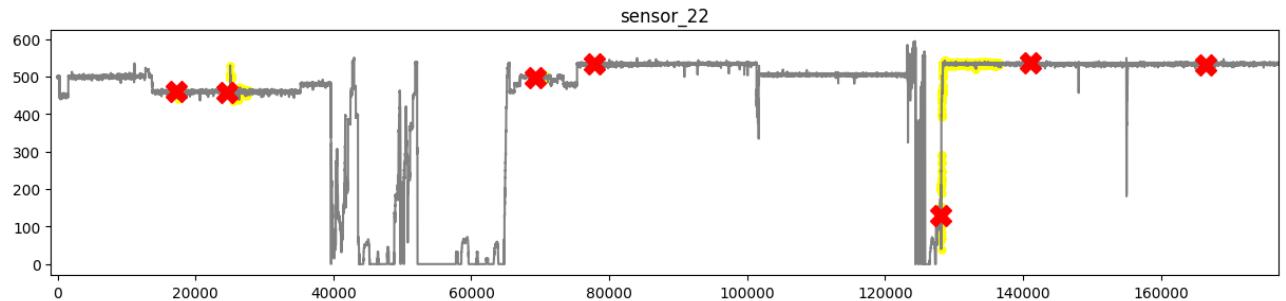


Figura 5.20: Sensor_23

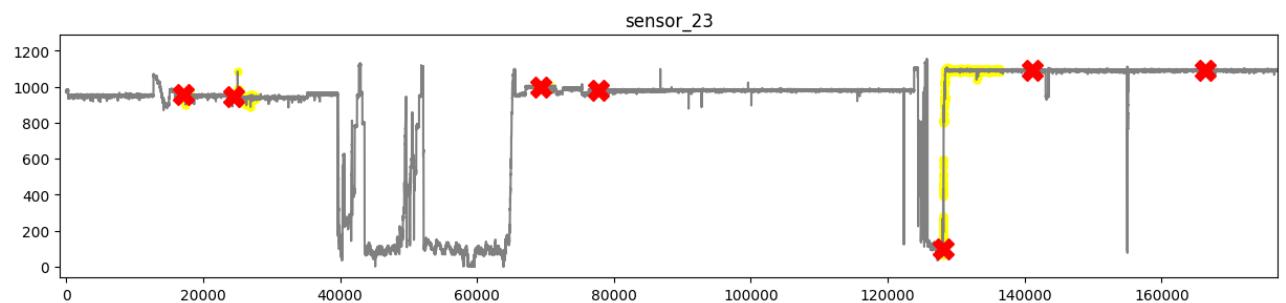


Figura 5.21: Sensor_24

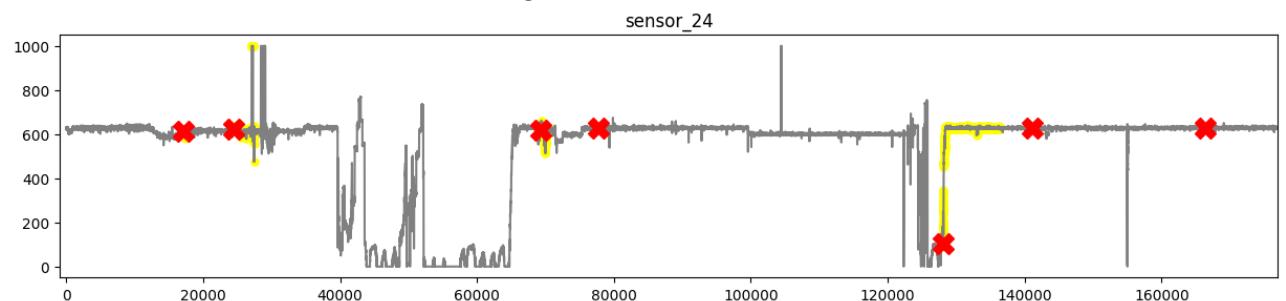


Figura 5.22: Sensor_25

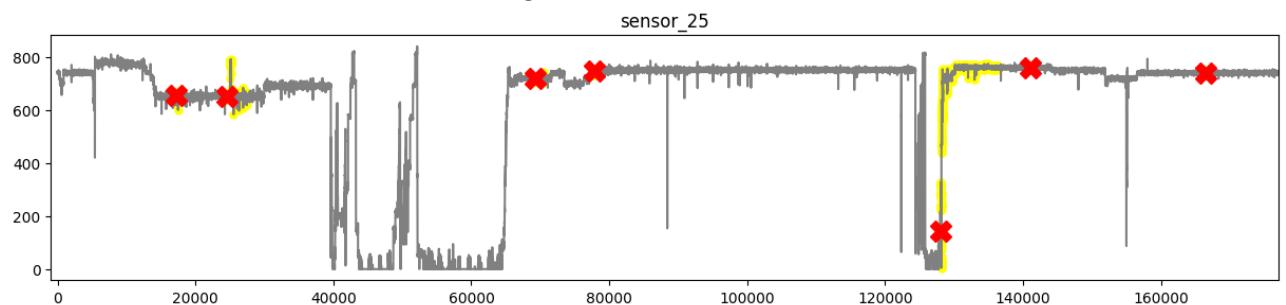


Figura 5.23: Sensor_26

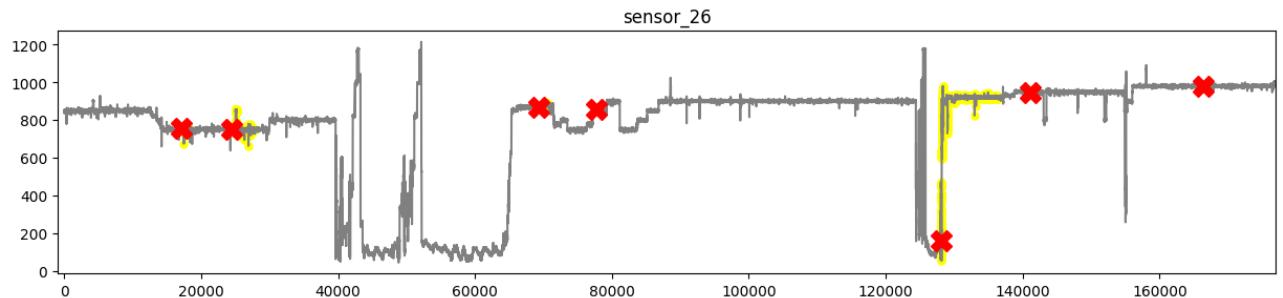


Figura 5.24: Sensor_27

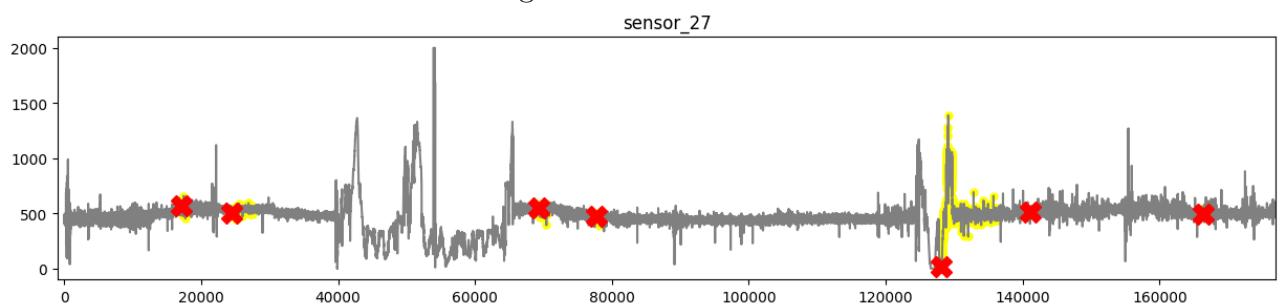


Figura 5.25: Sensor_28

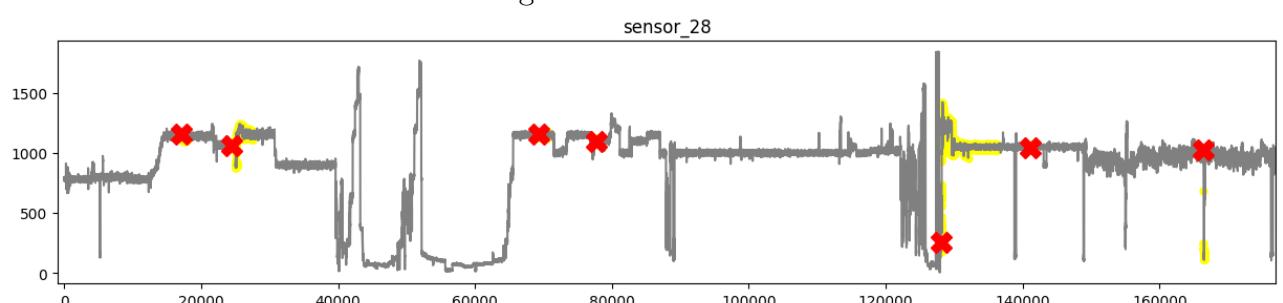


Figura 5.26: Sensor_29

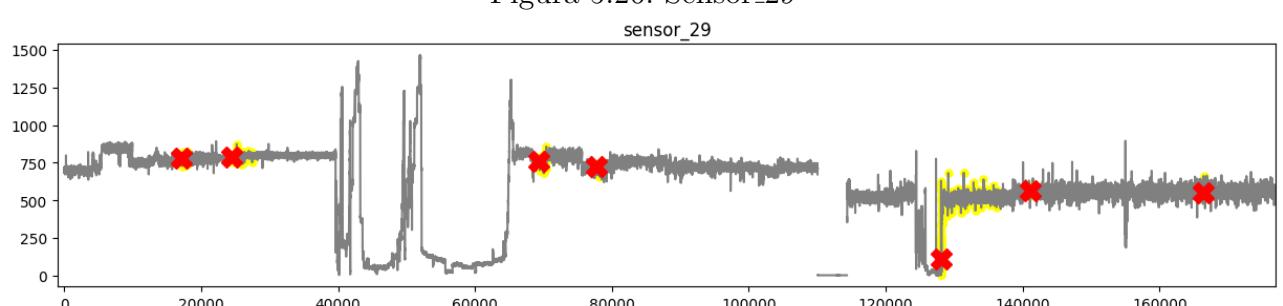


Figura 5.27: Sensor_30

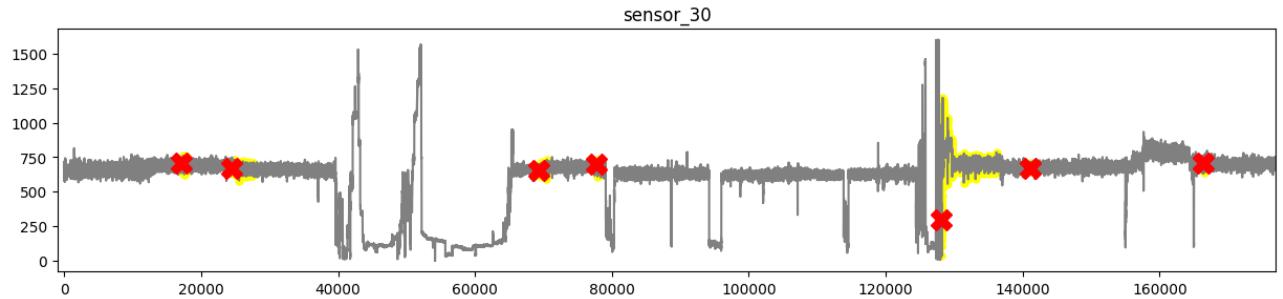


Figura 5.28: Sensor_31

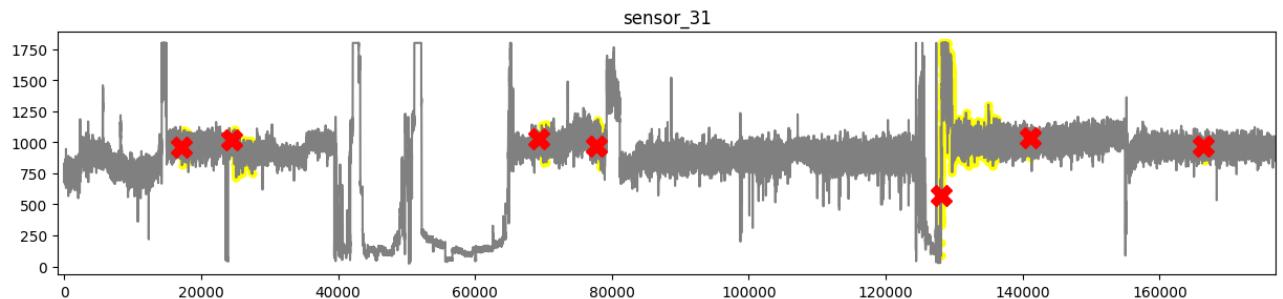


Figura 5.29: Sensor_32

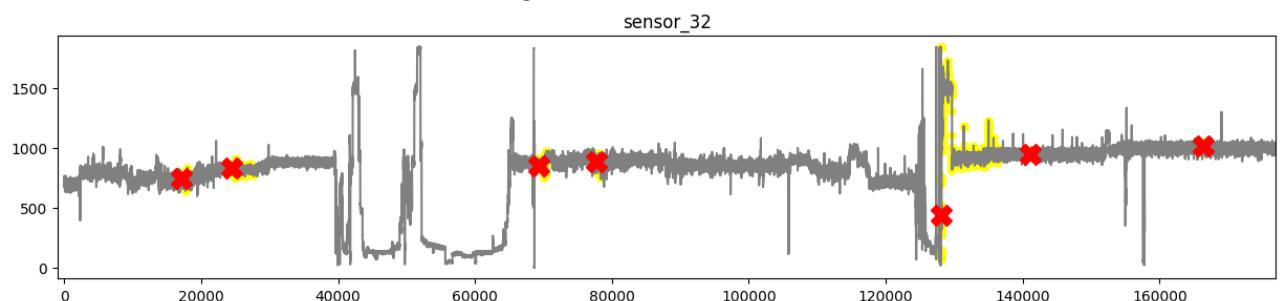


Figura 5.30: Sensor_33

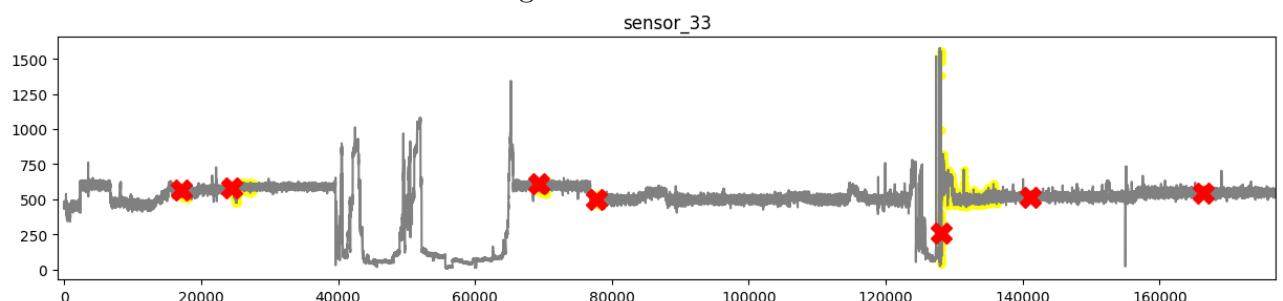


Figura 5.31: Sensor_34

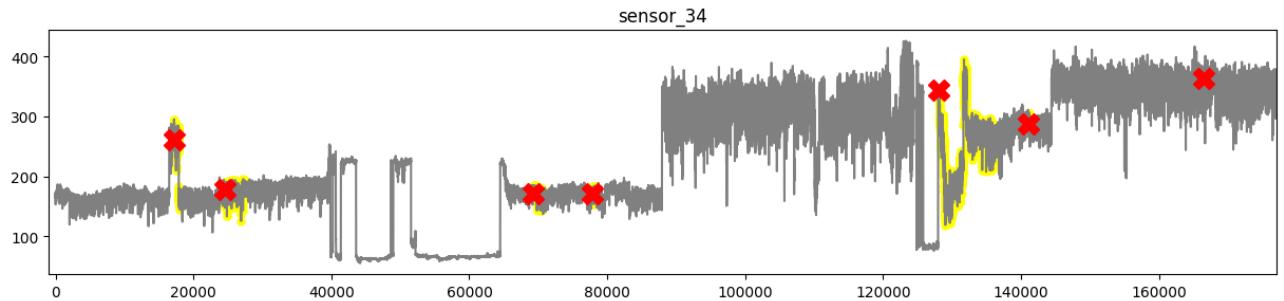


Figura 5.32: Sensor_35

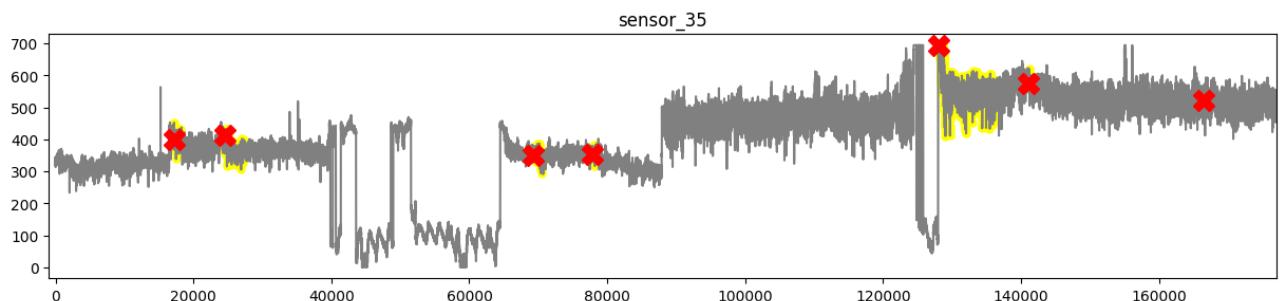


Figura 5.33: Sensor_36

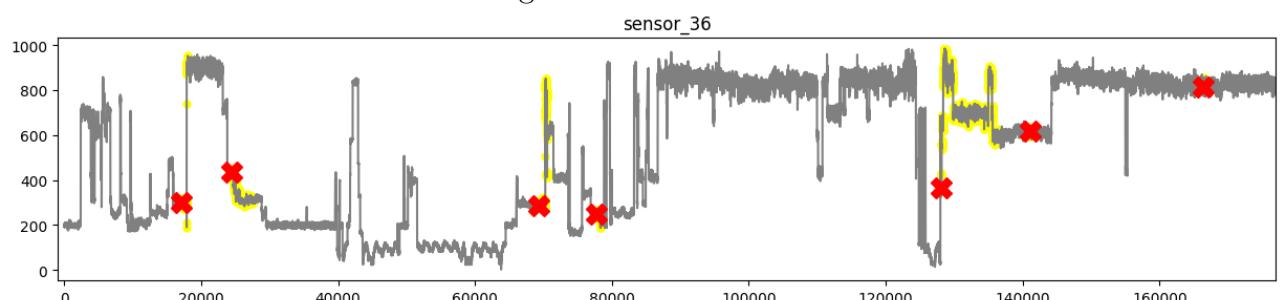


Figura 5.34: Sensor_37

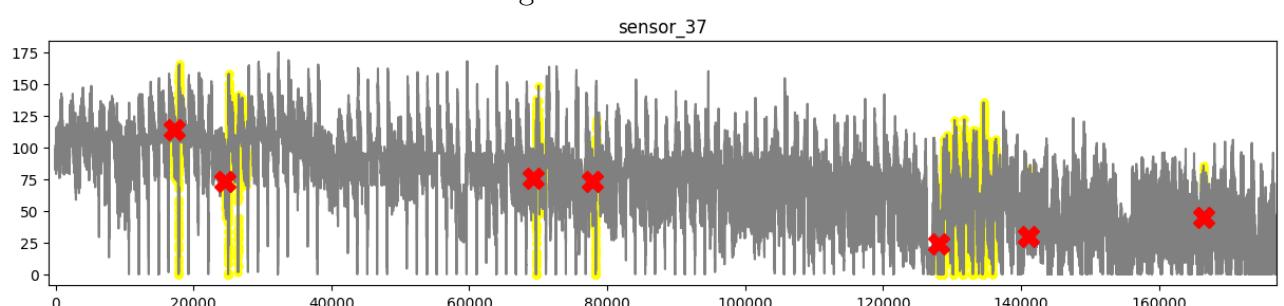


Figura 5.35: Sensor_38

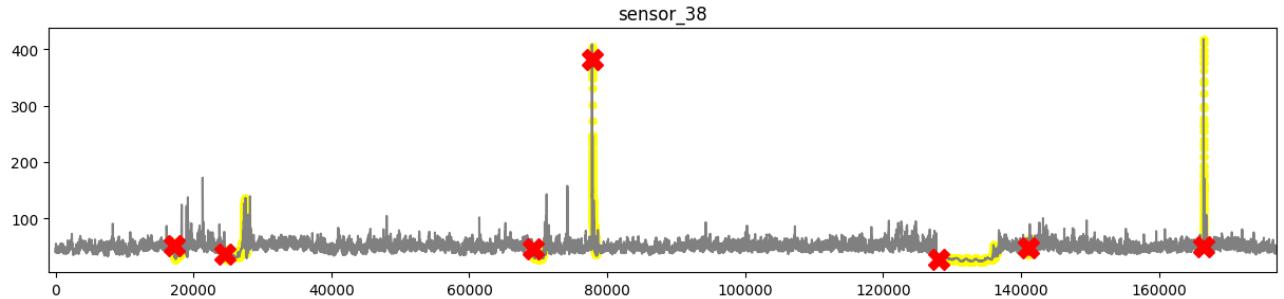


Figura 5.36: Sensor_39

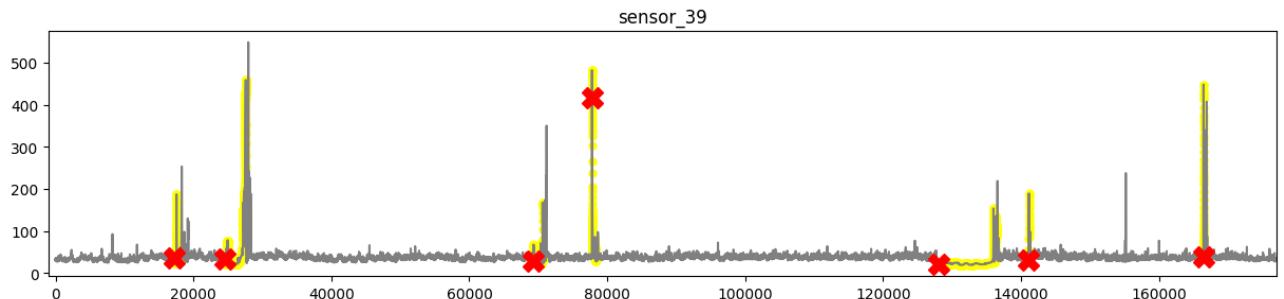


Figura 5.37: Sensor_40

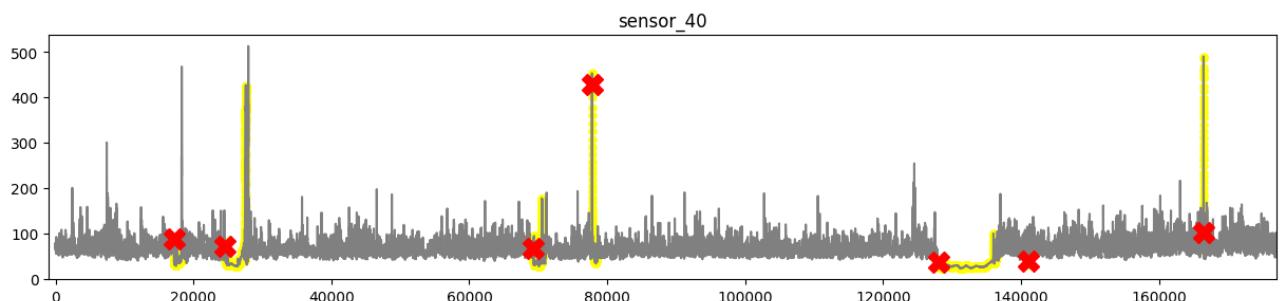


Figura 5.38: Sensor_41

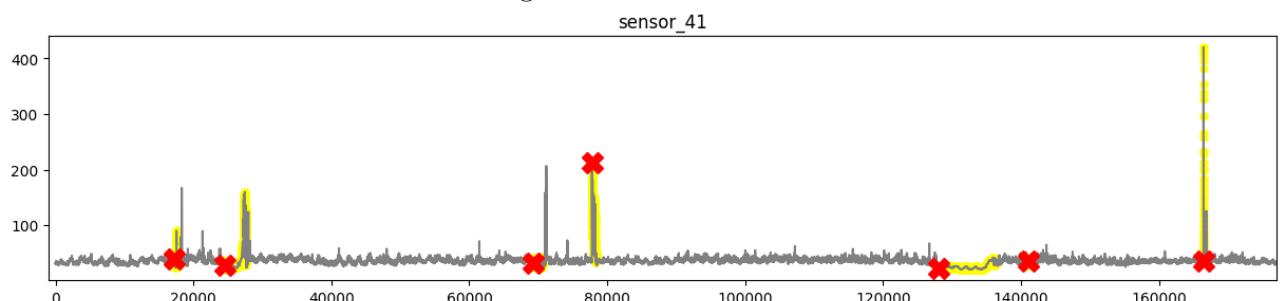


Figura 5.39: Sensor_42

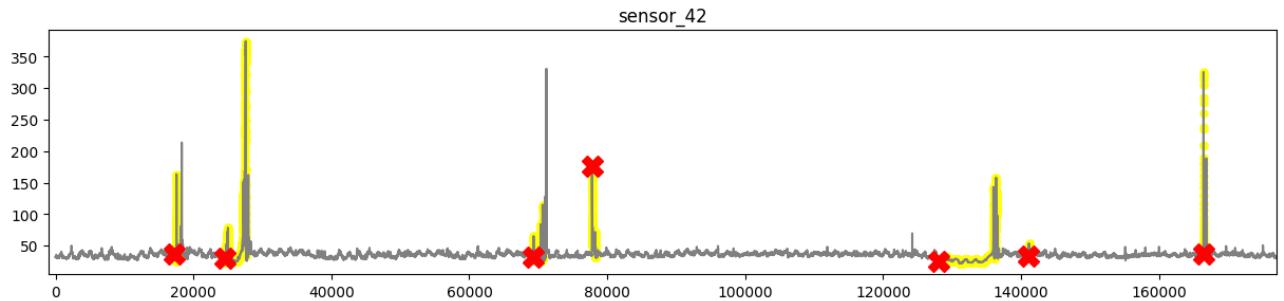


Figura 5.40: Sensor_43

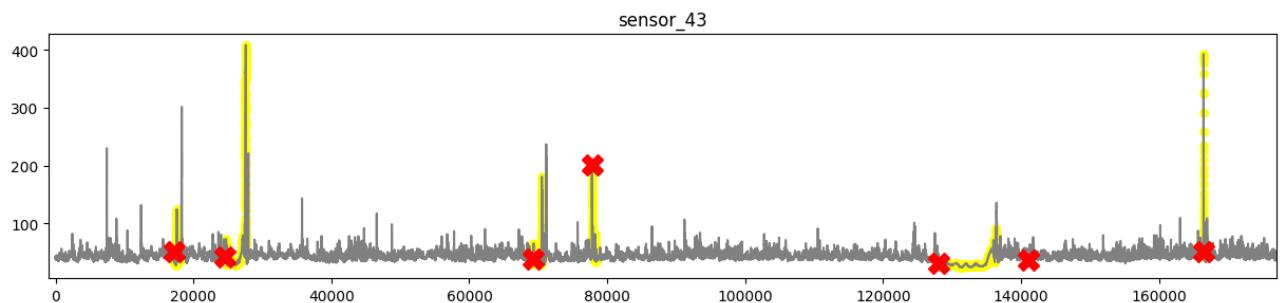


Figura 5.41: Sensor_44

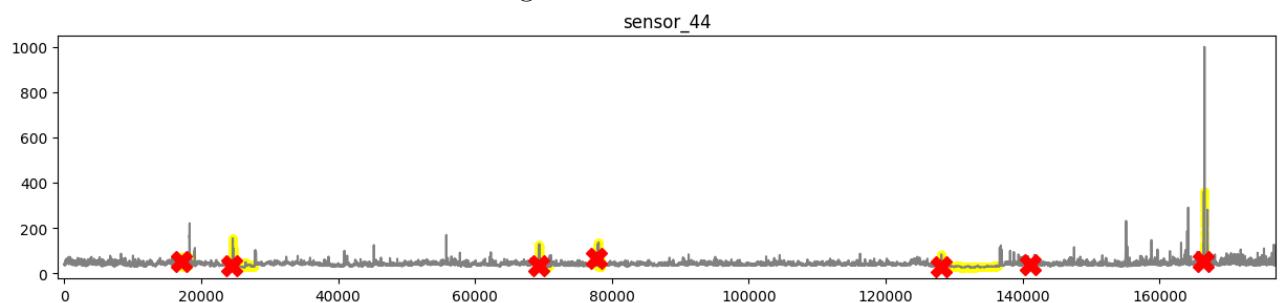


Figura 5.42: Sensor_45

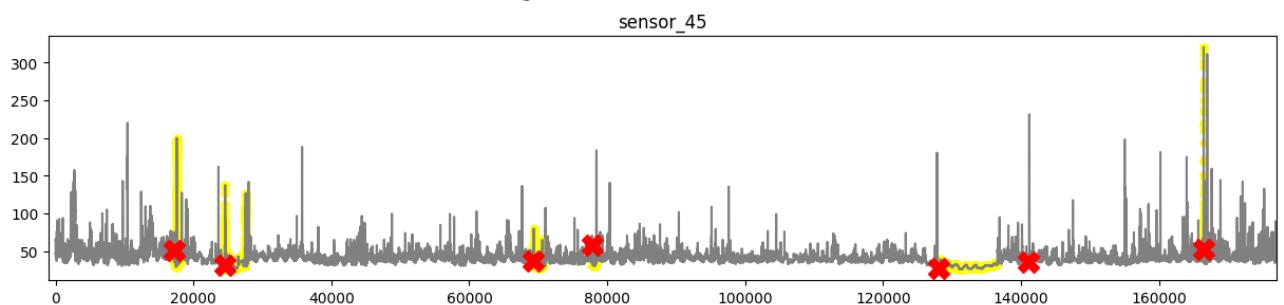


Figura 5.43: Sensor_46

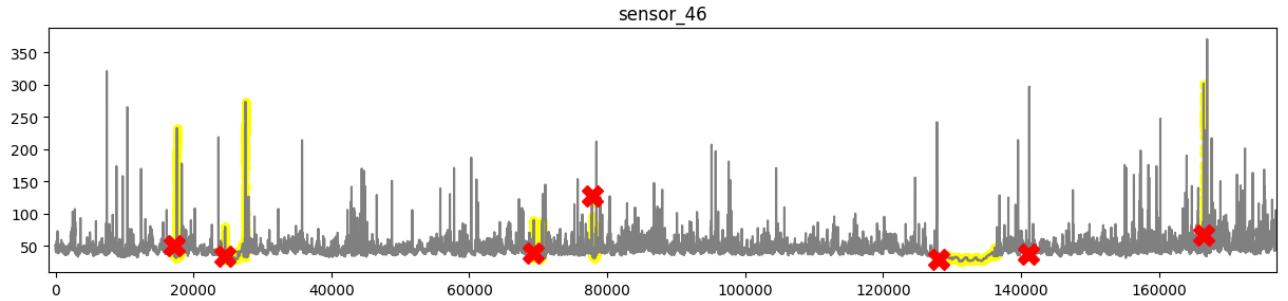


Figura 5.44: Sensor_47

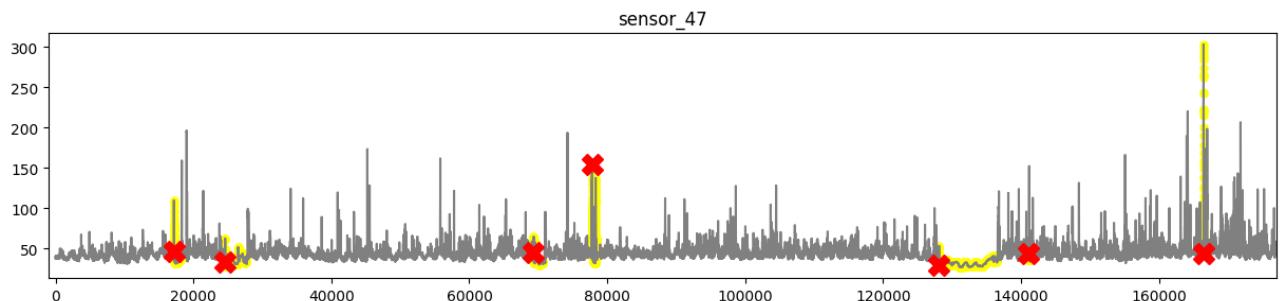


Figura 5.45: Sensor_48

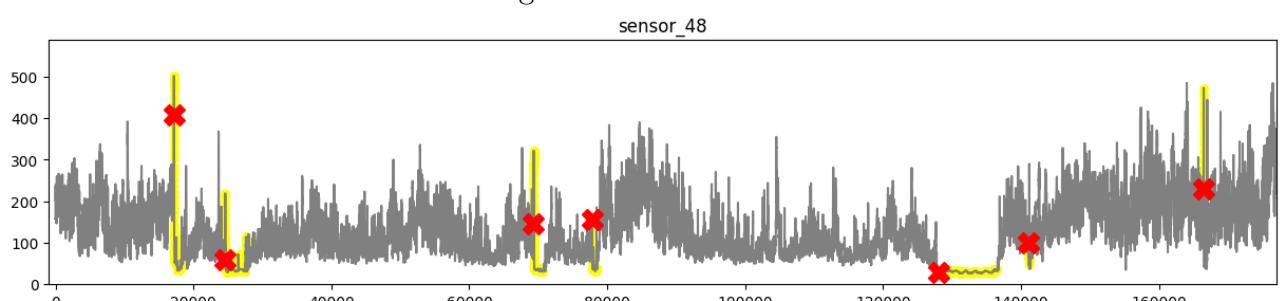


Figura 5.46: Sensor_49

